Pregunta 1 — Mediación moderada

Métodos Cuantitativos de la Investigación en Negocios — Tarea 2 (2026)

```python
# Instalación condicional de dependencias para Google Colab.
# En ejecución local no instala nada si los paquetes ya están disponibles.
import importlib, subprocess, sys

def instalar_si_falta(import_name, package_name=None):
    package_name = package_name or import_name
    try:
        importlib.import_module(import_name)
    except ImportError:
        print(f'Instalando {package_name}...')
        subprocess.check_call([sys.executable, '-m', 'pip', 'install', '-q', package_name])

instalar_si_falta('pyreadstat', 'pyreadstat')

print('Dependencias verificadas y entorno inicial preparado.')

```

```
Dependencias verificadas y entorno inicial preparado.
```

Enunciado de la pregunta 1

Para cada una de las preguntas, describa claramente los pasos seguidos y adjunte los resultados de los análisis efectuados durante el proceso.

1. Como parte de una investigación en la que está participando, se le ha solicitado realizar un análisis de un modelo que explica la relación entre la presión competitiva del mercado y el desempeño innovador de la empresa. En este modelo (ver figura 1) se plantea que el efecto de la presión competitiva sobre el desempeño innovador está mediado por la conducta innovadora de los empleados, pero que esta relación depende de la cultura de tolerancia al fracaso de la organización.

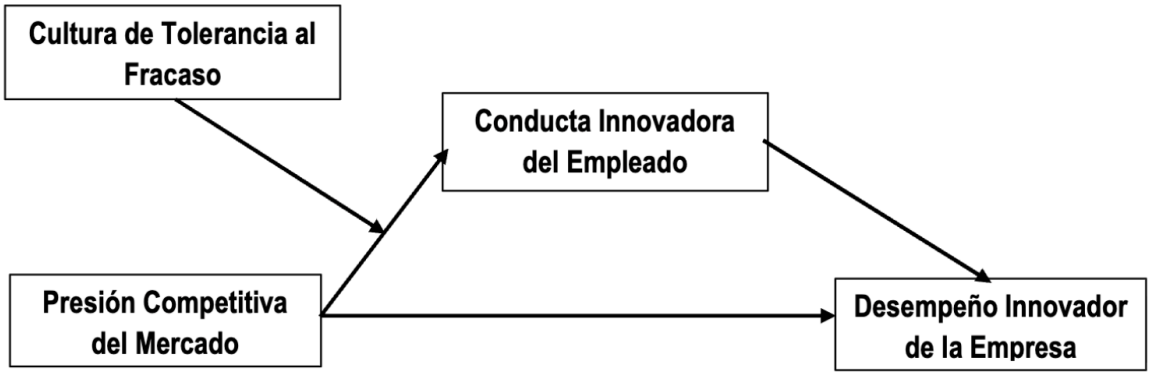

Figura 1

Las variables del modelo se explican a continuación:

- **Presión Competitiva del Mercado:** Nivel de rivalidad y cambios tecnológicos en el sector, medida en una escala de 1 a 10, donde un mayor número representa una mayor presión competitiva.
- **Cultura de Tolerancia al Fracaso:** Grado en que la gerencia castiga o premia los errores al experimentar, medida en una escala de 1 a 7, donde un mayor número representa una mayor tolerancia al fracaso por parte de la gerencia.
- **Conducta Innovadora del Empleado:** Generación e implementación de ideas nuevas en el trabajo, medida como el número de ideas propuestas por el empleado en los últimos 5 años.
- **Desempeño Innovador de la Empresa:** Generación exitosa de nuevos productos o servicios para el mercado, medida como el porcentaje de ingresos de la organización proveniente de productos o servicios lanzados los últimos 5 años.

Con los datos de las respuestas 200 empleados de 200 empresas distintas, contenidos en la base `Med_Mod.sav`, usted deberá:

a) Plantear el modelo en forma de hipótesis.
b) Evaluar cada una de estas hipótesis.
c) Interpretar los resultados.

Respuesta

El modelo corresponde a una **mediación moderada de primera etapa**: la presión competitiva del mercado puede influir en el desempeño innovador a través de la conducta innovadora del empleado, y ese primer tramo depende de la cultura de tolerancia al fracaso.

En términos de variables estadísticas:

- **X:** Presión competitiva del mercado.
- **W:** Cultura de tolerancia al fracaso.
- **M:** Conducta innovadora del empleado.
- **Y:** Desempeño innovador de la empresa.

La lógica estadística es equivalente al **modelo 7 de Hayes**. En este notebook no se usa la macro PROCESS directamente; se reproduce esa especificación en Python mediante regresiones OLS y bootstrap para el efecto indirecto condicional.

```
from pathlib import Path
from urllib.request import urlretrieve, urlopen
import ssl
import warnings
warnings.filterwarnings('ignore')

import numpy as np
import pandas as pd
import pyreadstat
from scipy import stats
import statsmodels.api as sm
import statsmodels.formula.api as smf

pd.set_option('display.max_columns', 100)
pd.set_option('display.width', 160)

# Base requerida para este notebook.
# Funciona localmente y también en Google Colab abierto desde GitHub.
REQUIRED_DATA_FILE = 'Med_Mod.sav'
RAW_DATA_BASE = 'https://raw.githubusercontent.com/sebabecerra/Metodos-Cuantitativos-DEN/main/Tarea2/data'

def encontrar_o_descargar_base(filename):
    candidatas = [
        Path.cwd() / 'data',                # ejecución desde Tarea2
        Path.cwd().parent / 'data',         # ejecución desde Tarea2/notebooks
        Path.cwd() / 'Tarea2' / 'data',     # ejecución desde raíz del repo o Colab
        Path.cwd()                          # respaldo: base junto al notebook
    ]
    for ruta in candidatas:
        if (ruta / filename).exists():
            return ruta

    # Si Colab no tiene la carpeta del repo clonada, se descarga la base desde GitHub.
    destino_dir = Path.cwd() / 'Tarea2' / 'data'
    destino_dir.mkdir(parents=True, exist_ok=True)
    destino = destino_dir / filename
    url = f'{RAW_DATA_BASE}/{filename}'
    print(f'Base {filename} no encontrada localmente. Descargando desde GitHub...')
    try:
        urlretrieve(url, destino)
    except Exception as error:
        # Respaldo útil en algunos entornos locales con problemas de certificados SSL.
        # En Colab normalmente no se activa, pero evita fallas si Python no encuentra certificados.
        print('Descarga estándar falló; intentando respaldo SSL...')
        contexto = ssl._create_unverified_context()
        with urlopen(url, context=contexto) as respuesta, open(destino, 'wb') as archivo:
            archivo.write(respuesta.read())
    return destino_dir

DATA_DIR = encontrar_o_descargar_base(REQUIRED_DATA_FILE)
print('Directorio de datos:', DATA_DIR)
print('Base usada:', DATA_DIR / REQUIRED_DATA_FILE)
```

```
Directorio de datos: /content/Tarea2/data
Base usada: /content/Tarea2/data/Med_Mod.sav
```

1.a) Planteamiento del modelo en forma de hipótesis

Se analiza una **mediación moderada de primera etapa**:

- X: presión competitiva del mercado.
- M: conducta innovadora del empleado.
- Y: desempeño innovador de la empresa.
- W: cultura de tolerancia al fracaso.

La moderación se ubica en la relación $X \rightarrow M$. Antes de escribir las ecuaciones, se define la notación: X_c representa la presión competitiva centrada en su media, W_c representa la tolerancia al fracaso centrada en su media, M corresponde a la conducta innovadora del empleado y Y al desempeño innovador de la empresa. Los coeficientes a_1, a_2, a_3, b, c' y c representan los efectos estimados en cada camino: a_1 es la asociación entre presión competitiva y conducta innovadora cuando $W_c = 0$, a_2 es la asociación entre tolerancia al

fracaso y conducta innovadora cuando $X_c = 0$, a_3 es la interacción, b es la asociación entre conducta innovadora y desempeño, c' es el efecto directo residual y c es el efecto total.

El análisis se articula en **tres ecuaciones**:

$$\begin{aligned} \text{(1) Mediador:} \quad & M = i_M + a_1 X_c + a_2 W_c + a_3 (X_c W_c) + e_M \\ \text{(2) Resultado:} \quad & Y = i_Y + c' X + bM + e_Y \\ \text{(3) Efecto total:} \quad & Y = i_T + cX + e_T \end{aligned}$$

Las ecuaciones (1) y (2) constituyen el sistema estructural equivalente al modelo 7 de Hayes; la ecuación (3) se reporta para documentar el efecto total, aunque no forma parte de las hipótesis formales. A partir de (1) y (2) se deriva el efecto indirecto condicional $(a_1 + a_3 W)b$, que es una función de los coeficientes y no una regresión adicional.

Las hipótesis, alineadas con las flechas de la figura del enunciado, son:

- **H1:** la presión competitiva se asocia positivamente con la conducta innovadora ($a_1 > 0$).
- **H2:** la conducta innovadora se asocia positivamente con el desempeño innovador ($b > 0$).
- **H3:** existe un efecto directo residual de la presión competitiva sobre el desempeño una vez incorporada la conducta innovadora ($c' \neq 0$).
- **H4:** existe un efecto indirecto significativo de la presión competitiva sobre el desempeño a través de la conducta innovadora ($IE(W_c) \neq 0$).
- **H5:** la tolerancia al fracaso fortalece la relación presión competitiva--conducta innovadora ($a_3 > 0$).

El índice de mediación moderada $a_3 b$ se reporta como evidencia complementaria, porque indica si el mecanismo indirecto cambia de intensidad según W. El efecto total c se estima y reporta porque documenta la asociación global, pero la hipótesis formal sobre el vínculo $X \rightarrow Y$ es H3, correspondiente al camino directo dibujado en la figura.

```python
# Chequeo inicial de la base.
# Se carga la base completa; no se filtran observaciones ni se toma una submuestra.
# apply_value_formats=False conserva los valores numéricos originales, necesarios para estimar los modelos.
df, meta = pyreadstat.read_sav(DATA_DIR/'Med_Mod.sav', apply_value_formats=False)

print('Archivo usado:', DATA_DIR/'Med_Mod.sav')
print('Número de observaciones:', len(df))
print('Número de variables:', df.shape[1])
print('Dimensión de la base:', df.shape)
print('Datos perdidos totales:', int(df.isna().sum().sum()))
print('\nDatos perdidos por variable:')
print(df.isna().sum().to_string())
print('\nDescriptivos básicos:')
print(df.describe().round(3).to_string())

print('\nEtiquetas de variables:')
for c in df.columns:
    print(c, '->', meta.column_names_to_labels.get(c))

```

```
Archivo usado: /content/Tarea2/data/Med_Mod.sav
Número de observaciones: 200
Número de variables: 5
Dimensión de la base: (200, 5)
Datos perdidos totales: 0

Datos perdidos por variable:
ID              0
Pres_Comp       0
Cult_Tol_Frac   0
Con_Inn_Emple   0
Des_Inn_Empre   0

Descriptivos básicos:
            ID  Pres_Comp  Cult_Tol_Frac  Con_Inn_Emple  Des_Inn_Empre
count  200.000    200.000        200.000        200.000        200.000
mean   100.500      4.576          2.785          9.595          9.639
std     57.879      1.079          0.758          3.406          2.983
min      1.000      2.129          1.054          3.000          4.113
25%     50.750      3.853          2.200          7.000          7.714
50%    100.500      4.541          2.892          9.000          9.304
75%    150.250      5.328          3.451         12.000         11.445
max    200.000      7.778          4.543         21.000         21.066

Etiquetas de variables:
ID -> None
Pres_Comp -> Presión Competitiva del Mercado
Cult_Tol_Frac -> Cultura de Tolerancia al Fracaso
Con_Inn_Emple -> Conducta Innovadora del Empleado
Des_Inn_Empre -> Desempeño Innovador de la Empresa
```

1.b) Evaluación de las hipótesis: preparación de variables

Se centran X y W en sus medias. Esto no cambia el ajuste ni el término de interacción, pero hace que los efectos principales se interpreten cuando la otra variable está en su media y reduce colinealidad no esencial.

```python
# Definición de variables del modelo.
# X: presión competitiva; W: tolerancia al fracaso; M: conducta innovadora; Y: desempeño innovador.
X, W, M, Y = 'Pres_Comp', 'Cult_Tol_Frac', 'Con_Inn_Emple', 'Des_Inn_Empre'

# Se centran X y W para interpretar los efectos principales en el nivel promedio del moderador.
# La interacción XW representa el término de moderación del primer tramo X -> M.
df['Xc'] = df[X] - df[X].mean()
df['Wc'] = df[W] - df[W].mean()
df['XW'] = df['Xc'] * df['Wc']

print(df[[X, W, 'Xc', 'Wc', 'XW']].head().round(3).to_string(index=False))

```

```
Pres_Comp  Cult_Tol_Frac    Xc     Wc     XW
    5.745          3.358 1.169  0.573  0.669
    4.793          3.561 0.217  0.776  0.168
    5.972          4.083 1.396  1.298  1.811
    7.285          4.054 2.709  1.269  3.436
    4.649          1.622 0.073 -1.163 -0.085
```

1.b) Evaluación de las hipótesis: estimación de las tres ecuaciones

Se estiman las tres ecuaciones del planteamiento: (1) la del mediador, donde el coeficiente de XW —definido como $X_c W_c$— evalúa si el efecto de presión competitiva cambia según la tolerancia al fracaso; (2) la del resultado, que incorpora simultáneamente presión competitiva y conducta innovadora; y (3) la del efecto total, reportada como referencia descriptiva de la asociación global. Las dos primeras forman el sistema del modelo 7; la tercera no modifica el modelo, sino que documenta el efecto total antes de descomponerlo en directo e indirecto.

Se utilizan errores estándar robustos HC3. En cada tabla se interpretan el coeficiente, su error estándar, el estadístico de contraste y el p-value.

```python
# Especificación equivalente al modelo 7 de Hayes, estimada en Python con regresiones OLS.
# 1) Modelo del mediador: evalúa X -> M y la interacción XW.
# 2) Modelo del resultado: evalúa M -> Y controlando X.
# 3) Modelo total: evalúa el efecto total X -> Y antes de introducir el mediador.
modelo_M = smf.ols(f'{M} ~ Xc + Wc + XW', df).fit(cov_type='HC3')
modelo_Y = smf.ols(f'{Y} ~ Xc + {M}', df).fit(cov_type='HC3')
modelo_total = smf.ols(f'{Y} ~ Xc', df).fit(cov_type='HC3')

print('MODELO DEL MEDIADOR\n', modelo_M.summary().as_text())
print('\nMODELO DEL RESULTADO\n', modelo_Y.summary().as_text())
print('\nEFECTO TOTAL\n', modelo_total.summary().as_text())

# Tabla resumida de los coeficientes clave para leer directamente las hipótesis H1 y H5.
coeficientes_M = pd.DataFrame({
    'Coeficiente': modelo_M.params,
    'Error estándar HC3': modelo_M.bse,
    'Estadístico z': modelo_M.tvalues,
    'p-value': modelo_M.pvalues
})
print('\nCOEFICIENTES CENTRALES DEL MODELO DEL MEDIADOR')
print(coeficientes_M.loc[['Xc', 'Wc', 'XW']].round(4).to_string())

# El 0.5248 sale del coeficiente de XW: es cuánto cambia el efecto de X -> M
# cuando la tolerancia al fracaso aumenta una unidad.
print('\nEcuación estimada del mediador:')
p_ = modelo_M.params
print(f'M_hat = {p_["Intercept"]:.4f} + {p_["Xc"]:.4f}·Xc + {p_["Wc"]:.4f}·Wc + {p_["XW"]:.4f}·(Xc×Wc)')

```

```
MODELO DEL MEDIADOR
                            OLS Regression Results
==============================================================================
Dep. Variable:          Con_Inn_Emple   R-squared:                       0.981
Model:                            OLS   Adj. R-squared:                  0.980
Method:                 Least Squares   F-statistic:                     2625.
Date:                Thu, 16 Jul 2026   Prob (F-statistic):          6.32e-158
Time:                        18:28:23   Log-Likelihood:                -134.43
No. Observations:                 200   AIC:                             276.9
Df Residuals:                     196   BIC:                             290.0
Df Model:                           3
Covariance Type:                  HC3
==============================================================================
                 coef    std err          z      P>|z|      [0.025      0.975]
------------------------------------------------------------------------------
Intercept      9.5207      0.034    277.010      0.000       9.453       9.588
Xc             2.0008      0.039     50.823      0.000       1.924       2.078
Wc             2.8732      0.047     61.140      0.000       2.781       2.965
XW             0.5248      0.039     13.475      0.000       0.449       0.601
==============================================================================
Omnibus:                       11.982   Durbin-Watson:                   1.739
Prob(Omnibus):                  0.003   Jarque-Bera (JB):               14.307
Skew:                           0.458   Prob(JB):                     0.000782
```

```
Kurtosis:                       3.938   Cond. No.                         1.53
==============================================================================

Notes:
[1] Standard Errors are heteroscedasticity robust (HC3)

MODELO DEL RESULTADO
                            OLS Regression Results
==============================================================================
Dep. Variable:          Des_Inn_Empre   R-squared:                       0.973
Model:                            OLS   Adj. R-squared:                  0.973
Method:                 Least Squares   F-statistic:                     2153.
Date:                Thu, 16 Jul 2026   Prob (F-statistic):          1.38e-134
Time:                        18:28:23   Log-Likelihood:                -140.05
No. Observations:                 200   AIC:                             286.1
Df Residuals:                     197   BIC:                             296.0
Df Model:                           2
Covariance Type:                  HC3
==================================================================================
                     coef    std err          z      P>|z|      [0.025      0.975]
----------------------------------------------------------------------------------
Intercept         1.4086      0.156      9.006      0.000       1.102       1.715
Xc                0.0265      0.049      0.538      0.590      -0.070       0.123
Con_Inn_Emple     0.8577      0.017     51.267      0.000       0.825       0.891
==============================================================================
Omnibus:                        3.405   Durbin-Watson:                   1.866
Prob(Omnibus):                  0.182   Jarque-Bera (JB):                2.985
Skew:                           0.259   Prob(JB):                        0.225
Kurtosis:                       3.301   Cond. No.                         45.5
==============================================================================

Notes:
[1] Standard Errors are heteroscedasticity robust (HC3)
```

```
# R2 con cuatro decimales, reportados en el documento (Tablas 2 y 3).
print(f'R2 modelo del mediador  = {modelo_M.rsquared:.4f}')
print(f'R2 modelo del resultado = {modelo_Y.rsquared:.4f}')
print(f'R2 modelo total         = {modelo_total.rsquared:.4f}')
```

```
R2 modelo del mediador  = 0.9805
R2 modelo del resultado = 0.9732
R2 modelo total         = 0.5380
```

Estadístico de comparación y sustitución de los contrastes

Con errores estándar robustos HC3, `statsmodels` reporta estadísticos z asintóticos en los resúmenes utilizados aquí. Por ello, el estadístico de comparación bilateral al 95% de confianza se obtiene desde la distribución normal estándar. La regla de decisión es: se rechaza H_0 si $|z| > z_c$, equivalente a $p < 0.05$.

A modo de ilustración, para la interacción (H5) el estadístico se calcula como el coeficiente dividido por su error estándar robusto:

$$z = \frac{a_3}{EE(a_3)} = \frac{0.5248}{0.0389} = 13.48.$$

Como $13.48 > z_c$ y $p < 0.001$, se rechaza $H_0 : a_3 = 0$: existe moderación. La misma regla aplica a cada coeficiente de las tres ecuaciones. La celda siguiente calcula el valor crítico y los efectos condicionales que luego alimentan los efectos indirectos: cada una se obtiene reemplazando en $a(W) = a_1 + a_3 W$ con $DE(W) = 0.7583$.

```
# Estadístico de comparación (95%, bilateral) y efectos condicionales de X sobre M.
# Statsmodels reporta z en los resúmenes robustos HC3 usados aquí.
zc = stats.norm.ppf(.975)
z_a3 = modelo_M.params['XW'] / modelo_M.bse['XW']
print(f'z crítico bilateral (95%) = ±{zc:.4f}')
print(f'z interacción = {modelo_M.params["XW"]:.4f}/{modelo_M.bse["XW"]:.4f} = {z_a3:.4f} -> se rechaza H0: a3=0'

sdW = df['Wc'].std(ddof=1)
print(f'\nDE(W) = {sdW:.4f}')
print(f'a(baja)  = a1 + a3*(-DE) = {modelo_M.params["Xc"] - modelo_M.params["XW"]*sdW:.4f}')
print(f'a(media) = a1            = {modelo_M.params["Xc"]:.4f}')
print(f'a(alta)  = a1 + a3*(+DE) = {modelo_M.params["Xc"] + modelo_M.params["XW"]*sdW:.4f}')

```

```
z crítico bilateral (95%) = ±1.9600
z interacción = 0.5248/0.0389 = 13.4753 -> se rechaza H0: a3=0

DE(W) = 0.7583
a(baja)  = a1 + a3*(-DE) = 1.6029
a(media) = a1            = 2.0008
a(alta)  = a1 + a3*(+DE) = 2.3988
```

```
# Figura de moderación: efecto condicional de presión competitiva sobre conducta innovadora
# para tolerancia baja (-1 DE), media y alta (+1 DE).
import matplotlib
matplotlib.use('Agg')
import matplotlib.pyplot as plt
```

```python
from pathlib import Path
ASSETS_DIR = Path('../assets')
ASSETS_DIR.mkdir(parents=True, exist_ok=True)

x_min = df['Pres_Comp'].min()
x_max = df['Pres_Comp'].max()
x_grid = np.linspace(x_min, x_max, 100)
x_c_grid = x_grid - df['Pres_Comp'].mean()

w_mean = df['Cult_Tol_Frac'].mean()
w_sd = df['Cult_Tol_Frac'].std(ddof=1)
niveles = [
    ('Bajo (-1 DE)', w_mean - w_sd, '#1f77b4'),
    ('Medio (media)', w_mean, '#ff7f0e'),
    ('Alto (+1 DE)', w_mean + w_sd, '#2ca02c'),
]

fig, ax = plt.subplots(figsize=(9, 5.4))
for etiqueta, w_val, color in niveles:
    w_c = w_val - w_mean
    pred = (modelo_M.params['Intercept'] +
            modelo_M.params['Xc'] * x_c_grid +
            modelo_M.params['Wc'] * w_c +
            modelo_M.params['XW'] * x_c_grid * w_c)
    ax.plot(x_grid, pred, linewidth=2.5, label=etiqueta, color=color)

ax.set_title('Moderación de la cultura de tolerancia al fracaso')
ax.set_xlabel('Presión competitiva del mercado')
ax.set_ylabel('Conducta innovadora predicha')
ax.legend(title='Nivel de tolerancia')
ax.grid(alpha=.25)
fig.tight_layout()
fig.savefig(ASSETS_DIR / 'p1_moderacion_tolerancia.png', dpi=200, bbox_inches='tight')
plt.close(fig)
print(f'Figura guardada: {ASSETS_DIR / 'p1_moderacion_tolerancia.png'}')
```

```
Figura guardada: ../assets/p1_moderacion_tolerancia.png
```

```python
from IPython.display import Image, display
display(Image('../assets/p1_moderacion_tolerancia.png'))
```

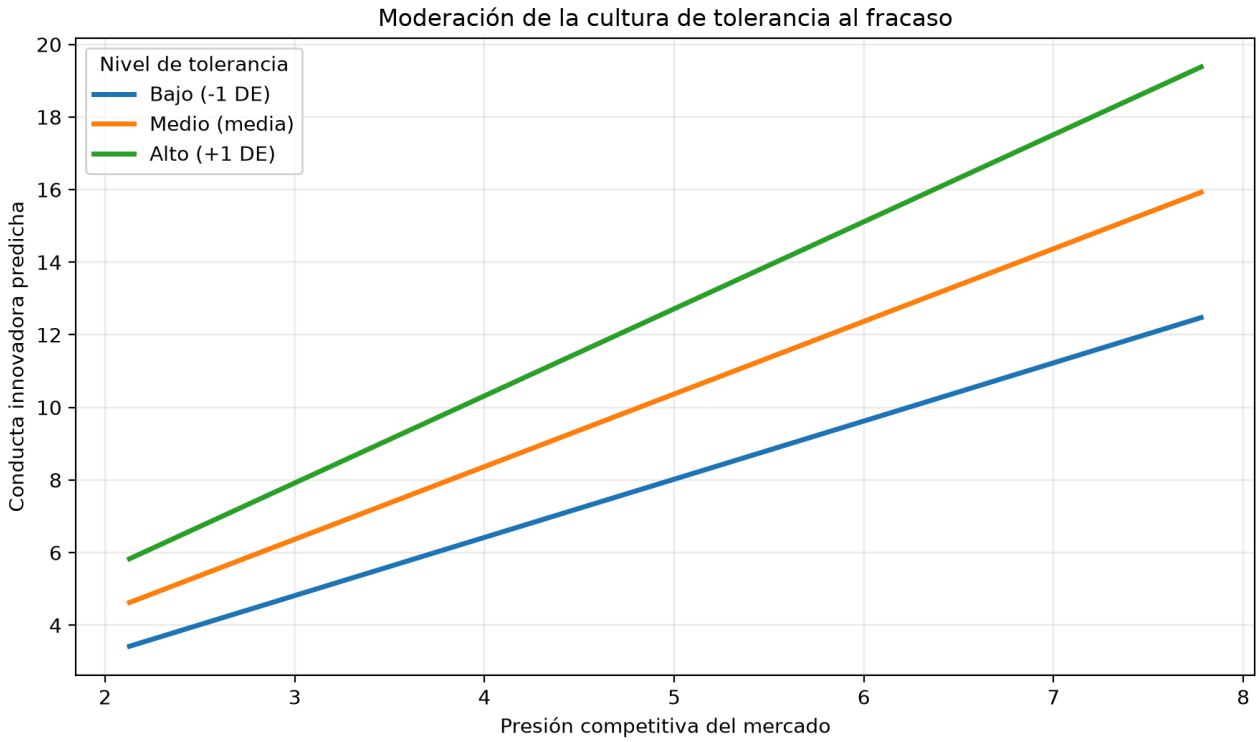

Relación entre las tres ecuaciones: por qué $c \neq c' + a_1 b$ en el modelo 7

En el modelo 4 (mediación simple) se cumple exactamente la descomposición $c = c' + ab$. En el modelo 7 esa identidad **no se cumple con** a_1, porque a_1 es el efecto de X sobre M condicional a W y a la interacción, mientras que la ecuación del efecto total omite a W. La identidad OLS exacta que sí se cumple es $c = c' + b\,\tilde{a_1}$, donde $\tilde{a_1}$ proviene de la regresión simple $M \sim X$. La brecha entre $\tilde{a_1}$ y a_1 se

explica por la correlación entre X y W. Además, el efecto total implicado por el sistema es condicional: $c(W) = c' + (a_1 + a_3 W)b$. Por eso la evidencia formal de mediación no descansa en c, sino en los efectos indirectos condicionales y su bootstrap.

```
# Verificación numérica de la descomposición del efecto total.
modelo_M_simple = smf.ols(f'{M} ~ Xc', df).fit()   # M ~ X sin W ni XW
a1s = modelo_M_simple.params['Xc']
c_  = modelo_total.params['Xc']
cp_ = modelo_Y.params['Xc']
b_  = modelo_Y.params[M]
a1_ = modelo_M.params['Xc']; a3_ = modelo_M.params['XW']

print(f'c (efecto total)                   = {c_:.4f}')
print(f"c' + a1*b (descomposición modelo 4) = {cp_ + a1_*b_:.4f}  -> NO coincide")
print(f'a1_simple (M ~ X)                  = {a1s:.4f}')
print(f"c' + b*a1_simple (identidad OLS)    = {cp_ + b_*a1s:.4f}  -> coincide exactamente")
print(f'corr(Xc,Wc) = {df.Xc.corr(df.Wc):.4f}  (explica la brecha entre a1 y a1_simple)')
print(f"Efecto total condicional c(W) = c' + (a1+a3*W)*b en W medio: {cp_ + a1_*b_:.4f}")
```

```
c (efecto total)                   = 2.0281
c' + a1*b (descomposición modelo 4) = 1.7427  -> NO coincide
a1_simple (M ~ X)                  = 2.3336
c' + b*a1_simple (identidad OLS)    = 2.0281  -> coincide exactamente
corr(Xc,Wc) = 0.1739  (explica la brecha entre a1 y a1_simple)
Efecto total condicional c(W) = c' + (a1+a3*W)*b en W medio: 1.7427
```

1.b) Evaluación de las hipótesis: efectos indirectos condicionales y bootstrap

Con los coeficientes estimados se calcula el efecto indirecto condicional: $(a_1 + a_3 W)b$. Este efecto se evalúa en tres niveles de tolerancia al fracaso: baja ($-1DE$), media y alta ($+1DE$).

El bootstrap de 5.000 remuestras se usa porque el producto de coeficientes no necesariamente sigue una distribución normal; esta cantidad sigue una práctica habitual en aplicaciones tipo PROCESS. La regla de decisión es: si el intervalo de confianza al 95% no contiene cero, el efecto indirecto se interpreta como significativo. El índice de mediación moderada se calcula como $a_3 b$ y resume cuánto cambia el efecto indirecto cuando aumenta la tolerancia al fracaso.

```
# Coeficientes necesarios para el efecto indirecto condicional.
# a1: efecto de X sobre M cuando W está en su media.
# a3: interacción XW; indica cómo cambia a1 según W.
# b: efecto de M sobre Y controlando X.
a1 = modelo_M.params['Xc']
a3 = modelo_M.params['XW']
b = modelo_Y.params[M]

sw = df['Wc'].std(ddof=1)
niveles = {'Baja (-1 DE)': -sw, 'Media': 0, 'Alta (+1 DE)': sw}

# Bootstrap: se remuestrean filas completas para conservar la estructura conjunta de X, W, M e Y.
rng = np.random.default_rng(20260706)
boot = []
for _ in range(5000):
    d = df.iloc[rng.integers(0, len(df), len(df))]
    mm = smf.ols(f'{M} ~ Xc + Wc + XW', d).fit()
    my = smf.ols(f'{Y} ~ Xc + {M}', d).fit()
    boot.append((mm.params['Xc'], mm.params['XW'], my.params[M]))
boot = np.asarray(boot)

filas = []
for nombre, w in niveles.items():
    vals = (boot[:, 0] + boot[:, 1] * w) * boot[:, 2]
    filas.append([nombre, a1 + a3 * w, (a1 + a3 * w) * b, *np.quantile(vals, [.025, .975])])

tabla = pd.DataFrame(filas, columns=['Tolerancia', 'Efecto X→M', 'Indirecto', 'IC95% inferior', 'IC95% superior']
indice = a3 * b
ici = np.quantile(boot[:, 1] * boot[:, 2], [.025, .975])

print(tabla.round(4).to_string(index=False))
print(f'\nÍndice de mediación moderada = {indice:.4f}; IC95% bootstrap [{ici[0]:.4f}, {ici[1]:.4f}]')

```

```
  Tolerancia  Efecto X→M  Indirecto  IC95% inferior  IC95% superior
Baja (-1 DE)      1.6029     1.3748          1.2880          1.4620
      Media      2.0008     1.7162          1.6227          1.8104
Alta (+1 DE)      2.3988     2.0576          1.9319          2.1853

Índice de mediación moderada = 0.4502; IC95% bootstrap [0.3758, 0.5184]
```

1.b) Evaluación de las hipótesis: diagnósticos del modelo

Se revisa multicolinealidad mediante VIF y heterocedasticidad con Breusch--Pagan. Los VIF permiten verificar que el centrado redujo colinealidad no esencial entre X, W y la interacción. Además, las regresiones principales usan errores estándar robustos HC3, por lo que

las conclusiones son más seguras frente a heterocedasticidad.

```
from statsmodels.stats.outliers_influence import variance_inflation_factor
from statsmodels.stats.diagnostic import het_breuschpagan

# VIF bajo indica que la interacción centrada no genera multicolinealidad problemática.
vif = pd.DataFrame({
    'Variable': modelo_M.model.exog_names,
    'VIF': [variance_inflation_factor(modelo_M.model.exog, i) for i in range(modelo_M.model.exog.shape[1])]
})

# Breusch--Pagan revisa heterocedasticidad; la inferencia principal ya usa HC3.
bp = het_breuschpagan(modelo_M.resid, modelo_M.model.exog)
print(vif.round(3).to_string(index=False))
print(f'\nBreusch-Pagan: LM={bp[0]:.4f}, p={bp[1]:.4g}')
```

```
 Variable   VIF
Intercept 1.027
       Xc 1.036
       Wc 1.046
       XW 1.016

Breusch-Pagan: LM=1.1407, p=0.7673
```

1.c) Interpretación de los resultados

La respuesta directa es que el modelo propuesto recibe apoyo empírico. La presión competitiva del mercado se relaciona positivamente con el desempeño innovador de la empresa, pero esa relación opera principalmente a través de la conducta innovadora del empleado. Además, la cultura de tolerancia al fracaso fortalece este proceso.

Respuesta directa a las hipótesis

Hipótesis	Relación evaluada	Evidencia principal	Decisión
H1	Presión competitiva $\rightarrow$ conducta innovadora	$a_1 = 2.0008$, $p < 0.001$	Apoyada
H2	Conducta innovadora $\rightarrow$ desempeño innovador	$b = 0.8577$, $p < 0.001$	Apoyada
H3	Efecto directo presión competitiva $\rightarrow$ desempeño	$c' = 0.0265$, $p = 0.590$	No apoyada
H4	Efecto indirecto vía conducta innovadora	IC95% bootstrap sin cero	Apoyada
H5	Moderación de tolerancia al fracaso sobre $X \rightarrow M$	$a_3 = 0.5248$, $p < 0.001$	Apoyada

En conjunto, los resultados apoyan H1, H2, H4 y H5. El efecto directo planteado en H3 no recibe apoyo empírico, por lo que la evidencia es consistente con una mediación *indirect-only*. El efecto total, reportado como referencia, es positivo y significativo ($c = 2.0281$, $p < 0.001$). Junto con el efecto directo no significativo y los indirectos significativos en todos los niveles del moderador, el patrón indica que el vínculo entre presión competitiva y desempeño innovador opera a través de la conducta innovadora del empleado.

En términos sustantivos, la presión competitiva no mejora el desempeño innovador simplemente por existir. Su efecto aparece cuando los empleados responden proponiendo e implementando ideas nuevas. Esa respuesta es más fuerte en empresas donde la gerencia tolera el fracaso asociado a experimentar.