

Tarea_2_P2_Analisis_Factorial.ipynb

Exportado desde el notebook ejecutado del repositorio. Incluye enunciado, código, outputs de texto e imágenes guardadas.

Celda 1 - Markdown

Pregunta 2 — Análisis factorial exploratorio

Métodos Cuantitativos de la Investigación en Negocios — Tarea 2 (2026)

Celda 2 - Código ejecutado #1

```
# Instalación condicional de dependencias para Google Colab.
# En ejecución local no instala nada si los paquetes ya están disponibles.
import importlib, subprocess, sys

def instalar_si_falta(import_name, package_name=None):
    package_name = package_name or import_name
    try:
        importlib.import_module(import_name)
    except ImportError:
        print(f'Instalando {package_name}...')
        subprocess.check_call([sys.executable, '-m', 'pip', 'install', '-q', package_name])

instalar_si_falta('pyreadstat', 'pyreadstat')
instalar_si_falta('factor_analyzer', 'factor-analyzer')

print('Dependencias verificadas y entorno inicial preparado.')
```

OUTPUT:

Dependencias verificadas y entorno inicial preparado.

Celda 3 - Markdown

Enunciado de la pregunta 2

2. La Universidad de Desarrollo está permanentemente tratando de tener los mejores profesores entre sus filas. Como parte de este esfuerzo, la UDD realizó un esfuerzo por analizar el cuestionario basado en la teoría de Blend asociada a los profesores de métodos de investigación. Esta teoría predice que los buenos profesores de métodos cuantitativos poseen cuatro características fundamentales: (1) gran amor por las estadísticas, (2) entusiasmo por el diseño de experimentos, (3) amor por la enseñanza, y (4) una completa ausencia de habilidades interpersonales normales. Estas características pueden estar correlacionadas entre ellas.

El cuestionario “Enseñanza de Experimentos para las Ciencias Sociales” (EECS) ya existe, pero la universidad mejoró este cuestionario y se convirtió en el EECS-R (“Enseñanza de Experimentos para las Ciencias Sociales - Revisado”). Este cuestionario revisado fue enviado y contestado satisfactoriamente por 239 profesores de métodos de investigación alrededor del mundo para evaluar si la teoría de Blend es correcta.

El cuestionario (preguntas, escala y respuestas) se encuentra en el archivo EECS-R.sav. Realice un Análisis Factorial Exploratorio y determine si se cumple la teoría de Blend.

Respuesta

La pregunta se resuelve verificando primero si los datos son adecuados para análisis factorial, determinando cuántos factores retener, interpretando las cargas factoriales y evaluando si la estructura empírica coincide con las cuatro dimensiones propuestas por la teoría de Blend.

Celda 4 - Código ejecutado #3

```
from pathlib import Path
from urllib.request import urlretrieve, urlopen
import ssl
import warnings
warnings.filterwarnings('ignore')

import numpy as np
import pandas as pd
import pyreadstat
from scipy import stats
import statsmodels.api as sm
import statsmodels.formula.api as smf
```

```

pd.set_option('display.max_columns', 100)
pd.set_option('display.width', 160)

# Base requerida para este notebook.
# Funciona localmente y también en Google Colab abierto desde GitHub.
REQUIRED_DATA_FILE = 'EECS-R.sav'
RAW_DATA_BASE = 'https://raw.githubusercontent.com/sebabecerra/Metodos-Cuantitativos-DEN/main/Tarea2/data'

def encontrar_o_descargar_base(filename):
    candidatas = [
        Path.cwd() / 'data',          # ejecución desde Tarea2
        Path.cwd().parent / 'data',    # ejecución desde Tarea2/notebooks
        Path.cwd() / 'Tarea2' / 'data', # ejecución desde raíz del repo o Colab
        Path.cwd()                    # respaldo: base junto al notebook
    ]
    for ruta in candidatas:
        if (ruta / filename).exists():
            return ruta

    # Si Colab no tiene la carpeta del repo clonada, se descarga la base desde GitHub.
    destino_dir = Path.cwd() / 'Tarea2' / 'data'
    destino_dir.mkdir(parents=True, exist_ok=True)
    destino = destino_dir / filename
    url = f'{RAW_DATA_BASE}/{filename}'
    print(f'Base {filename} no encontrada localmente. Descargando desde GitHub...')
    try:
        urlretrieve(url, destino)
    except Exception as error:
        # Respaldo útil en algunos entornos locales con problemas de certificados SSL.
        # En Colab normalmente no se activa, pero evita fallas si Python no encuentra certificados.
        print('Descarga estándar falló; intentando respaldo SSL...')
        contexto = ssl._create_unverified_context()
        with urlopen(url, context=contexto) as respuesta, open(destino, 'wb') as archivo:
            archivo.write(respuesta.read())
    return destino_dir

DATA_DIR = encontrar_o_descargar_base(REQUIRED_DATA_FILE)
print('Directorio de datos:', DATA_DIR)
print('Base usada:', DATA_DIR / REQUIRED_DATA_FILE)

```

OUTPUT:

```

Directorio de datos: /Users/sbc/projects/Metodos-Cuantitativos-DEN/Tarea2/data
Base usada: /Users/sbc/projects/Metodos-Cuantitativos-DEN/Tarea2/data/EECS-R.sav

```

Celda 5 - Markdown**1. Objetivo y decisiones analíticas**

Se evalúa si los 28 ítems del EECS-R reproducen cuatro dimensiones correlacionadas propuestas por la teoría de Blend: amor por la estadística, entusiasmo por el diseño experimental, amor por la enseñanza y ausencia de habilidades interpersonales.

Se usa análisis factorial exploratorio de factores comunes, extracción de máxima verosimilitud y rotación oblicua Oblimin, porque las dimensiones pueden correlacionarse. Los datos perdidos —solo nueve respuestas— se imputan con la mediana del ítem.

Celda 6 - Código ejecutado #3

```

from factor_analyzer import FactorAnalyzer
from factor_analyzer.factor_analyzer import calculate_bartlett_sphericity, calculate_kmo
import inspect
import sklearn.utils.validation as sk_validation
import factor_analyzer.factor_analyzer as fa_module

# Compatibilidad: algunas versiones nuevas de scikit-learn reemplazan
# force_all_finite por ensure_all_finite. factor_analyzer todavía usa
# force_all_finite en ciertos entornos, por eso se traduce el argumento.
_original_check_array = sk_validation.check_array
def _check_array_compat(*args, **kwargs):
    if (
        'force_all_finite' in kwargs
        and 'force_all_finite' not in inspect.signature(_original_check_array).parameters
    ):
        kwargs['ensure_all_finite'] = kwargs.pop('force_all_finite')
    return _original_check_array(*args, **kwargs)

```

```

fa_module.check_array = _check_array_compat

# Chequeo inicial de la base.
# Se carga la base completa; no se filtran observaciones ni se toma una submuestra.
df, meta = pyreadstat.read_sav(DATA_DIR/'EECS-R.sav', apply_value_formats=False)
items = [f'q{i}' for i in range(1, 29)]
X = df[items].copy()

print('Archivo usado:', DATA_DIR/'EECS-R.sav')
print('Número de observaciones:', len(df))
print('Número de ítems analizados:', len(items))
print('Dimensión de la matriz de ítems:', X.shape)
faltantes = int(X.isna().sum().sum())
print('Datos perdidos totales en los ítems:', faltantes)
print(f'Porcentaje de datos perdidos: {100 * faltantes / X.size:.3f}%')
print('\nDatos perdidos por ítem:')
print(X.isna().sum().to_string())
print('\nDescriptivos básicos de los ítems:')
print(X.describe().T[['mean', 'std', 'min', 'max']].round(3).to_string())
print('\nEtiquetas de ítems:')
for c in items:
    print(f'{c}: {meta.column_names_to_labels[c]}')

# Imputación por mediana debido a la baja proporción de datos perdidos.
X = X.apply(lambda s: s.fillna(s.median()))
print('\nDatos perdidos después de imputar por mediana:', int(X.isna().sum().sum()))

```

OUTPUT:

```

Archivo usado: /Users/sbc/projects/Metodos-Cuantitativos-DEN/Tarea2/data/EECS-R.sav
Número de observaciones: 239
Número de ítems analizados: 28
Dimensión de la matriz de ítems: (239, 28)
Datos perdidos totales en los ítems: 9
Porcentaje de datos perdidos: 0.134%

```

Datos perdidos por ítem:

```

q1      0
q2      1
q3      1
q4      0
q5      0
q6      0
q7      0
q8      0
q9      0
q10     0
q11     1
q12     2
q13     0
q14     0
q15     1
q16     0
q17     0
q18     1
q19     1
q20     0
q21     1
q22     0
q23     0
q24     0
q25     0
q26     0
q27     0
q28     0

```

Descriptivos básicos de los ítems:

	mean	std	min	max
q1	4.720	1.412	1.0	7.0
q2	4.782	1.391	1.0	7.0
q3	4.929	1.158	1.0	7.0
q4	4.791	1.243	1.0	7.0
q5	3.406	1.315	1.0	7.0
q6	5.276	1.387	1.0	7.0
q7	4.987	1.102	1.0	7.0

```

q8  5.213  1.277  1.0  7.0
q9  5.314  1.249  1.0  7.0
q10 4.444  1.454  1.0  7.0
q11 4.080  1.545  1.0  7.0
q12 3.865  1.423  1.0  7.0
q13 5.431  1.304  2.0  7.0
q14 4.895  1.575  1.0  7.0
q15 4.639  1.773  1.0  7.0
q16 4.619  1.757  1.0  7.0
q17 5.456  1.256  1.0  7.0
q18 3.958  1.411  1.0  7.0
q19 4.748  1.376  1.0  7.0
q20 4.950  1.259  1.0  7.0
q21 5.408  1.242  1.0  7.0
q22 5.368  1.331  1.0  7.0
q23 3.707  1.437  1.0  7.0
q24 4.820  1.308  1.0  7.0
q25 4.866  1.375  1.0  7.0
q26 4.895  1.406  1.0  7.0
q27 4.067  1.333  1.0  7.0
q28 4.088  1.448  1.0  7.0

```

Etiquetas de ítems:

```

q1: Una vez me desperté en un campo de vegetales abrazando un nabo el que erronaemente extraje pensando que era
la Mayor Raiz de Roy
q2: Si tuviese una pistola grande le dispararía a todos los estudiantes a los que tengo que enseñarles
q3: Me gusta memorizar valores de la distribucion F
q4: Le tengo un altar a Pearson en mi oficina
q5: Todavía vivo con mi madre y tengo poca preocupacion por mi higiene personal
q6: Enseñarle a otros me hace desear el tragar una botella de cloro porque, comparativamente, el dolor en mi
esófago ardiente sería un gran alivio
q7: Ayudarle a otros a entender la suma de cuadrados me provoca gran emocion
q8: Me gustan las condiciones de control
q9: Calculo 3 ANOVAs mentalmente antes de levantarme cada mañana
q10: Podría pasar todo el día explicandole estadísticas a las personas
q11: Me encanta cuando la gente me dice que les ayudé a entender la rotación de factores
q12: La gente se queda dormida apenas abro la boca para hablar
q13: Diseñar experimentos es entretenido
q14: Prefiero pensar en variables dependientes apropiadas en vez de ir a un pub
q15: Mi corazon se acelera considerablemente con la sola mencion del Análisis Factorial
q16: Pensar en si usar medidas independientes o repetitivas me encanta
q17: Me encanta sentarme en el parque para pensar si usaré observacion de participantes en mi próximo
experimento
q18: Pararme frente a 300 personas de ninguna forma me malestar estomacal
q19: Me gusta ayudar a los estudiantes
q20: Entregar conocimiento es el mayor don que se le puede conceder a un individuo
q21: Pensar en la corrección de Bonferroni me provoca un hormigueo en la ingle
q22: Tiemblo de emocion al pensar en diseñar mi proximo experimento
q23: Frecuentemente ocupo mi tiempo libre hablandole a los ratones del laboratorio... e incluso ellos se mueren
de aburrimiento
q24: Traté de construir una máquina del tiempo para poder volver a los años 1930s y seguir a Fisher de rodillas
besando el suelo que haya pisado
q25: Amo enseñar
q26: Ocupo gran parte del tiempo ayudando a los estudiantes
q27: Me encanta enseñar porque los estudiantes tienen que fingir que les agrado o recibirán malas notas
q28: Mi gato es mi unico amigo

```

Datos perdidos después de imputar por mediana: 0

Celda 7 - Markdown

2. Factorabilidad: Bartlett y KMO

Bartlett contrasta que la matriz de correlaciones sea identidad. Se requiere $p < 0.05$. KMO cuantifica varianza común; valores superiores a 0.80.

La prueba se calcula como $\chi^2 = -(n-1) \frac{2p+5}{6} \ln|R|$, con $gl = p(p-1)/2$, donde n es el número de casos, p el número de ítems y $|R|$ el determinante de la matriz de correlaciones. La regla de decisión es: se rechaza H_0 (matriz identidad) si el estadístico supera el valor crítico $\chi^2_{\{0.95, gl\}}$, equivalente a $p < 0.05$.

Celda 8 -Codigo ejecutado #7

```

chi,p=calculate_bartlett_sphericity(X); _,kmo=calculate_kmo(X)
print(f'Bartlett: chi-cuadrado={chi:.4f}, gl={28*27//2}, ' + ('p como {chi:.2f} > {stats.chi2.ppf(.95,378):.2f},

```

se rechaza H_0 ')

OUTPUT:

Bartlett: chi-cuadrado=3045.3894, gl=378, p como 3045.39 > 424.33, se rechaza H_0

Celda 9 - Markdown

3. Número de factores

Para decidir cuántos factores retener se combinan tres criterios:

1. Autovalores observados: indican cuánta varianza explica cada dimensión inicial.
2. Gráfico de sedimentación: muestra los autovalores ordenados de mayor a menor; se observa el punto donde la curva comienza a aplanarse, porque desde ahí los factores adicionales aportan poca información nueva.
3. Análisis paralelo: compara los autovalores observados con los que aparecerían por azar en matrices aleatorias del mismo tamaño.

El análisis paralelo es especialmente importante porque el criterio de autovalor mayor que 1 puede sugerir más factores de los realmente respaldados por los datos. En esta aplicación, el cuarto factor queda muy cerca del percentil 95 aleatorio. El valor 1.501 corresponde al percentil 95 del cuarto autovalor obtenido en las 1.000 matrices aleatorias generadas para el análisis paralelo. Por eso se revisa también la media de autovalores aleatorios y la coherencia teórica de cuatro dimensiones.

Celda 10 - Código ejecutado #9

```
R=X.corr().to_numpy(); eig=np.linalg.eigvalsh(R)[::-1]
rng=np.random.default_rng(12345)
rand=[]
for _ in range(1000):
    Rr=np.corrcoef(rng.normal(size=X.shape),rowvar=False)
    rand.append(np.linalg.eigvalsh(Rr)[::-1])
rand=np.array(rand)
rand95=np.percentile(rand,95,axis=0)
randmean=rand.mean(axis=0)
print('Primeros 8 autovalores observados:',np.round(eig[:8],3))
print('Percentil 95 aleatorio:',np.round(rand95[:8],3))
print('Media aleatoria:',np.round(randmean[:8],3))
print('Factores retenidos por percentil 95:',int((eig>rand95).sum()))
print('Factores retenidos por media aleatoria:',int((eig>randmean).sum()))
print(f'Cuarto autovalor observado = {eig[3]:.3f}; percentil 95 aleatorio = {rand95[3]:.3f}; media aleatoria = {randmean[3]:.3f}')
```

```
import matplotlib.pyplot as plt
fig, ax = plt.subplots(figsize=(8,5))
xs=np.arange(1,len(items)+1)
ax.plot(xs,eig,marker='o',label='Autovalores observados',linewidth=2)
ax.plot(xs,rand95,marker='s',label='Percentil 95 aleatorio',linewidth=1.5)
ax.plot(xs,randmean,linestyle='--',label='Media aleatoria',linewidth=1.5)
ax.axvline(4,color='gray',linestyle=':',label='4 factores retenidos')
ax.set_xlabel('Número de factor')
ax.set_ylabel('Autovalor')
ax.set_title('Análisis paralelo y gráfico de sedimentación')
ax.set_xlim(1,12)
ax.grid(alpha=.25)
ax.legend()
plt.show()
```

OUTPUT:

```
Primeros 8 autovalores observados: [9.02  2.743 1.707 1.505 1.158 0.976 0.916 0.829]
Percentil 95 aleatorio: [1.799 1.66  1.574 1.501 1.435 1.376 1.328 1.274]
Media aleatoria: [1.694 1.59  1.511 1.445 1.385 1.331 1.281 1.232]
Factores retenidos por percentil 95: 4
Factores retenidos por media aleatoria: 4
Cuarto autovalor observado = 1.505; percentil 95 aleatorio = 1.501; media aleatoria = 1.445
```

Celda 11 - Markdown

Figura: análisis paralelo y gráfico de sedimentación. La curva observada se compara con autovalores aleatorios. La decisión de retener cuatro factores queda respaldada porque los primeros cuatro autovalores observados superan la referencia aleatoria, aunque el cuarto factor es una decisión ajustada bajo el percentil 95.

Celda 12 - Codigo ejecutado #12

```
fa=FactorAnalyzer(n_factors=4,rotation='oblimin',method='ml'); fa.fit(X)
L=pd.DataFrame(fa.loadings_,index=items,columns=['F1','F2','F3','F4'])
print(L.round(3).to_string())
print('\nVarianza por factor:')
varianza = pd.DataFrame(np.array(fa.get_factor_variance()).T,columns=['SS
cargas','Proporción','Acumulada'],index=['F1','F2','F3','F4'])
print(varianza.round(4).to_string())
print('\nCorrelaciones factoriales:')
print(pd.DataFrame(fa.ph_i_,index=L.columns,columns=L.columns).round(3).to_string())
```

OUTPUT:

	F1	F2	F3	F4
q1	0.401	-0.140	0.285	0.340
q2	0.097	-0.329	0.357	0.272
q3	0.116	0.293	-0.048	0.508
q4	0.125	0.165	0.137	0.510
q5	0.056	0.055	0.669	-0.131
q6	0.160	-0.347	0.161	0.264
q7	0.139	0.452	-0.049	0.299
q8	0.575	0.222	0.036	0.242
q9	0.437	-0.114	0.258	0.372
q10	0.417	-0.069	0.178	0.044
q11	0.266	0.457	0.200	0.102
q12	-0.011	0.133	0.269	-0.164
q13	0.560	0.082	-0.033	0.209
q14	0.757	0.028	0.179	-0.337
q15	0.361	-0.017	0.137	0.184
q16	0.741	0.215	-0.024	-0.200
q17	0.788	-0.009	-0.034	0.136
q18	0.232	-0.322	0.404	0.142
q19	-0.055	0.568	-0.177	0.078
q20	0.035	0.450	0.052	0.199
q21	0.471	0.165	-0.040	0.270
q22	0.857	-0.074	-0.021	0.113
q23	-0.094	0.042	0.700	0.066
q24	0.097	0.284	0.127	0.481
q25	0.101	0.533	0.131	0.082
q26	0.278	0.593	0.020	-0.072
q27	-0.020	0.612	0.382	0.068
q28	0.012	0.211	0.533	-0.016

Varianza por factor:

	SS cargas	Proporción	Acumulada
F1	4.3219	0.1544	0.1544
F2	2.7152	0.0970	0.2513
F3	2.1239	0.0759	0.3272
F4	1.7733	0.0633	0.3905

Correlaciones factoriales:

	F1	F2	F3	F4
F1	1.000	0.299	0.471	0.370
F2	0.299	1.000	0.130	0.129
F3	0.471	0.130	1.000	0.252
F4	0.370	0.129	0.252	1.000

Celda 13 - Markdown

5. Interpretación y confiabilidad

La solución se interpreta considerando conjuntamente contenido y cargas:

- F1: entusiasmo por diseño experimental.
- F2: amor por la enseñanza.
- F3: ausencia de habilidades interpersonales.
- F4: amor por la estadística.

Se calcula alfa con conjuntos conceptualmente coherentes. Algunos ítems presentan cargas cruzadas o débiles, por lo que la teoría se evalúa en grado, no solo contando factores.

Celda 14 - Codigo ejecutado #14

```
def alpha(d):
    k=d.shape[1]; return k/(k-1)*(1-d.var(ddof=1).sum()/d.sum(axis=1).var(ddof=1))
sets={
```

```
'Diseño experimental':['q8','q13','q14','q16','q17','q22'],
'Enseñanza':['q7','q10','q11','q19','q20','q25','q26'],
'Habilidades interpersonales deficientes':['q2','q5','q6','q12','q18','q23','q27','q28'],
'Estadística':['q1','q3','q4','q9','q15','q21','q24']}
for nombre,its in sets.items(): print(f'{nombre}: alpha={alpha(X[its]):.3f} ({len(its)} ítems)')
```

OUTPUT:

```
Diseño experimental: alpha=0.880 (6 ítems)
Enseñanza: alpha=0.747 (7 ítems)
Habilidades interpersonales deficientes: alpha=0.691 (8 ítems)
Estadística: alpha=0.830 (7 ítems)
```

Celda 15 - Codigo ejecutado #15

```
# Correlaciones ítem-total corregidas por subescala teórica.
# Verifica que ningún ítem esté invertido o mal codificado dentro de su subescala:
# una correlación ítem-total negativa indicaría necesidad de recodificación antes del alfa.
for nombre, its in sets.items():
    sub = X[its]
    print(f'\n{nombre}:')
    for it in its:
        resto = sub.drop(columns=it).sum(axis=1)
        r = sub[it].corr(resto)
        marca = ' <-- NEGATIVA' if r < 0 else ''
        print(f' {it}: r ítem-total corregida = {r:.3f}{marca}')
```

OUTPUT:

```
Diseño experimental:
q8: r ítem-total corregida = 0.714
q13: r ítem-total corregida = 0.611
q14: r ítem-total corregida = 0.634
q16: r ítem-total corregida = 0.678
q17: r ítem-total corregida = 0.767
q22: r ítem-total corregida = 0.783
```

```
Enseñanza:
q7: r ítem-total corregida = 0.476
q10: r ítem-total corregida = 0.248
q11: r ítem-total corregida = 0.538
q19: r ítem-total corregida = 0.360
q20: r ítem-total corregida = 0.505
q25: r ítem-total corregida = 0.568
q26: r ítem-total corregida = 0.583
```

```
Habilidades interpersonales deficientes:
q2: r ítem-total corregida = 0.382
q5: r ítem-total corregida = 0.486
q6: r ítem-total corregida = 0.261
q12: r ítem-total corregida = 0.170
q18: r ítem-total corregida = 0.446
q23: r ítem-total corregida = 0.566
q27: r ítem-total corregida = 0.333
q28: r ítem-total corregida = 0.424
```

```
Estadística:
q1: r ítem-total corregida = 0.636
q3: r ítem-total corregida = 0.516
q4: r ítem-total corregida = 0.539
q9: r ítem-total corregida = 0.626
q15: r ítem-total corregida = 0.529
q21: r ítem-total corregida = 0.603
q24: r ítem-total corregida = 0.647
```

Celda 16 - Markdown**6. Conclusión**

Bartlett es significativo ($\chi^2(378)=3045.39$, $p<0.001$) y KMO=0.895, por lo que la matriz es adecuada. El análisis paralelo recomienda cuatro factores tanto con el percentil 95 (cuarto autovalor 1.505 contra umbral 1.501, decisión ajustada) como con la media de los autovalores aleatorios (umbral 1.445, decisión holgada), coincidiendo con Blend y con el respaldo de la expectativa teórica a priori. La solución rotada permite reconocer las cuatro áreas teóricas, especialmente diseño experimental y estadística/enseñanza.

Sin embargo, hay cargas cruzadas (por ejemplo q1, q9 y q27) e ítems sin carga factorial relevante o

débiles (como q12), y la dimensión de habilidades interpersonales deficientes no queda completamente limpia. La teoría de Blend recibe apoyo general respecto del número y contenido de factores, pero no apoyo perfecto a nivel de todos los ítems. Se recomienda revisar o eliminar ítems ambiguos antes de una validación confirmatoria.