

✓ Pregunta 2 — Análisis factorial exploratorio

Métodos Cuantitativos de la Investigación en Negocios — Tarea 2 (2026)

```
1 # Instalación condicional de dependencias para Google Colab.
2 # En ejecución local no instala nada si los paquetes ya están dispo
3 import importlib, subprocess, sys
4
5 def instalar_si_falta(import_name, package_name=None):
6     package_name = package_name or import_name
7     try:
8         importlib.import_module(import_name)
9     except ImportError:
10         print(f'Instalando {package_name}...')
11         subprocess.check_call([sys.executable, '-m', 'pip', 'instal
12
13 instalar_si_falta('pyreadstat', 'pyreadstat')
14 instalar_si_falta('factor_analyzer', 'factor-analyzer')
15
16 print('Dependencias verificadas y entorno inicial preparado.')
17
```

Dependencias verificadas y entorno inicial preparado.

✓ Enunciado de la pregunta 2

2. La Universidad de Desarrollo está permanentemente tratando de tener los mejores profesores entre sus filas. Como parte de este esfuerzo, la UDD realizó un esfuerzo por analizar el cuestionario basado en la teoría de Blend asociada a los profesores de métodos de investigación. Esta teoría predice que los buenos profesores de métodos cuantitativos poseen cuatro características fundamentales: (1) gran amor por las estadísticas, (2) entusiasmo por el diseño de experimentos, (3) amor por la enseñanza, y (4) una completa ausencia de habilidades interpersonales normales. Estas características pueden estar correlacionadas entre ellas.

El cuestionario “Enseñanza de Experimentos para las Ciencias Sociales” (EECS) ya existe, pero la universidad mejoró este cuestionario y se convirtió en el EECS-R (“Enseñanza de Experimentos para las Ciencias Sociales - Revisado”). Este cuestionario revisado fue enviado y contestado satisfactoriamente por 239 profesores de métodos de investigación alrededor del mundo para evaluar si la teoría de Blend es correcta.

El cuestionario (preguntas, escala y respuestas) se encuentra en el archivo EECS-R.sav. Realice un Análisis Factorial Exploratorio y determine si se cumple la teoría de Blend.

Respuesta

La pregunta se resuelve verificando primero si los datos son adecuados para análisis factorial, determinando cuántos factores retener, interpretando las cargas factoriales y evaluando si la estructura empírica coincide con las cuatro dimensiones propuestas por la teoría de Blend.

```
1 from pathlib import Path
2 from urllib.request import urlretrieve, urlopen
3 import ssl
4 import warnings
5 warnings.filterwarnings('ignore')
6
7 import numpy as np
8 import pandas as pd
9 import pyreadstat
10 from scipy import stats
11 import statsmodels.api as sm
12 import statsmodels.formula.api as smf
13
14 pd.set_option('display.max_columns', 100)
15 pd.set_option('display.width', 160)
16
17 # Base requerida para este notebook.
18 # Funciona localmente y también en Google Colab abierto desde GitHub
19 REQUIRED_DATA_FILE = 'EECS-R.sav'
20 RAW_DATA_BASE = 'https://raw.githubusercontent.com/sebabecerra/Met
21
22 def encontrar_o_descargar_base(filename):
23     candidatas = [
24         Path.cwd() / 'data',                # ejecución desde Tar
25         Path.cwd().parent / 'data',         # ejecución desde Tar
26         Path.cwd() / 'Tarea2' / 'data',     # ejecución desde raíz
27         Path.cwd()                          # respaldo: base junt
28     ]
29     for ruta in candidatas:
30         if (ruta / filename).exists():
31             return ruta
32
33     # Si Colab no tiene la carpeta del repo clonada, se descarga l
34     destino_dir = Path.cwd() / 'Tarea2' / 'data'
35     destino_dir.mkdir(parents=True, exist_ok=True)
36     destino = destino_dir / filename
37     url = f'{RAW_DATA_BASE}/{filename}'
38     print(f'Base {filename} no encontrada localmente. Descargando
39     try:
40         urlretrieve(url, destino)
41     except Exception as error:
42         # Respaldo útil en algunos entornos locales con problemas
43         # En Colab normalmente no se activa, pero evita fallas si
44         print('Descarga estándar falló; intentando respaldo SSL...
45         contexto = ssl._create_unverified_context()
46         with urlopen(url, context=contexto) as respuesta, open(des
```

```

47         archivo.write(respuesta.read())
48     return destino_dir
49
50 DATA_DIR = encontrar_o_descargar_base(REQUIRED_DATA_FILE)
51 print('Directorio de datos:', DATA_DIR)
52 print('Base usada:', DATA_DIR / REQUIRED_DATA_FILE)
--

```

```

Directorio de datos: /Users/sbc/projects/Metodos-Cuantitativos-DEN/Tarea
Base usada: /Users/sbc/projects/Metodos-Cuantitativos-DEN/Tarea2/data/EE

```

✓ 1. Objetivo y decisiones analíticas

Se evalúa si los 28 ítems del EECS-R reproducen cuatro dimensiones correlacionadas propuestas por la teoría de Blend: amor por la estadística, entusiasmo por el diseño experimental, amor por la enseñanza y ausencia de habilidades interpersonales.

Se usa **análisis factorial exploratorio de factores comunes**, extracción de máxima verosimilitud y rotación oblicua Oblimin, porque las dimensiones pueden correlacionarse. Los datos perdidos —solo nueve respuestas— se imputan con la mediana del ítem.

```

1 from factor_analyzer import FactorAnalyzer
2 from factor_analyzer.factor_analyzer import calculate_bartlett_sph
3 import inspect
4 import sklearn.utils.validation as sk_validation
5 import factor_analyzer.factor_analyzer as fa_module
6
7 # Compatibilidad: algunas versiones nuevas de scikit-learn reemplaza
8 # force_all_finite por ensure_all_finite. factor_analyzer todavía
9 # force_all_finite en ciertos entornos, por eso se traduce el argu
10 _original_check_array = sk_validation.check_array
11 def _check_array_compat(*args, **kwargs):
12     if (
13         'force_all_finite' in kwargs
14         and 'force_all_finite' not in inspect.signature(_original_
15     ):
16         kwargs['ensure_all_finite'] = kwargs.pop('force_all_finite
17     return _original_check_array(*args, **kwargs)
18
19 fa_module.check_array = _check_array_compat
20
21 # Chequeo inicial de la base.
22 # Se carga la base completa; no se filtran observaciones ni se tom
23 df, meta = pyreadstat.read_sav(DATA_DIR/'EECS-R.sav', apply_value_
24 items = [f'q{i}' for i in range(1, 29)]
25 X = df[items].copy()
26
27 print('Archivo usado:', DATA_DIR/'EECS-R.sav')
28 print('Número de observaciones:', len(df))
29 print('Número de ítems analizados:', len(items))
30 print('Dimensión de la matriz de ítems:', X.shape)

```

```

31 faltantes = int(X.isna().sum().sum())
32 print('Datos perdidos totales en los ítems:', faltantes)
33 print(f'Porcentaje de datos perdidos: {100 * faltantes / X.size:.3}')
34 print('\nDatos perdidos por ítem:')
35 print(X.isna().sum().to_string())
36 print('\nDescriptivos básicos de los ítems:')
37 print(X.describe().T[['mean', 'std', 'min', 'max']].round(3).to_string())
38 print('\nEtiquetas de ítems:')
39 for c in items:
40     print(f'{c}: {meta.column_names_to_labels[c]}')
41
42 # Imputación por mediana debido a la baja proporción de datos perdidos
43 X = X.apply(lambda s: s.fillna(s.median()))
44 print('\nDatos perdidos después de imputar por mediana:', int(X.isna().sum().sum()))

```

```

q4    4.791    1.243    1.0    7.0
q5    3.406    1.315    1.0    7.0

```

```

q18: Pararme frente a 300 personas de ninguna forma me malestar estomac
q19: Me gusta ayudar a los estudiantes
q20: Entregar conocimiento es el mayor don que se le puede conceder a u
q21: Pensar en la corrección de Bonferroni me provoca un hormigueo en l
q22: Tiemblo de emoción al pensar en diseñar mi próximo experimento
q23: Frecuentemente ocupo mi tiempo libre hablandole a los ratones del
q24: Traté de construir una máquina del tiempo para poder volver a los
q25: Amo enseñar
q26: Ocupo gran parte del tiempo ayudando a los estudiantes
q27: Me encanta enseñar porque los estudiantes tienen que fingir que le
q28: Mi gato es mi único amigo

```

Datos perdidos después de imputar por mediana: 0

✓ 2. Factorabilidad: Bartlett y KMO

Bartlett contrasta que la matriz de correlaciones sea identidad. Se requiere $p < 0.05$.

KMO cuantifica varianza común; valores superiores a 0.80.

La prueba se calcula como $\chi^2 = -\left(n - 1 - \frac{2p+5}{6}\right) \ln |R|$, con $gl = p(p - 1)/2$, donde n es el número de casos, p el número de ítems y $|R|$ el determinante de la matriz de correlaciones. La regla de decisión es: se rechaza H_0 (matriz identidad) si el estadístico supera el valor crítico $\chi^2_{0.95, gl}$, equivalente a $p < 0.05$.

```

1 chi,p=calculate_bartlett_sphericity(X); _,kmo=calculate_kmo(X)
2 print(f'Bartlett: chi-cuadrado={chi:.4f}, gl={28*27//2}, ' + ('p<0.
3 print(f'KMO global={kmo:.4f}')
4
5 # Verificación manual de Bartlett: chi2 = -(n-1-(2p+5)/6)·ln|R|.
6 # Reproducir la fórmula a mano documenta el cálculo y valida la fun
7 lnR = np.linalg.slogdet(X.corr().to_numpy())[1]
8 chi_manual = -(len(X)-1-(2*28+5)/6)*lnR
9 print(f'\nln|R| = {lnR:.4f}')
10 print(f'chi2 manual = -(239-1-61/6)·({lnR:.4f}) = {chi_manual:.4f}')
11 print(f'chi2 crítico (95%, gl=378) = {stats.chi2.ppf(.95,378):.4f}')

```

```

Bartlett: chi-cuadrado=3045.3894, gl=378, p<0.001
KMO global=0.8952

```

```

ln|R| = -13.3667
chi2 manual = -(239-1-61/6)·(-13.3667) = 3045.3894 (coincide con la fun
chi2 crítico (95%, gl=378) = 424.3342 -> como 3045.39 > 424.33, se rechaza

```

✓ 3. Número de factores

Para decidir cuántos factores retener se combinan tres criterios:

1. **Autovalores observados:** indican cuánta varianza explica cada dimensión inicial.
2. **Gráfico de sedimentación:** muestra los autovalores ordenados de mayor a menor; se observa el punto donde la curva comienza a aplanarse, porque desde ahí los factores adicionales aportan poca información nueva.

3. Análisis paralelo: compara los autovalores observados con los que aparecerían por azar en matrices aleatorias del mismo tamaño.

El análisis paralelo es especialmente importante porque el criterio de autovalor mayor que 1 puede sugerir más factores de los realmente respaldados por los datos. En esta aplicación, el cuarto factor queda muy cerca del percentil 95 aleatorio. El valor 1.501 corresponde al percentil 95 del cuarto autovalor obtenido en las 1.000 matrices aleatorias generadas para el análisis paralelo. Por eso se revisa también la media de autovalores aleatorios y la coherencia teórica de cuatro dimensiones.

```
1 R=X.corr().to_numpy(); eig=np.linalg.eigvalsh(R)[::-1]
2 rng=np.random.default_rng(12345)
3 rand=[]
4 for _ in range(1000):
5     Rr=np.corrcoef(rng.normal(size=X.shape),rowvar=False)
6     rand.append(np.linalg.eigvalsh(Rr)[::-1])
7 rand=np.array(rand)
8 rand95=np.percentile(rand,95,axis=0)
9 randmean=rand.mean(axis=0)
10 print('Primeros 8 autovalores observados:',np.round(eig[:8],3))
11 print('Percentil 95 aleatorio:',np.round(rand95[:8],3))
12 print('Media aleatoria:',np.round(randmean[:8],3))
13 print('Factores retenidos por percentil 95:',int((eig>rand95).sum()))
14 print('Factores retenidos por media aleatoria:',int((eig>randmean).sum()))
15 print(f'Cuarto autovalor observado = {eig[3]:.3f}; percentil 95 aleatorio = {rand95[3]:.3f}')
16
17 import matplotlib.pyplot as plt
18 from pathlib import Path
19 from IPython.display import Image, display
20 ASSETS_DIR = Path('../assets')
21 ASSETS_DIR.mkdir(parents=True, exist_ok=True)
22 fig, ax = plt.subplots(figsize=(8,5))
23 xs=np.arange(1,len(items)+1)
24 ax.plot(xs,eig,marker='o',label='Autovalores observados',linewidth=2)
25 ax.plot(xs,rand95,marker='s',label='Percentil 95 aleatorio',linewidth=2)
26 ax.plot(xs,randmean,linestyle='--',label='Media aleatoria',linewidth=2)
27 ax.axvline(4,color='gray',linestyle=':',label='4 factores retenidos')
28 ax.set_xlabel('Número de factor')
29 ax.set_ylabel('Autovalor')
30 ax.set_title('Análisis paralelo y gráfico de sedimentación')
31 ax.set_xlim(1,12)
32 ax.grid(alpha=.25)
33 ax.legend()
34 fig.savefig(ASSETS_DIR / 'p2_scree_parallel.png', dpi=200, bbox_inches='tight')
35 plt.close(fig)
36 display(Image(str(ASSETS_DIR / 'p2_scree_parallel.png')))
37 print(f'Figura guardada: {ASSETS_DIR / 'p2_scree_parallel.png'})
```

Primeros 8 autovalores observados: [9.03 2.725 1.706 1.505 1.157 0.975
 Percentil 95 aleatorio: [1.785 1.656 1.55 1.501 1.437 1.367 1.312 1.268
 Media aleatoria: [1.687 1.567 1.494 1.445 1.388 1.333 1.285 1.239]
 Factores retenidos por percentil 95: 4
 Factores retenidos por media aleatoria: 4
 Cuarto autovalor observado = 1.505; percentil 95 aleatorio = 1.501; medi
 Figura guardada: ../assets/p2_scree_parallel.png




Figura: análisis paralelo y gráfico de sedimentación. La curva observada se compara con autovalores aleatorios. La decisión de retener cuatro factores queda respaldada porque los primeros cuatro autovalores observados superan la referencia aleatoria, aunque el cuarto factor es una decisión ajustada bajo el percentil 95.

```

1 fa=FactorAnalyzer(n_factors=4,rotation='oblimin',method='ml'); fa.f
2 L=pd.DataFrame(fa.loadings_,index=items,columns=['F1','F2','F3','F4
3 print(L.round(3).to_string())
4 print('\nVarianza por factor:')
5 varianza = pd.DataFrame(np.array(fa.get_factor_variance()).T,column
6 print(varianza.round(4).to_string())
7 print('\nCorrelaciones factoriales:')
8 print(pd.DataFrame(fa.phi_,index=L.columns,columns=L.columns).round
  
```

	F1	F2	F3	F4
q1	0.401	-0.140	0.285	0.340
q2	0.097	-0.329	0.357	0.272
q3	0.116	0.293	-0.048	0.508
q4	0.125	0.165	0.137	0.510
q5	0.056	0.055	0.669	-0.131
q6	0.160	-0.347	0.161	0.264
q7	0.139	0.452	-0.049	0.299

q8	0.575	0.222	0.036	0.242
q9	0.437	-0.114	0.258	0.372
q10	0.417	-0.069	0.178	0.044
q11	0.266	0.457	0.200	0.102
q12	-0.011	0.133	0.269	-0.164
q13	0.560	0.082	-0.033	0.209
q14	0.757	0.028	0.179	-0.337
q15	0.361	-0.017	0.137	0.184
q16	0.741	0.215	-0.024	-0.200
q17	0.788	-0.009	-0.034	0.136
q18	0.232	-0.322	0.404	0.142
q19	-0.055	0.568	-0.177	0.078
q20	0.035	0.450	0.052	0.199
q21	0.471	0.165	-0.040	0.270
q22	0.857	-0.074	-0.021	0.113
q23	-0.094	0.042	0.700	0.066
q24	0.097	0.284	0.127	0.481
q25	0.101	0.533	0.131	0.082
q26	0.278	0.593	0.020	-0.072
q27	-0.020	0.612	0.382	0.068
q28	0.012	0.211	0.533	-0.016

Varianza por factor:

	SS cargas	Proporción	Acumulada
F1	4.3219	0.1544	0.1544
F2	2.7152	0.0970	0.2513
F3	2.1239	0.0759	0.3272
F4	1.7733	0.0633	0.3905

Correlaciones factoriales:

	F1	F2	F3	F4
F1	1.000	0.299	0.471	0.370
F2	0.299	1.000	0.130	0.129
F3	0.471	0.130	1.000	0.252
F4	0.370	0.129	0.252	1.000

✓ 5. Interpretación y confiabilidad

La solución se interpreta considerando conjuntamente contenido y cargas:

- F1: entusiasmo por diseño experimental.
- F2: amor por la enseñanza.
- F3: ausencia de habilidades interpersonales.
- F4: amor por la estadística.

Se calcula alfa con conjuntos conceptualmente coherentes. Algunos ítems presentan cargas cruzadas o débiles, por lo que la teoría se evalúa en grado, no solo contando factores.

```
1 def alpha(d):
2     k=d.shape[1]; return k/(k-1)*(1-d.var(ddof=1).sum()/d.sum(axis=1)).
3     sets={
4     'Diseño experimental':['q8','q13','q14','q16','q17','q22'],
5     'Enseñanza':['q7','q10','q11','q19','q20','q25','q26'],
6     'Habilidades interpersonales deficientes':['q2','q5','q6','q12','q1
```



```
7 'Estadística': ['q1', 'q3', 'q4', 'q9', 'q15', 'q21', 'q24']}]
8 for nombre, its in sets.items(): print(f'{nombre}: alpha={alpha(X[it
```

Diseño experimental: alpha=0.880 (6 ítems)

Enseñanza: alpha=0.747 (7 ítems)

Habilidades interpersonales deficientes: alpha=0.691 (8 ítems)

Estadística: alpha=0.830 (7 ítems)

```
1 # Correlaciones ítem-total corregidas por subescala teórica.
2 # Verifica que ningún ítem esté invertido o mal codificado dentro d
3 # una correlación ítem-total negativa indicaría necesidad de recodi
4 for nombre, its in sets.items():
5     sub = X[its]
6     print(f'\n{nombre}:')
7     for it in its:
8         resto = sub.drop(columns=it).sum(axis=1)
9         r = sub[it].corr(resto)
10        marca = ' <-- NEGATIVA' if r < 0 else ''
11        print(f' {it}: r ítem-total corregida = {r:.3f}{marca}')
```

Diseño experimental:

```
q8: r ítem-total corregida = 0.714
q13: r ítem-total corregida = 0.611
q14: r ítem-total corregida = 0.634
q16: r ítem-total corregida = 0.678
q17: r ítem-total corregida = 0.767
q22: r ítem-total corregida = 0.783
```

Enseñanza:

```
q7: r ítem-total corregida = 0.476
q10: r ítem-total corregida = 0.248
q11: r ítem-total corregida = 0.538
q19: r ítem-total corregida = 0.360
q20: r ítem-total corregida = 0.505
q25: r ítem-total corregida = 0.568
q26: r ítem-total corregida = 0.583
```

Habilidades interpersonales deficientes:

```
q2: r ítem-total corregida = 0.382
q5: r ítem-total corregida = 0.486
q6: r ítem-total corregida = 0.261
q12: r ítem-total corregida = 0.170
q18: r ítem-total corregida = 0.446
q23: r ítem-total corregida = 0.566
q27: r ítem-total corregida = 0.333
q28: r ítem-total corregida = 0.424
```

Estadística:

```
q1: r ítem-total corregida = 0.636
q3: r ítem-total corregida = 0.516
q4: r ítem-total corregida = 0.539
q9: r ítem-total corregida = 0.626
q15: r ítem-total corregida = 0.529
q21: r ítem-total corregida = 0.603
q24: r ítem-total corregida = 0.647
```

6. Conclusión

Bartlett es significativo ($\chi^2(378) = 3045.39, p < 0.001$) y KMO=0.895, por lo que la matriz es adecuada. El análisis paralelo recomienda **cuatro factores** tanto con el percentil 95 (cuarto autovalor 1.505 contra umbral 1.501, decisión ajustada) como con la media de los autovalores aleatorios (umbral 1.445, decisión holgada), coincidiendo con Blend y con el respaldo de la expectativa teórica a priori. La solución rotada permite reconocer las cuatro áreas teóricas, especialmente diseño experimental y estadística/enseñanza.

Sin embargo, hay cargas cruzadas (por ejemplo q1, q9 y q27) e ítems sin carga factorial relevante o débiles (como q12), y la dimensión de habilidades interpersonales deficientes no queda completamente limpia. **La teoría de Blend recibe apoyo general respecto del número y contenido de factores, pero no apoyo perfecto a nivel de todos los ítems.** Se recomienda revisar o eliminar ítems ambiguos antes de una validación confirmatoria.