

Tarea_2_P4_MANOVA.ipynb

Exportado desde el notebook ejecutado del repositorio. Incluye enunciado, código, outputs de texto e imágenes guardadas.

Celda 1 - Markdown

Pregunta 4 — MANOVA factorial de lealtad

Métodos Cuantitativos de la Investigación en Negocios — Tarea 2 (2026)

Celda 2 - Código ejecutado #1

```
# Instalación condicional de dependencias para Google Colab.
# En ejecución local no instala nada si los paquetes ya están disponibles.
import importlib, subprocess, sys

def instalar_si_falta(import_name, package_name=None):
    package_name = package_name or import_name
    try:
        importlib.import_module(import_name)
    except ImportError:
        print(f'Instalando {package_name}...')
        subprocess.check_call([sys.executable, '-m', 'pip', 'install', '-q', package_name])

instalar_si_falta('pyreadstat', 'pyreadstat')
instalar_si_falta('pingouin', 'pingouin')

print('Dependencias verificadas y entorno inicial preparado.')
```

OUTPUT:

Dependencias verificadas y entorno inicial preparado.

Celda 3 - Markdown

Enunciado de la pregunta 4

4. La empresa HBAT produce y vende productos de papel a dos industrias: Impresores de revistas e impresores de diarios. Los productos llegan a estos clientes a través de dos canales: Directo (Fuerza de Ventas) e Indirecto (Agentes). HBAT realizó una investigación de mercados en las que recolectó información en un sinnúmero de variables, métricas y no métricas, disponibles en el archivo HBAT200.sav, en una muestra de 200 clientes.

Entre las variables consideradas se encuentran algunas asociadas al resultado de compras y relación (5 variables), y variables descriptivas de las empresas de las cuales se recolectó información. Las variables se describen a continuación:

Datos de Clasificación de las empresas encuestadas

- X1 - Tipo de Cliente.
- X2 - Tipo de Industria.
- X3 - Tamaño de la Empresa.
- X4 - Región.
- X5 - Sistema de Distribución.

Resultado de Compras y Relación con HBAT

- X19 - Satisfacción.
- X20 - Intención de Recomendar a HBAT.
- X21 - Intención de Recomprar a HBAT.
- X22 - Nivel de Compras de HBAT.
- X23 - Considera Alianza Estratégica con HBAT.

Los ejecutivos de HBAT tienen diversas preguntas respecto a su desempeño y el nivel de satisfacción de sus clientes. En particular, están interesados en conocer el efecto de “Tamaño de la Empresa” y el “Tipo de Distribución” en la lealtad de los clientes, la cual consideran un constructo compuesto por tres variables: X19, Satisfacción; X20, Intención de Recomendar; X21, Intención de Recomprar.

En particular, desean determinar si:

- a) ¿Incide el tipo de distribución en la lealtad de los clientes?
- b) ¿Se comportan los clientes de forma distinta en términos de su lealtad dependiendo de su tamaño?
- c) ¿Son las variables tipo de distribución y tamaño antecedentes independientes de la lealtad?

Respuesta

Como la lealtad se mide mediante tres variables relacionadas, la pregunta se resuelve mediante un MANOVA factorial 2×2 . Este enfoque permite evaluar simultáneamente el efecto del tipo de distribución, el tamaño de la empresa y su interacción sobre satisfacción, recomendación y recompra.

Celda 4 - Código ejecutado #3

```
from pathlib import Path
from urllib.request import urlretrieve, urlopen
import ssl
import warnings
warnings.filterwarnings('ignore')

import numpy as np
import pandas as pd
import pyreadstat
from scipy import stats
import statsmodels.api as sm
import statsmodels.formula.api as smf

pd.set_option('display.max_columns', 100)
pd.set_option('display.width', 160)

# Base requerida para este notebook.
# Funciona localmente y también en Google Colab abierto desde GitHub.
REQUIRED_DATA_FILE = 'HBAT_200.sav'
RAW_DATA_BASE = 'https://raw.githubusercontent.com/sebabecerra/Metodos-Cuantitativos-DEN/main/Tarea2/data'

def encontrar_o_descargar_base(filename):
    candidatas = [
        Path.cwd() / 'data',                # ejecución desde Tarea2
        Path.cwd().parent / 'data',          # ejecución desde Tarea2/notebooks
        Path.cwd() / 'Tarea2' / 'data',      # ejecución desde raíz del repo o Colab
        Path.cwd()                          # respaldo: base junto al notebook
    ]
    for ruta in candidatas:
        if (ruta / filename).exists():
            return ruta

    # Si Colab no tiene la carpeta del repo clonada, se descarga la base desde GitHub.
    destino_dir = Path.cwd() / 'Tarea2' / 'data'
    destino_dir.mkdir(parents=True, exist_ok=True)
    destino = destino_dir / filename
    url = f'{RAW_DATA_BASE}/{filename}'
    print(f'Base {filename} no encontrada localmente. Descargando desde GitHub...')
    try:
        urlretrieve(url, destino)
    except Exception as error:
        # Respaldo útil en algunos entornos locales con problemas de certificados SSL.
        # En Colab normalmente no se activa, pero evita fallas si Python no encuentra certificados.
        print('Descarga estándar falló; intentando respaldo SSL...')
        contexto = ssl._create_unverified_context()
        with urlopen(url, context=contexto) as respuesta, open(destino, 'wb') as archivo:
            archivo.write(respuesta.read())
    return destino_dir

DATA_DIR = encontrar_o_descargar_base(REQUIRED_DATA_FILE)
print('Directorio de datos:', DATA_DIR)
print('Base usada:', DATA_DIR / REQUIRED_DATA_FILE)
```

OUTPUT:

Directorio de datos: /Users/sbc/projects/Metodos-Cuantitativos-DEN/Tarea2/data
 Base usada: /Users/sbc/projects/Metodos-Cuantitativos-DEN/Tarea2/data/HBAT_200.sav

Celda 5 - Markdown

1. Diseño, procedimiento e hipótesis

La lealtad se representa mediante satisfacción, recomendación y recompra. Se aplica MANOVA factorial 2×2 con tipo de distribución y tamaño. Se prueban:

- H01: la distribución no se asocia conjuntamente con la lealtad.
- H02: el tamaño no se asocia conjuntamente con la lealtad.
- H03: distribución y tamaño actúan independientemente (sin interacción).

Tras MANOVA se analizan ANOVA univariados y medias de celdas.

Celda 6 -Codigo ejecutado #3

```
from statsmodels.multivariate.manova import MANOVA
from statsmodels.stats.anova import anova_lm
import pingouin as pg

# Chequeo inicial de la base.
# Se carga la base completa; no se filtran observaciones ni se toma una submuestra.
df, meta = pyreadstat.read_sav(DATA_DIR/'HBAT_200.sav', apply_value_formats=False)
dvs = ['Satisfaccion', 'Recomendacion', 'Recompra']
factores = ['Tipo_Dist', 'Tamaño_Empresa']

print('Archivo usado:', DATA_DIR/'HBAT_200.sav')
print('Número de observaciones:', len(df))
print('Número de variables:', df.shape[1])
print('Dimensión de la base:', df.shape)
print('Datos perdidos totales:', int(df[dvs + factores].isna().sum().sum()))
print('\nDatos perdidos por variable usada:')
print(df[dvs + factores].isna().sum().to_string())
print('\nCodificación observada de factores:')
for v in factores:
    print(f'\n{v}:')
    print(df[v].value_counts(dropna=False).sort_index().to_string())
print('\nTamaños de celda:')
print(df.groupby(['Tipo_Dist', 'Tamaño_Empresa']).size().rename('n').to_string())
print('\nDescriptivos de variables dependientes:')
print(df[dvs].describe().round(3).to_string())
print('\nMedias por celda:')
print(df.groupby(['Tipo_Dist', 'Tamaño_Empresa'])[dvs].mean().round(3).to_string())
print(f'\nF crítico univariado (95%; 1,196) = {stats.f.ppf(.95,1,196):.4f}')
```

OUTPUT:

Archivo usado: /Users/sbc/projects/Metodos-Cuantitativos-DEN/Tarea2/data/HBAT_200.sav
Número de observaciones: 200
Número de variables: 11
Dimensión de la base: (200, 11)
Datos perdidos totales: 0

Datos perdidos por variable usada:

Satisfaccion	0
Recomendacion	0
Recompra	0
Tipo_Dist	0
Tamaño_Empresa	0

Codificación observada de factores:

Tipo_Dist:

Tipo_Dist	
0.0	108
1.0	92

Tamaño_Empresa:

Tamaño_Empresa	
0.0	98
1.0	102

Tamaños de celda:

Tipo_Dist	Tamaño_Empresa	
0.0	0.0	45
	1.0	63
1.0	0.0	53
	1.0	39

Descriptivos de variables dependientes:

	Satisfaccion	Recomendacion	Recompra
count	200.000	200.000	200.000
mean	6.952	6.952	7.665

std	1.241	1.083	0.893
min	4.700	4.000	4.300
25%	6.000	6.100	7.100
50%	7.050	7.000	7.600
75%	7.900	7.650	8.200
max	9.900	9.900	9.900

Medias por celda:

		Satisfaccion	Recomendacion	Recompra
Tipo_Dist	Tamaño_Empresa			
0.0	0.0	6.211	6.091	7.142
	1.0	6.406	6.771	7.475
1.0	0.0	7.128	7.079	7.670
	1.0	8.449	8.067	8.569

F crítico univariado (95%; 1,196) = 3.8893

Celda 7 - Markdown

2. Consistencia de la medida de lealtad y supuestos

Se reportan alfa, correlaciones, Box M para igualdad de matrices de covarianza y Levene por variable. MANOVA es razonablemente robusto con tamaños similares; ante violaciones se privilegia Pillai, aunque también se presenta Wilks.

La consistencia se calcula con $\alpha=\frac{k}{k-1}\bigl(1-\frac{\sum_i s_i^2}{s_T^2}\bigr)$.
Reemplazando ($k=3$, $\sum s_i^2=3.5109$, $s_T^2=8.4457$):
 $\alpha=\frac{3}{2}\bigl(1-\frac{3.5109}{8.4457}\bigr)=0.876$. Los estadísticos de comparación al 95% son $\chi^2_{0.95,18}=28.87$ para Box M y $F_{0.95;3,196}=2.6507$ para Levene: Box M (27.55) no supera su crítico, por lo que no se rechaza la igualdad de matrices de covarianza; Levene lo supera en satisfacción (4.93) y recompra (4.55), pero no en recomendación (1.72).

Celda 8 - Codigo ejecutado #7

```
def alpha(d):
    k=d.shape[1]; return k/(k-1)*(1-d.var(ddof=1).sum()/d.sum(axis=1).var(ddof=1))
print('Alfa lealtad=',round(alpha(df[dvs]),4)); print('\nCorrelaciones:\n',df[dvs].corr().round(3).to_string())
df['grupo']=df.Tipo_Dist.astype(str)+'_'+df.Tamaño_Empresa.astype(str)
print('\nBox M:\n',pg.box_m(df,dvs=dvs,group='grupo').round(4).to_string())
for v in dvs:
    grupos=[g[v] for _,g in df.groupby('grupo')]; st,p=stats.levene(*grupos); print(f'Levene {v}: F={st:.4f},
p={p:.4g}')
print(f'\nchi2 crítico Box M (95%, gl=18) = {stats.chi2.ppf(.95,18):.4f}')
print(f'F crítico Levene (95%; 3,196) = {stats.f.ppf(.95,3,196):.4f}')
```

OUTPUT:

Alfa lealtad= 0.8764

Correlaciones:

	Satisfaccion	Recomendacion	Recompra
Satisfaccion	1.000	0.762	0.726
Recomendacion	0.762	1.000	0.661
Recompra	0.726	0.661	1.000

Box M:

```
Chi2    df    pval  equal_cov
box 27.551 18.0 0.0692      True
Levene Satisfaccion: F=4.9332, p=0.00252
Levene Recomendacion: F=1.7195, p=0.1643
Levene Recompra: F=4.5532, p=0.004149
```

chi2 crítico Box M (95%, gl=18) = 28.8693
F crítico Levene (95%; 3,196) = 2.6507

Celda 9 - Markdown

3. MANOVA factorial

La interacción prueba directamente si distribución y tamaño son antecedentes independientes. Si es significativa, la asociación de una variable varía según el nivel de la otra.

Con efectos de un grado de libertad (diseño 2x2), las cuatro pruebas multivariadas (Pillai, Wilks, Hotelling y Roy) producen exactamente el mismo F, y este se obtiene directamente de Lambda mediante

$$F=\frac{1-\Lambda}{\Lambda}\cdot\frac{g_2}{g_1}.$$

Por ejemplo, para distribución: $F=\frac{1-0.8526}{0.8526}\cdot\frac{194}{3}=11.18$. El estadístico de comparación al 95% es $F_{0.95;3,194}=2.6512$: se rechaza cada H_0 cuyo F observado lo supere.

Celda 10 - Codigo ejecutado #9

```
ma=MANOVA.from_formula('Satisfaccion + Recomendacion + Recompra ~ C(Tipo_Dist) * C(Tamaño_Empresa)',df)
print(ma.mv_test())
print(f'F crítico multivariado (95%; 3,194) = {stats.f.ppf(.95,3,194):.4f}')
```

OUTPUT:

Multivariate linear model						
=====						
Intercept	Value	Num DF	Den DF	F Value	Pr > F	
Wilks' lambda	0.0436	3.0000	194.0000	1419.8017	0.0000	
Pillai's trace	0.9564	3.0000	194.0000	1419.8017	0.0000	
Hotelling-Lawley trace	21.9557	3.0000	194.0000	1419.8017	0.0000	
Roy's greatest root	21.9557	3.0000	194.0000	1419.8017	0.0000	

C(Tipo_Dist)	Value	Num DF	Den DF	F Value	Pr > F	
Wilks' lambda	0.8526	3.0000	194.0000	11.1840	0.0000	
Pillai's trace	0.1474	3.0000	194.0000	11.1840	0.0000	
Hotelling-Lawley trace	0.1729	3.0000	194.0000	11.1840	0.0000	
Roy's greatest root	0.1729	3.0000	194.0000	11.1840	0.0000	

C(Tamaño_Empresa)	Value	Num DF	Den DF	F Value	Pr > F	
Wilks' lambda	0.9028	3.0000	194.0000	6.9588	0.0002	
Pillai's trace	0.0972	3.0000	194.0000	6.9588	0.0002	
Hotelling-Lawley trace	0.1076	3.0000	194.0000	6.9588	0.0002	
Roy's greatest root	0.1076	3.0000	194.0000	6.9588	0.0002	

C(Tipo_Dist):C(Tamaño_Empresa)	Value	Num DF	Den DF	F Value	Pr > F	
Wilks' lambda	0.9034	3.0000	194.0000	6.9167	0.0002	
Pillai's trace	0.0966	3.0000	194.0000	6.9167	0.0002	
Hotelling-Lawley trace	0.1070	3.0000	194.0000	6.9167	0.0002	
Roy's greatest root	0.1070	3.0000	194.0000	6.9167	0.0002	
=====						

F crítico multivariado (95%; 3,194) = 2.6512

Celda 11 - Markdown

4. ANOVA univariados y tamaño de efecto

Se calcula eta cuadrado parcial $\eta_p^2=SC_{\text{efecto}}/(SC_{\text{efecto}}+SC_{\text{error}})$.

El estadístico de comparación de los ANOVA univariados al 95% es $F_{0.95;1,196}=3.8893$; se rechaza H_0 cuando el F observado lo supera. A modo de ilustración del tamaño de efecto, para la interacción en satisfacción: $\eta_p^2=\frac{15.3264}{15.3264+174.0669}=0.081$.

Dado que se realizan tres pruebas univariadas por familia de efectos, se usa como referencia adicional la corrección de Bonferroni: $\alpha=0.05/3=0.0167$. Con este criterio, la interacción sigue siendo significativa en satisfacción ($p<0.001$) y en recompra ($p=0.0099<0.0167$), y no significativa en recomendación ($p=0.221$).

Celda 12 - Codigo ejecutado #11

```
for v in dvs:
    fit=smf.ols(f'{v} ~ C(Tipo_Dist) * C(Tamaño_Empresa)',df).fit(); tab=anova_lm(fit,typ=2);
    err=tab.loc['Residual','sum_sq']; tab['eta2_parcial']=tab.sum_sq/(tab.sum_sq+err)
    print('\n',v); print(tab.round(4).to_string())
print(f'\nF crítico univariado (95%; 1,196) = {stats.f.ppf(.95,1,196):.4f}')
```

```
print(f'F crítico univariado con Bonferroni (alfa=0.05/3; 1,196) = {stats.f.ppf(1-0.05/3,1,196):.4f}')
```

OUTPUT:

Satisfaccion	sum_sq	df	F	PR(>F)	eta2_parcial
C(Tipo_Dist)	105.6251	1.0	118.9343	0.0	0.3776
C(Tamaño_Empresa)	24.8461	1.0	27.9768	0.0	0.1249
C(Tipo_Dist):C(Tamaño_Empresa)	15.3264	1.0	17.2576	0.0	0.0809
Residual	174.0669	196.0	NaN	NaN	0.5000

Recomendacion	sum_sq	df	F	PR(>F)	eta2_parcial
C(Tipo_Dist)	63.0323	1.0	83.1164	0.0000	0.2978
C(Tamaño_Empresa)	32.9133	1.0	43.4006	0.0000	0.1813
C(Tipo_Dist):C(Tamaño_Empresa)	1.1417	1.0	1.5055	0.2213	0.0076
Residual	148.6389	196.0	NaN	NaN	0.5000

Recompra	sum_sq	df	F	PR(>F)	eta2_parcial
C(Tipo_Dist)	31.7444	1.0	55.4024	0.0000	0.2204
C(Tamaño_Empresa)	17.1827	1.0	29.9883	0.0000	0.1327
C(Tipo_Dist):C(Tamaño_Empresa)	3.8924	1.0	6.7934	0.0099	0.0335
Residual	112.3039	196.0	NaN	NaN	0.5000

F crítico univariado (95%; 1,196) = 3.8893
F crítico univariado con Bonferroni (alfa=0.05/3; 1,196) = 5.8308

Celda 13 - Codigo ejecutado #12

```
# Diagnósticos multivariados adicionales: Mardia y Mahalanobis.
# Estos diagnósticos complementan Box M, Levene y la elección de Pillai.
X = df[dvs].to_numpy(float)
media = X.mean(axis=0)
S = np.cov(X, rowvar=False)
Sinv = np.linalg.inv(S)
D = (X - media) @ Sinv @ (X - media).T
b1p = np.mean(D**3)
md2 = np.diag(D)
b2p = np.mean(md2**2)
n, p_dim = X.shape
skew_stat = n * b1p / 6
skew_df = p_dim * (p_dim + 1) * (p_dim + 2) // 6
skew_p = 1 - stats.chi2.cdf(skew_stat, skew_df)
z_kurt = (b2p - p_dim * (p_dim + 2)) / np.sqrt(8 * p_dim * (p_dim + 2) / n)
kurt_p = 2 * (1 - stats.norm.cdf(abs(z_kurt)))
mah_cut = stats.chi2.ppf(.999, p_dim)
print(f'Mardia asimetría: b1p={b1p:.4f}, chi2={skew_stat:.4f}, gl={skew_df}, p={skew_p:.4f}')
print(f'Mardia curtosis: b2p={b2p:.4f}, z={z_kurt:.4f}, p={kurt_p:.4f}')
print(f'Mahalanobis máximo={md2.max():.4f}; corte chi2(.999,3)={mah_cut:.4f}; casos sobre corte={({md2 >
mah_cut).sum()})')

# Efectos simples con pruebas t de Welch y corrección Bonferroni por variable dependiente.
filas = []
for dv in dvs:
    for size_val, size_lab in [(0, 'Pequeña'), (1, 'Grande')]:
        directa = df[(df.Tipo_Dist == 1) & (df.Tamaño_Empresa == size_val)][dv]
        indirecta = df[(df.Tipo_Dist == 0) & (df.Tamaño_Empresa == size_val)][dv]
        t_stat, p_val = stats.ttest_ind(directa, indirecta, equal_var=False)
        va, vb = directa.var(ddof=1), indirecta.var(ddof=1)
        na, nb_ = len(directa), len(indirecta)
        gl = (va/na + vb/nb_)**2 / ((va/na)**2/(na-1) + (vb/nb_)**2/(nb_-1))
        filas.append([dv, f'Directa - indirecta | {size_lab}', directa.mean() - indirecta.mean(), t_stat, gl,
p_val])
    for dist_val, dist_lab in [(0, 'Indirecta'), (1, 'Directa')]:
        grande = df[(df.Tipo_Dist == dist_val) & (df.Tamaño_Empresa == 1)][dv]
        pequena = df[(df.Tipo_Dist == dist_val) & (df.Tamaño_Empresa == 0)][dv]
        t_stat, p_val = stats.ttest_ind(grande, pequena, equal_var=False)
        va, vb = grande.var(ddof=1), pequena.var(ddof=1)
        na, nb_ = len(grande), len(pequena)
        gl = (va/na + vb/nb_)**2 / ((va/na)**2/(na-1) + (vb/nb_)**2/(nb_-1))
        filas.append([dv, f'Grande - pequeña | {dist_lab}', grande.mean() - pequena.mean(), t_stat, gl, p_val])

efectos_simples = pd.DataFrame(filas, columns=['Variable', 'Comparación', 'Diferencia', 't_Welch', 'gl', 'p'])
efectos_simples['p_Bonf'] = np.minimum(efectos_simples['p'] * 4, 1)
```

```
print('\nEfectos simples Welch con Bonferroni por variable dependiente:')
print(efectos_simples.round({'Diferencia': 3, 't_Welch': 3, 'gl': 2, 'p': 4, 'p_Bonf':
4}).to_string(index=False))
```

OUTPUT:

Mardia asimetría: blp=0.3289, chi2=10.9630, gl=10, p=0.3604
Mardia curtosis: b2p=14.4609, z=-0.6960, p=0.4864
Mahalanobis máximo=17.5371; corte chi2(.999,3)=16.2662; casos sobre corte=1

Efectos simples Welch con Bonferroni por variable dependiente:

Variable	Comparación	Diferencia	t_Welch	gl	p	p_Bonf
Satisfaccion	Directa - indirecta Pequeña	0.917	4.487	82.48	0.0000	0.0001
Satisfaccion	Directa - indirecta Grande	2.042	11.855	94.68	0.0000	0.0000
Satisfaccion	Grande - pequeña Indirecta	0.195	0.946	86.65	0.3466	1.0000
Satisfaccion	Grande - pequeña Directa	1.320	7.767	87.34	0.0000	0.0000
Recomendacion	Directa - indirecta Pequeña	0.988	5.451	83.89	0.0000	0.0000
Recomendacion	Directa - indirecta Grande	1.295	7.539	86.85	0.0000	0.0000
Recomendacion	Grande - pequeña Indirecta	0.680	3.689	89.62	0.0004	0.0015
Recomendacion	Grande - pequeña Directa	0.987	5.862	80.50	0.0000	0.0000
Recompra	Directa - indirecta Pequeña	0.528	3.176	65.69	0.0023	0.0091
Recompra	Directa - indirecta Grande	1.095	7.606	89.15	0.0000	0.0000
Recompra	Grande - pequeña Indirecta	0.332	1.878	79.17	0.0640	0.2562
Recompra	Grande - pequeña Directa	0.899	6.901	71.91	0.0000	0.0000

Celda 14 - Markdown

Gráfico de interacción

Se grafica la media de satisfacción por celda. Las rectas no paralelas ilustran la interacción: la ventaja de la distribución directa es mayor entre las empresas grandes. Este gráfico respalda la Figura 6 del documento.

Celda 15 - Codigo ejecutado #14

```
# Figura integrada de interacción para las tres variables dependientes.
# Cada panel muestra las medias por tamaño de empresa y tipo de distribución.
import matplotlib
matplotlib.use('Agg')
import matplotlib.pyplot as plt

labels_tam = {0.0: 'Pequeña', 1.0: 'Grande'}
labels_dist = {0.0: 'Distribución indirecta', 1.0: 'Distribución directa'}
colors = {0.0: '#1f77b4', 1.0: '#ff7f0e'}
markers = {0.0: 'o', 1.0: 's'}

y_lims = {
    'Satisfaccion': (6.0, 8.7),
    'Recomendacion': (5.9, 8.3),
    'Recompra': (7.0, 8.8),
}

titles = {
    'Satisfaccion': 'Satisfacción',
    'Recomendacion': 'Recomendación',
    'Recompra': 'Recompra',
}

fig, axes = plt.subplots(1, 3, figsize=(13, 4), sharex=True)
for ax, dv in zip(axes, dvs):
    for dist_val in [0.0, 1.0]:
        medias = []
        for tam_val in [0.0, 1.0]:
            media = df[(df['Tipo_Dist'] == dist_val) & (df['Tamaño_Empresa'] == tam_val)][dv].mean()
            medias.append(media)
        ax.plot([0, 1], medias, marker=markers[dist_val], color=colors[dist_val], linewidth=2,
label=labels_dist[dist_val])
        ax.set_title(titles[dv])
        ax.set_xticks([0, 1], ['Pequeña', 'Grande'])
        ax.set_xlabel('Tamaño de la empresa')
        ax.set_ylim(*y_lims[dv])
        ax.grid(alpha=.25)
axes[0].set_ylabel('Media')
axes[0].legend(loc='upper left', fontsize=8)
fig.suptitle('Interacción distribución x tamaño sobre las variables de lealtad', y=1.04)
fig.tight_layout()
fig.savefig('p4_interaccion_lealtad.png', dpi=200, bbox_inches='tight')
```

```
plt.close(fig)
print('Figura guardada: p4_interaccion_lealtad.png')
```

OUTPUT:

Figura guardada: p4_interaccion_lealtad.png

Celda 16 - Markdown

5. Efectos simples

Dado que existe interacción multivariada, las medias permiten interpretar dónde cambia el efecto. Se comparan distribución directa versus indirecta dentro de cada tamaño y tamaño grande versus pequeño dentro de cada distribución.

Se reportan 12 contrastes t de Welch. Con corrección de Bonferroni por familia ($\alpha=0.05/4=0.0125$ por variable dependiente) todas las conclusiones se mantienen: los contrastes significativos conservan $p<0.0125$ y los no significativos, como grande-pequeña bajo distribución indirecta en satisfacción ($p=0.347$) y recompra ($p=0.064$), siguen siéndolo.

Celda 17 - Código ejecutado #16

```
for v in dvs:
    print('\n',v)
    for tam in [0,1]:
        a=df[(df.Tamaño_Empresa==tam)&(df.Tipo_Dist==0)][v]; b=df[(df.Tamaño_Empresa==tam)&(df.Tipo_Dist==1)][v]
        t,p=stats.ttest_ind(b,a,equal_var=False); print(f'Directa-Indirecta, tamaño {tam}:
diferencia={b.mean()-a.mean():.3f}, t={t:.3f}, p={p:.4g}')
    for dist in [0,1]:
        a=df[(df.Tipo_Dist==dist)&(df.Tamaño_Empresa==0)][v]; b=df[(df.Tipo_Dist==dist)&(df.Tamaño_Empresa==1)][v]
        t,p=stats.ttest_ind(b,a,equal_var=False); print(f'Grande-Pequeña, distribución {dist}:
diferencia={b.mean()-a.mean():.3f}, t={t:.3f}, p={p:.4g}')
```

OUTPUT:

Satisfaccion
Directa-Indirecta, tamaño 0: diferencia=0.917, t=4.487, p=2.318e-05
Directa-Indirecta, tamaño 1: diferencia=2.042, t=11.855, p=2.054e-20
Grande-Pequeña, distribución 0: diferencia=0.195, t=0.946, p=0.3466
Grande-Pequeña, distribución 1: diferencia=1.320, t=7.767, p=1.437e-11

Recomendacion
Directa-Indirecta, tamaño 0: diferencia=0.988, t=5.451, p=4.932e-07
Directa-Indirecta, tamaño 1: diferencia=1.295, t=7.539, p=4.279e-11
Grande-Pequeña, distribución 0: diferencia=0.680, t=3.689, p=0.0003856
Grande-Pequeña, distribución 1: diferencia=0.987, t=5.862, p=9.628e-08

Recompra
Directa-Indirecta, tamaño 0: diferencia=0.528, t=3.176, p=0.002273
Directa-Indirecta, tamaño 1: diferencia=1.095, t=7.606, p=2.753e-11
Grande-Pequeña, distribución 0: diferencia=0.332, t=1.878, p=0.06404
Grande-Pequeña, distribución 1: diferencia=0.899, t=6.901, p=1.689e-09

Celda 18 - Markdown

6. Conclusión

La medida de lealtad es confiable ($\alpha=0.876$). La distribución incide en la combinación de resultados, Pillai V=0.147, F(3,194)=11.184, $p<0.001$; el tamaño también, V=0.097, F(3,194)=6.959, $p<0.001$. Se rechazan H01 y H02. (Con efectos de un grado de libertad, Wilks entrega el mismo F.)

La interacción distribución×tamaño también es significativa, Pillai V=0.097, F(3,194)=6.917, $p<0.001$: no son antecedentes independientes. En los ANOVA, la interacción aparece en satisfacción ($p<0.001$) y recompra ($p=0.0099$), pero no en recomendación ($p=0.221$). Las empresas grandes con distribución directa presentan las mayores medias: satisfacción 8.449, recomendación 8.067 y recompra 8.569. El beneficio de distribución directa es especialmente fuerte en empresas grandes.