

UNIVERSIDAD DEL DESARROLLO
FACULTAD DE ECONOMÍA Y NEGOCIOS
PhD in Business Economics

**MÉTODOS CUANTITATIVOS DE LA
INVESTIGACIÓN EN NEGOCIOS**

TAREA #2-3-4: RESPUESTAS

Fecha de entrega: 17 de julio de 2026

Ponderación: 65 %

Estudiante: J. Sebastián Becerra C.

Enunciado general

Para cada una de las preguntas, se describen claramente los pasos seguidos y se adjuntan los resultados de los análisis efectuados durante el proceso. Los cálculos fueron realizados en Python y R mediante notebooks reproducibles, uno por pregunta, incluidos en la carpeta de entrega.

Notebooks reproducibles en Google Colab

Los análisis de cada pregunta pueden revisarse y ejecutarse en Google Colab desde los siguientes vínculos:

- [Pregunta 1: mediación moderada.](#)
- [Pregunta 2: análisis factorial exploratorio.](#)
- [Pregunta 3: CFA, SEM y comparación por género.](#)
- [Pregunta 4: MANOVA factorial.](#)

1. Pregunta 1: mediación moderada

1.1. Modelo conceptual

El objetivo es comprender de qué manera una condición externa, como la presión competitiva del mercado, puede traducirse en un mayor desempeño innovador de la empresa. El modelo no asume que esta relación sea exclusivamente directa. Más bien plantea que la presión competitiva activa primero una respuesta interna en los empleados, expresada en la generación, promoción e implementación de nuevas ideas. Esa conducta innovadora constituye el mecanismo que conecta la presión del entorno con resultados innovadores a nivel organizacional.

Desde esta perspectiva, la conducta innovadora del empleado funciona como mediador. Su papel no es únicamente estadístico; constituye el mecanismo que permite explicar cómo la presión competitiva puede traducirse en innovación efectiva en lugar de permanecer como una simple exigencia externa.

El modelo también reconoce que una misma presión competitiva puede generar respuestas distintas según el contexto organizacional. Si los errores derivados de la experimentación son castigados, los trabajadores pueden responder evitando riesgos. En cambio, cuando el fracaso se acepta como parte del aprendizaje, la presión competitiva puede transformarse con mayor facilidad en experimentación e innovación. Por ello, la cultura de tolerancia al fracaso actúa como moderador del camino entre presión competitiva y conducta innovadora.

Al combinar ambos argumentos, el modelo corresponde a una mediación moderada de primera etapa, equivalente al Modelo 7 de PROCESS.

1.2. a) Planteamiento del modelo en forma de hipótesis

Tabla 1: Variables del modelo

Rol	Variable	Símbolo
Independiente	Presión competitiva del mercado	X
Mediadora	Conducta innovadora del empleado	M
Moderadora	Cultura de tolerancia al fracaso	W
Dependiente	Desempeño innovador de la empresa	Y




Figura 1

Figura 1: Modelo conceptual de mediación moderada presentado en el enunciado. La cultura de tolerancia al fracaso modera el camino entre presión competitiva y conducta innovadora, y el modelo conserva el camino directo entre presión competitiva y desempeño innovador.

El modelo se estima mediante tres regresiones relacionadas, cada una con una finalidad distinta.

En las ecuaciones, X_c representa la presión competitiva centrada en su media, W_c representa la tolerancia al fracaso centrada en su media, M corresponde a la conducta innovadora del empleado y Y al desempeño innovador de la empresa. Los coeficientes a_1 , a_2 , a_3 , b , c' y c representan los efectos estimados en cada camino del modelo: a_1 es la asociación entre presión competitiva y conducta innovadora cuando la tolerancia está en su media, a_2 es la asociación entre tolerancia y conducta innovadora cuando la presión está en su media, a_3 es la interacción, b es la asociación entre conducta innovadora y desempeño, c' es el efecto directo residual y c es el efecto total.

1.2.1. Primera regresión: modelo del mediador

La primera ecuación explica la conducta innovadora a partir de la presión competitiva, la tolerancia al fracaso y su interacción:

$$M = i_M + a_1 X_c + a_2 W_c + a_3 (X_c W_c) + e_M. \quad (1)$$

El coeficiente a_1 representa el efecto de la presión competitiva cuando la tolerancia al fracaso está en su media, porque $W_c = 0$. El coeficiente a_2 representa el efecto de la tolerancia al fracaso cuando la presión competitiva está en su media, porque $X_c = 0$. Finalmente, a_3 indica cuánto cambia el efecto de X_c sobre M por cada unidad adicional de W_c . Si a_3 es significativo, existe moderación.

1.2.2. Segunda regresión: modelo del resultado

La segunda ecuación explica el desempeño innovador a partir de la presión competitiva y de la conducta innovadora:

$$Y = i_Y + c'X_c + bM + e_Y. \quad (2)$$

El coeficiente b representa el efecto de la conducta innovadora sobre el desempeño, controlando la presión competitiva. El coeficiente c' corresponde al efecto directo residual de la presión competitiva una vez incorporado el mediador.

1.2.3. Tercera regresión: efecto total

La tercera ecuación estima la asociación global entre presión competitiva y desempeño antes de incorporar el mediador:

$$Y = i_T + cX_c + e_T. \quad (3)$$

El coeficiente c representa el efecto total. Esta ecuación documenta si existe una relación global, pero no identifica el mecanismo estadístico que podría estar detrás de esa asociación.

1.2.4. Efecto indirecto condicional

El efecto indirecto es una función del moderador:

$$IE(W_c) = (a_1 + a_3W_c)b. \quad (4)$$

Por tanto, el mecanismo $X_c \rightarrow M \rightarrow Y$ no tiene necesariamente la misma magnitud para todos los niveles centrados de tolerancia al fracaso.

1.2.5. Hipótesis específicas

- H1: la presión competitiva se asocia positivamente con la conducta innovadora de los empleados ($a_1 > 0$).
- H2: la conducta innovadora de los empleados se asocia positivamente con el desempeño innovador de la empresa ($b > 0$).

- H3: existe un efecto directo residual de la presión competitiva sobre el desempeño innovador una vez incorporada la conducta innovadora ($c' \neq 0$).
- H4: existe un efecto indirecto significativo de la presión competitiva sobre el desempeño innovador a través de la conducta innovadora ($IE(W_c) \neq 0$).
- H5: la tolerancia al fracaso fortalece la relación entre presión competitiva y conducta innovadora ($a_3 > 0$).

1.3. b) Estrategia analítica y evaluación de hipótesis

Se analizaron 200 observaciones sin valores perdidos. La presión competitiva y la tolerancia al fracaso se centraron respecto de sus medias:

$$X_c = X - \bar{X}, \quad W_c = W - \bar{W},$$

para luego construir el término de interacción $X_c W_c$. El centrado no altera el ajuste ni la significancia de la interacción, pero permite interpretar los efectos principales en el nivel medio de la otra variable y reduce la colinealidad no esencial.

Las regresiones se estimaron mediante mínimos cuadrados ordinarios con errores estándar robustos HC3. Los efectos indirectos condicionales y el índice de mediación moderada se evaluaron mediante 5.000 remuestras bootstrap. La regla de decisión fue: para coeficientes individuales, $p < .05$; para efectos indirectos, intervalo de confianza bootstrap que no incluya cero.

El análisis se desarrolla en seis pasos: primero se revisan descriptivos y correlaciones; segundo, se estima el modelo del mediador; tercero, se interpreta la interacción mediante efectos condicionales; cuarto, se estima el modelo del resultado; quinto, se reporta el efecto total; y sexto, se evalúan los efectos indirectos condicionales y el índice de mediación moderada.

Como complemento, la Tabla 2 resume las variables originales antes de centrar X y W . Esto permite verificar la escala real de cada variable y facilita interpretar las magnitudes estimadas.

Tabla 2: Estadísticos descriptivos de las variables de la Pregunta 1

Variable	N	Media	DE	Mín.	Máy.
Presión competitiva	200	4.576	1.079	2.129	7.778
Tolerancia al fracaso	200	2.785	0.758	1.054	4.543
Conducta innovadora	200	9.595	3.406	3.000	21.000
Desempeño innovador	200	9.639	2.983	4.113	21.066

La Tabla 3 muestra las asociaciones bivariadas iniciales. La presión competitiva se correlaciona fuertemente con conducta innovadora y desempeño innovador, y de forma positiva pero más moderada con tolerancia al fracaso.

Tabla 3: Correlaciones bivariadas con presión competitiva

Variable correlacionada con presión competitiva	r	p
Tolerancia al fracaso	.174	.014
Conducta innovadora	.739	< .001
Desempeño innovador	.733	< .001

Como diagnóstico adicional, se evaluó la multicolinealidad mediante el factor de inflación de la varianza. Todos los VIF fueron inferiores a 1.05, por lo que no se observaron problemas de colinealidad entre la presión competitiva centrada, la tolerancia centrada y su interacción. La prueba de Breusch–Pagan tampoco detectó heterocedasticidad en el modelo del mediador ($LM = 1.1407$, $p = .767$). En cualquier caso, la inferencia principal utiliza errores estándar robustos HC3.

Tabla 4: Diagnóstico de multicolinealidad en el modelo del mediador

Término	VIF
Constante	1.027
Presión competitiva centrada (X_c)	1.036
Tolerancia centrada (W_c)	1.046
Interacción $X_c W_c$	1.016

1.3.1. Regresión 1: conducta innovadora

Tabla 5: Modelo del mediador

Predictor	B	EE robusto	z	p
Constante	9.5207	0.0344	277.01	< .001
Presión competitiva centrada (a_1)	2.0008	0.0394	50.82	< .001
Tolerancia centrada (a_2)	2.8732	0.0470	61.14	< .001
Interacción $X_c W_c$ (a_3)	0.5248	0.0389	13.48	< .001

El modelo explica el 98.05 % de la variación observada en la conducta innovadora ($R^2 = 0.9805$). Con tolerancia al fracaso en su media, un punto adicional de presión competitiva se asocia con aproximadamente dos ideas adicionales propuestas por el empleado durante el período considerado. A su vez, con presión competitiva en su media, un punto adicional de tolerancia al fracaso se asocia con aproximadamente 2.87 ideas adicionales.

El resultado central es la interacción positiva y significativa. El coeficiente $a_3 = 0.5248$ indica que, por cada punto adicional de tolerancia al fracaso, el efecto de la presión competitiva sobre la conducta innovadora aumenta en aproximadamente 0.525 ideas por cada punto de presión competitiva. Los resultados sugieren que la presión competitiva genera una respuesta innovadora más intensa cuando la organización tolera los errores inherentes a los procesos de experimentación. Se apoyan H1 y H5.

Tabla 6: Efectos condicionales de presión competitiva sobre conducta innovadora

Nivel de tolerancia	Efecto condicional	EE robusto	z	IC95 % inf.	IC95 % sup.
Baja (−1 DE)	1.603	0.045	35.66	1.515	1.691
Media	2.001	0.039	50.82	1.924	2.078
Alta (+1 DE)	2.399	0.053	45.15	2.295	2.503




Figura 2: Moderación de la cultura de tolerancia al fracaso en la relación entre presión competitiva y conducta innovadora, generada desde el notebook de la Pregunta 1.

1.3.2. Regresión 2: desempeño innovador

Tabla 7: Modelo del resultado

Predictor	B	EE robusto	z	p
Constante	1.4086	0.1564	9.01	< .001
Presión competitiva centrada (c')	0.0265	0.0492	0.54	.590
Conducta innovadora (b)	0.8577	0.0167	51.27	< .001

El modelo explica el 97.32 % de la variación observada en el desempeño innovador ($R^2 = 0.9732$). La conducta innovadora presenta una asociación positiva y significativa: una idea adicional se asocia con un aumento aproximado de 0.858 puntos porcentuales en el porcentaje de ingresos proveniente de productos o servicios nuevos, controlando la presión competitiva. Se apoya H2.

En cambio, el efecto directo residual de la presión competitiva no es significativo, por lo que H3 no recibe apoyo estadístico. Esto sugiere que, una vez incorporada la conducta innovadora de los empleados, la presión competitiva no aporta una explicación adicional estadísticamente distinguible de cero. Sin embargo, la ausencia de significancia de c' no constituye por sí sola la prueba formal de mediación; esta debe establecerse mediante el efecto indirecto bootstrap. La evidencia relevante para evaluar la mediación no proviene de la significancia del efecto

directo, sino del intervalo de confianza bootstrap del efecto indirecto condicional. Por ello, la conclusión principal descansa en los efectos indirectos y en el índice de mediación moderada.

1.3.3. Regresión 3: efecto total

La presión competitiva presenta una asociación total positiva y significativa con el desempeño:

$$c = 2.0281, \quad p < .001.$$

El efecto total resume la asociación entre presión competitiva y desempeño antes de incorporar el mediador. Un punto adicional de presión competitiva se asocia, en promedio, con un aumento de 2.028 puntos porcentuales en el porcentaje de ingresos proveniente de productos o servicios nuevos. La evaluación del mecanismo propuesto se basa, en cambio, en el efecto indirecto condicional y en el índice de mediación moderada.

1.3.4. Efectos indirectos condicionales

Tabla 8: Efectos indirectos según tolerancia al fracaso

Tolerancia	Pendiente condicional $X_c \rightarrow M$	Indirecto	IC95 % inf.	IC95 % sup.
Baja (-1 DE)	1.6029	1.3748	1.2880	1.4620
Media	2.0008	1.7162	1.6227	1.8104
Alta ($+1$ DE)	2.3988	2.0576	1.9319	2.1853

Los tres intervalos excluyen cero, por lo que existe mediación en niveles bajos, medios y altos de tolerancia. Se apoya H4. Además, el efecto indirecto aumenta de 1.3748 a 2.0576 a medida que aumenta la tolerancia.

El índice de mediación moderada es:

$$a_3b = (0.5248)(0.8577) = 0.4502,$$

con IC95 % bootstrap $[0.3758, 0.5184]$. Como el intervalo no contiene cero, el efecto indirecto varía significativamente con la tolerancia al fracaso. Este resultado complementa H4 y H5, mostrando que el mecanismo indirecto es más fuerte cuando aumenta la tolerancia al fracaso.

Tabla 9: Índice de mediación moderada			
Índice	Estimación	IC95 % inf.	IC95 % sup.
a_3b	.4502	.3758	.5184

Tabla 10: Resumen final de hipótesis de la Pregunta 1

Hipótesis	Relación evaluada	Evidencia principal	Decisión
H1	Presión competitiva $\rightarrow$ conducta innovadora	$a_1 = 2.0008, p < .001$	Apoyada
H2	Conducta innovadora $\rightarrow$ desempeño innovador	$b = 0.8577, p < .001$	Apoyada
H3	Efecto directo presión competitiva $\rightarrow$ desempeño	$c' = 0.0265, p = .590$	No apoyada
H4	Efecto indirecto vía conducta innovadora	IC95 % bootstrap sin cero	Apoyada
H5	Moderación de tolerancia al fracaso sobre $X \rightarrow M$	$a_3 = 0.5248, p < .001$	Apoyada

En conjunto, los resultados apoyan H1, H2, H4 y H5. El efecto directo planteado en H3 no recibe apoyo empírico, por lo que la evidencia es consistente con una mediación *indirect-only*.

1.4. c) Interpretación de los resultados

La evidencia permite reconstruir el proceso completo. Primero, la presión competitiva se asocia con mayor conducta innovadora de los empleados. Segundo, dicha conducta se asocia con mayor desempeño innovador. Tercero, este mecanismo es más intenso cuando la cultura organizacional tolera los errores derivados de experimentar.

En términos gerenciales, la presión competitiva por sí sola no garantiza innovación. Para que se asocie con mejores resultados, la organización debe permitir que los empleados experimenten sin un temor excesivo al fracaso. El patrón observado corresponde a una mediación de tipo *indirect-only*: el efecto total de la presión competitiva sobre el desempeño es positivo, pero la asociación directa residual deja de ser significativa una vez incorporada la conducta innovadora.

2. Pregunta 2: análisis factorial exploratorio

2.1. Teoría de Blend y objetivo del AFE

La teoría de Blend sostiene que los buenos profesores de métodos cuantitativos poseen cuatro características latentes: amor por la estadística, entusiasmo por el diseño de experimentos, amor por la enseñanza y ausencia de habilidades interpersonales normales. Dado que estas dimensiones no se observan directamente, deben inferirse a partir del patrón de respuestas a los 28 ítems del cuestionario.

Para evaluar si la estructura propuesta por la teoría de Blend emerge empíricamente, se realizó un análisis factorial exploratorio (AFE). Esta técnica permite determinar cuántos factores latentes están presentes y qué ítems se asocian con cada dimensión.

La teoría no queda confirmada únicamente porque aparezcan cuatro factores. También es necesario que los factores sean interpretables, que los ítems carguen de forma coherente y que las dimensiones presenten confiabilidad razonable.

2.2. Preparación de datos y descriptivos

La base contiene 239 profesores y 28 ítems. Se encontraron nueve respuestas faltantes, equivalentes aproximadamente al 0.13 % del total de respuestas posibles, imputadas mediante la mediana del ítem por tratarse de una proporción mínima y de escalas tipo Likert. Esta decisión conserva el tamaño muestral, pero no incorpora incertidumbre por imputación y puede reducir levemente la variabilidad. El análisis siguió estas etapas: revisión de rangos y faltantes, matriz de correlaciones, Bartlett y KMO, determinación del número de factores, extracción, rotación, interpretación de cargas y confiabilidad.

Tabla 11: Descriptivos generales de los ítems del EECS-R

Indicador descriptivo	Valor
Profesores observados	239
Ítems analizados	28
Rango observado de respuestas	1 a 7
Media global de respuestas	4.705
Desviación estándar global	1.488
Media mínima entre ítems	3.406
Media máxima entre ítems	5.456
DE mínima entre ítems	1.102
DE máxima entre ítems	1.773
Valores faltantes	9

2.3. Adecuación factorial

La prueba de Bartlett evalúa si la matriz de correlaciones poblacional es una identidad:

$$H_0 : \mathbf{R} = \mathbf{I}.$$

El resultado fue:

$$\chi^2(378) = 3045.39, \quad p < .001.$$

Se rechaza H_0 , por lo que las correlaciones contienen estructura común suficiente. El índice KMO global fue 0.895, valor considerado meritorio. En conjunto, ambos resultados justifican continuar con el AFE, aunque no determinan cuántos factores existen ni prueban por sí solos la teoría.

Tabla 12: Adecuación de los datos para análisis factorial

Indicador	Resultado
Observaciones	239
Ítems analizados	28
Valores faltantes	9
Valores faltantes sobre respuestas posibles	0.13 %
Bartlett χ^2	3045.39
Grados de libertad	378
p Bartlett	< .001
KMO global	.895

2.4. Número de factores

La decisión se basó en autovalores, gráfico de sedimentación y análisis paralelo con 1.000 matrices aleatorias. El gráfico de sedimentación muestra los autovalores ordenados de mayor a menor y permite observar el punto donde la curva comienza a aplanarse; desde ese punto, los factores adicionales aportan poca información nueva. El criterio de autovalor mayor que uno se consideró solo como referencia, porque puede sugerir más factores de los realmente respaldados por los datos.

Los primeros cuatro autovalores observados superaron el percentil 95 de los autovalores aleatorios. La decisión del cuarto factor fue ajustada: 1.505 frente a un umbral de 1.501. Este

valor corresponde al percentil 95 del cuarto autovalor obtenido en las 1.000 matrices aleatorias generadas para el análisis paralelo. Por ello se verificó con la media de los autovalores aleatorios, donde el cuarto factor también fue retenido y el quinto quedó claramente por debajo. Por esta razón, el análisis paralelo suele considerarse uno de los criterios más confiables para determinar el número de factores. La decisión no se basa solo en la diferencia numérica, sino también en la teoría previa y en la interpretabilidad de la solución de cuatro factores.

Tabla 13: Análisis paralelo para determinar el número de factores

Factor	Autovalor observado	Media aleatoria	Percentil 95 aleatorio	Decisión
1	9.021	1.694	1.799	Retener
2	2.743	1.590	1.660	Retener
3	1.707	1.511	1.574	Retener
4	1.505	1.445	1.501	Retener
5	1.158	1.385	1.435	Descartar
6	0.976	1.331	1.376	Descartar




Figura 3: Análisis paralelo y gráfico de sedimentación generado desde el notebook de la Pregunta 2. Los cuatro primeros autovalores observados superan la referencia aleatoria; el cuarto lo hace por un margen estrecho respecto del percentil 95 y con mayor holgura respecto de la media aleatoria.

2.5. Extracción, rotación e interpretación

Una vez retenidos cuatro factores, se estimó la solución factorial principal mediante máxima verosimilitud y rotación Oblimin. La elección de máxima verosimilitud se justifica porque la pregunta busca evaluar dimensiones latentes de la teoría de Blend, no solamente reducir los ítems a un conjunto de componentes. En este enfoque, el modelo intenta explicar la varianza común entre los ítems mediante factores latentes y separarla de la varianza específica o de error.

Para transparentar la decisión metodológica, se estimó también la misma solución de cuatro factores con el método principal, manteniendo la misma muestra imputada y la misma rotación Oblimin. El método principal reporta una varianza acumulada mayor, porque reproduce una proporción más alta de la varianza observada de los ítems. Sin embargo, explicar más varianza observada no implica necesariamente representar mejor constructos latentes. Por esta razón, máxima verosimilitud se mantiene como especificación principal, mientras que el método principal se presenta como análisis de sensibilidad.

Tabla 14: Comparación de métodos de extracción con la misma muestra imputada

Método	Rotación	Observaciones	Varianza acumulada 4 factores
Máxima verosimilitud	Oblimin	239	39.05 %
Principal	Oblimin	239	47.82 %

La rotación Oblimin se utilizó porque es una rotación oblicua: permite que los factores se correlacionen entre sí. Esta decisión es coherente con el enunciado, que indica que las cuatro características pueden estar correlacionadas, y con los resultados empíricos, donde las correlaciones entre factores alcanzaron un máximo de 0.471. Por tanto, no se fuerza artificialmente independencia entre dimensiones.

La solución principal con máxima verosimilitud explica 39.05 % de la varianza acumulada. En una rotación oblicua este porcentaje debe interpretarse con cautela, porque los factores pueden correlacionarse y la varianza no se reparte de forma completamente independiente entre dimensiones. Se interpreta la matriz patrón porque representa la contribución específica de cada factor controlando las correlaciones entre ellos. Se consideraron relevantes las cargas factoriales absolutas cercanas o superiores a 0.40. Un ítem se consideró complejo cuando además presentaba una carga secundaria cercana o superior a 0.30, o cuando la diferencia entre sus dos cargas principales era pequeña.

Tabla 15: Varianza explicada por la solución principal de cuatro factores

Factor	Suma de cargas al cuadrado	Varianza explicada	Varianza acumulada
F1	4.322	15.44 %	15.44 %
F2	2.715	9.70 %	25.13 %
F3	2.124	7.59 %	32.72 %
F4	1.773	6.33 %	39.05 %

Tabla 16: Matriz patrón rotada del EECS-R

Ítem	F1	F2	F3	F4	Dimensión dominante
q1	.40	-.14	.28	.34	Complejo
q2	.10	-.33	.36	.27	Habilidades interpersonales deficientes: carga débil
q3	.12	.29	-.05	.51	Estadística
q4	.12	.17	.14	.51	Estadística
q5	.06	.05	.67	-.13	Habilidades interpersonales deficientes
q6	.16	-.35	.16	.26	Ítem débil; carga máxima en F2; asignación teórica a habilidades interpersonales deficientes
q7	.14	.45	-.05	.30	Enseñanza
q8	.58	.22	.04	.24	Diseño experimental
q9	.44	-.11	.26	.37	Complejo
q10	.42	-.07	.18	.04	Diseño experimental; asignación teórica a enseñanza
q11	.27	.46	.20	.10	Enseñanza
q12	-.01	.13	.27	-.16	Ítem débil (sin carga factorial relevante)
q13	.56	.08	-.03	.21	Diseño experimental

Ítem	F1	F2	F3	F4	Dimensión dominante
q14	.76	.03	.18	-.34	Diseño experimental
q15	.36	-.02	.14	.18	Débil
q16	.74	.22	-.02	-.20	Diseño experimental
q17	.79	-.01	-.03	.14	Diseño experimental
q18	.23	-.32	.40	.14	Habilidades interpersonales deficientes
q19	-.05	.57	-.18	.08	Enseñanza
q20	.04	.45	.05	.20	Enseñanza
q21	.47	.17	-.04	.27	Diseño experimental; asignación teórica a estadística
q22	.86	-.07	-.02	.11	Diseño experimental
q23	-.09	.04	.70	.07	Habilidades interpersonales deficientes
q24	.10	.28	.13	.48	Estadística
q25	.10	.53	.13	.08	Enseñanza
q26	.28	.59	.02	-.07	Enseñanza
q27	-.02	.61	.38	.07	Complejo
q28	.01	.21	.53	-.02	Habilidades interpersonales deficientes

El primer factor está definido principalmente por q8, q10, q13, q14, q16, q17, q21 y q22 y representa entusiasmo por el diseño de experimentos. El segundo factor, definido por q7, q11, q19, q20, q25, q26 y q27, representa amor por la enseñanza. El tercero, asociado principalmente con q5, q18, q23 y q28, refleja habilidades interpersonales deficientes, dimensión denominada en el enunciado como ausencia de habilidades interpersonales normales. El cuarto, definido por q3, q4 y q24, representa amor por la estadística.

La estructura general es interpretable, pero no perfecta. q1, q9 y q27 muestran complejidad o cargas cruzadas; q10 y q21 presentan discrepancias entre su asignación teórica y su patrón empírico de cargas; q14 y q18 presentan cargas secundarias relevantes; q12 no alcanza 0.40 en ningún factor; y q15 también es débil. Una carga cruzada reduce la pureza conceptual

de la escala, porque el ítem parece recoger contenido de más de una dimensión. En q12, el problema es aún más claro: no se vincula claramente con ninguno de los factores y sería el candidato más evidente a revisión o eliminación.

La correlación factorial más alta fue cercana a 0.47 entre F1 y F3. Esto confirma que los factores se relacionan, pero no son equivalentes, y respalda el uso de una rotación oblicua.

Tabla 17: Diagnóstico de ítems en la solución factorial

Criterio diagnóstico	Ítems identificados
Carga primaria menor a .40	q2, q6, q12, q15
Comunalidad menor a .30	q6, q10, q12, q15, q20
Patrón ambiguo o cargas próximas en más de un factor	q1, q2, q9, q14, q18, q27
Discrepancia teoría-cargas	q10 y q21

Tabla 18: Correlaciones entre factores rotados

	F1	F2	F3	F4
F1	1.000	.299	.471	.370
F2	.299	1.000	.130	.129
F3	.471	.130	1.000	.252
F4	.370	.129	.252	1.000

2.6. Confiabilidad de las subescalas teóricas

La confiabilidad se calculó manteniendo la asignación teórica original de los ítems: diseño experimental (q8, q13, q14, q16, q17 y q22); enseñanza (q7, q10, q11, q19, q20, q25 y q26); habilidades interpersonales deficientes (q2, q5, q6, q12, q18, q23, q27 y q28); y estadística (q1, q3, q4, q9, q15, q21 y q24). Esta composición no reasigna automáticamente cada indicador según su mayor carga empírica.

Tabla 19: Confiabilidad de las subescalas teóricas originales

Dimensión	Alfa de Cronbach
Diseño experimental	0.880
Estadística	0.830
Enseñanza	0.747
Habilidades interpersonales deficientes	0.691

Estos alfas corresponden a las subescalas teóricas originales usadas para organizar los ítems, no automáticamente a la confiabilidad pura de cada factor empírico rotado. Diseño expe-

rimental y estadística presentan confiabilidad alta; enseñanza, confiabilidad adecuada; y la dimensión de habilidades interpersonales deficientes, consistencia más baja y cercana al umbral de 0.70. Esta menor confiabilidad es coherente con la presencia de ítems débiles y heterogeneidad de contenido. No se observaron correlaciones ítem-total negativas, por lo que el problema no parece provenir de ítems invertidos mal codificados.

El alfa no demuestra unidimensionalidad. Debe interpretarse junto con la estructura factorial, las cargas cruzadas y la coherencia conceptual.

2.7. Conclusión de la pregunta 2

La evidencia ofrece apoyo general, aunque no completo, a la estructura de cuatro dimensiones propuesta por la teoría de Blend. La matriz es factorizable, el análisis paralelo favorece una solución de cuatro factores y el contenido de estos puede interpretarse como diseño experimental, enseñanza, habilidades interpersonales deficientes y estadística.

No obstante, el apoyo no es perfecto a nivel de ítems. q1, q9 y q27 son complejos; q10 y q21 presentan discrepancias entre su asignación teórica y su patrón empírico de cargas; q12 no presenta una carga factorial relevante y q15 es débil; y la dimensión de habilidades interpersonales deficientes presenta menor consistencia. Por tanto, el EECS-R reproduce las cuatro dimensiones principales, pero sería recomendable revisar los ítems problemáticos y validar una versión depurada mediante CFA en una muestra independiente.

2.8. Apéndice de sensibilidad: especificaciones alternativas sin ID

Como verificación adicional, se estimaron dos especificaciones alternativas usando solamente los 28 ítems del cuestionario, sin incluir la variable administrativa ID. La primera usa el método principal con eliminación listwise y rotación Oblimin; la segunda usa residuos mínimos con eliminación listwise y rotación Varimax.

Tabla 20: Especificaciones alternativas de sensibilidad sin ID

Criterio	Principal + Oblimin	Minres + Varimax
Variables incluidas	28 ítems	28 ítems
Variable ID incluida	No	No
Tratamiento de faltantes	Eliminación listwise	Eliminación listwise
Observaciones usadas	231	231
Método de extracción	Principal	Minres
Rotación	Oblimin	Varimax
Varianza acumulada de la solución de 4 factores	47.88 %	46.23 %

La alternativa con método principal y eliminación listwise alcanza 47.88 %, muy cerca del 47.82 % obtenido con método principal e imputación por mediana. Por tanto, la diferencia frente al 39.05 % del análisis principal se debe principalmente al método de extracción y no al tratamiento de los valores faltantes. La alternativa Varimax también produce una solución interpretable, pero no se adopta como referencia porque fuerza factores no correlacionados.

La variable ID se excluye en todos los análisis porque no es un ítem del EECS-R, no mide ningún rasgo latente y su inclusión alteraría artificialmente KMO, Bartlett, autovalores y cargas factoriales.

3. Pregunta 3: CFA y ecuaciones estructurales

3.1. Justificación conceptual del análisis

El objetivo es analizar cómo las condiciones laborales percibidas por los trabajadores se relacionan con su satisfacción, compromiso organizacional e intención de permanecer en la empresa. Se consideran cinco constructos latentes: actitud hacia compañeros, percepción del ambiente de trabajo, satisfacción laboral, compromiso organizacional e intención de permanencia. Como cada constructo fue medido mediante cuatro ítems observados, primero se evalúa el modelo de medición y luego se comparan los modelos estructurales propuestos.

Los análisis se realizaron con `lavaan` en R. Primero se estimó un análisis factorial confirmatorio (CFA, por sus siglas en inglés) para evaluar si los ítems representan adecuadamente sus constructos. Luego se estimaron modelos de ecuaciones estructurales (SEM) para analizar simultáneamente las relaciones entre constructos latentes, considerando el error de medición. La estimación principal se realizó con máxima verosimilitud robusta (MLR) y máxima verosimilitud con información completa (FIML). MLR entrega errores estándar y pruebas robustas frente a desviaciones de normalidad; FIML permite utilizar toda la información disponible. En esta base no hubo valores perdidos en las variables de la Pregunta 3.

La respuesta sigue cuatro pasos: primero se evalúa el modelo de medición mediante CFA; segundo, se revisa confiabilidad y validez; tercero, se comparan los modelos estructurales del enunciado; y cuarto, se analiza si el modelo funciona de manera comparable entre hombres y mujeres.

3.2. Constructos e indicadores

Tabla 21: Constructos e indicadores del modelo

Constructo	Símbolo	Indicadores
Actitud hacia compañeros	AC	AC1, AC2, AC3, AC4
Percepción del ambiente	PA	PA1, PA2, PA3, PA4
Satisfacción laboral	ST	ST1, ST2, ST3, ST4
Compromiso organizacional	CO	CO1, CO2, CO3, CO4
Intención de permanecer	IP	IP1, IP2, IP3, IP4

La base contiene 400 trabajadores: 200 hombres y 200 mujeres. La variable género está codificada como 0 = masculino y 1 = femenino. Cada constructo se especifica de manera reflectiva.

Constructos	Ítems*
Actitud hacia compañeros de trabajo	AC1 - ¿Cuán contento está con el trabajo de sus compañeros?
	AC2 - ¿Cómo se siente en su relación respecto a sus compañeros de trabajo?
	AC3 - ¿Qué tan seguido realiza actividades con sus compañeros de trabajo en días libres?
	AC4 - En general, ¿qué tan parecidos a Ud. son sus compañeros de trabajo?
Compromiso organizacional	CO1 - Mi trabajo en esta empresa me da una sensación de logros.
	CO2 - Estoy dispuesto a poner un gran esfuerzo mas allá de lo que se esperaría normalmente para ayudar a que esta empresa sea exitosa
	CO3 - Tengo un sentido de lealtad con esta empresa.
	CO4 - Estoy orgulloso de contarle a otras personas que trabajo en esta empresa.
Intención de permanecer en el trabajo	IP1 - No estoy buscando activamente otro trabajo.
	IP2 - Rara vez veo las ofertas de trabajo en sitios para esos fines.
	IP3 - No tengo interés en buscar trabajo durante los próximos 12 meses.
	IP4 - ¿Qué tan probable es que usted este trabajando para la misma empresa dentro de los próximos 12 meses?
Percepción del ambiente de trabajo	PA1 - Estoy muy conforme con el ambiente físico de trabajo en esta empresa.
	PA2 - El lugar en que trabajo está diseñado para facilitar mi trabajo.
	PA3 - Hay pocos obstáculos que me hacen ser menos productivo en mi lugar de trabajo.
	PA4 - ¿Qué término describe mejor el ambiente de trabajo en su empresa?
Satisfacción con el trabajo	ST1 - Considerando todas las cosas, me siento muy satisfecho cuando pienso en mi trabajo.
	ST2 - Cuando piensa en su trabajo, ¿qué tan satisfecho se siente?
	ST3 - ¿Que tan satisfecho está con su actual trabajo?
	ST4 - Como empleado, ¿qué tan satisfecho esta con su empleador?
Características personales	D1 - Género
	Edad
	EXP - Experiencia en años

* Las escalas específicas de cada ítem se encuentran detalladas en el archivo de datos **Laboral.sav**

Figura 4: Constructos e ítems del cuestionario según el enunciado de la Pregunta 3.

3.3. Especificación de los modelos estructurales

Las figuras del enunciado establecen que PA y AC se asocian con ST y CO; además, ST se asocia con CO, y ST y CO se asocian con IP. La diferencia entre los modelos consiste únicamente en que el modelo parcialmente mediado agrega los efectos directos de PA y AC sobre IP.

Modelo 1 (Completamente Mediado)




Figura 5: Modelo estructural completamente mediado presentado en el enunciado de la Pregunta 3.

Modelo 1 (Parcialmente Mediado)




Figura 6: Modelo estructural parcialmente mediado presentado en el enunciado de la Pregunta 3. El modelo parcial agrega caminos directos desde percepción del ambiente y actitud hacia compañeros hacia intención de permanecer.

3.3.1. Modelo completamente mediado

$$ST = \beta_1 PA + \beta_2 AC + \varepsilon_{ST}, \quad (5)$$

$$CO = \beta_3 PA + \beta_4 AC + \beta_5 ST + \varepsilon_{CO}, \quad (6)$$

$$IP = \beta_6 ST + \beta_7 CO + \varepsilon_{IP}. \quad (7)$$

En este modelo, PA y AC no poseen caminos directos hacia IP; sus asociaciones con la intención de permanecer deben transmitirse a través de ST y CO.

3.3.2. Modelo parcialmente mediado

El modelo parcial conserva las dos primeras ecuaciones y amplía la ecuación de permanencia:

$$IP = \beta_6 ST + \beta_7 CO + \beta_8 PA + \beta_9 AC + \varepsilon_{IP}. \quad (8)$$

Por tanto, permite que PA y AC se relacionen con la intención de permanecer tanto indirectamente, por medio de ST y CO, como directamente. Los modelos son anidados: el completo se obtiene al fijar $\beta_8 = \beta_9 = 0$.

3.4. a) Evaluación del modelo de medición

3.4.1. Ajuste global del CFA

Tabla 22: Confiabilidad alfa de Cronbach por constructo

Constructo	Alfa de Cronbach
Actitud hacia compañeros de trabajo (AC)	.891
Percepción del ambiente de trabajo (PA)	.847
Satisfacción con el trabajo (ST)	.811
Compromiso organizacional (CO)	.823
Intención de permanecer (IP)	.886

El CFA de cinco factores correlacionados presentó un ajuste muy bueno. El ajuste se evaluó mediante el índice de ajuste comparativo (CFI), el índice Tucker–Lewis (TLI), el error cuadrático medio de aproximación (RMSEA) y el residuo cuadrático medio estandarizado (SRMR). Los índices robustos estimados con **lavaan** fueron:

$$\chi^2_{rob}(160) = 216.90, \quad CFI_{rob} = .987, \quad TLI_{rob} = .985, \\ RMSEA_{rob} = .028, \quad SRMR = .033.$$

El CFI y el TLI superan .95, el RMSEA es inferior a .06 y el SRMR es bajo. Por tanto, la estructura de cinco factores reproduce adecuadamente la matriz de covarianzas observada.

Tabla 23: Ajuste global del CFA de cinco factores

Modelo	χ^2_{rob}	gl	p	CFI_{rob}	TLI_{rob}	$RMSEA_{rob}$	SRMR	BIC
CFA cinco factores	216.90	160	.002	.987	.985	.028	.033	24926.95

Tabla 24: Cargas factoriales estandarizadas del CFA

Constructo	Ítem	Carga	Constructo	Ítem	Carga
AC	AC1	.822	ST	ST1	.737
AC	AC2	.820	ST	ST2	.737
AC	AC3	.837	ST	ST3	.697
AC	AC4	.815	ST	ST4	.709
PA	PA1	.692	CO	CO1	.583
PA	PA2	.804	CO	CO2	.886
PA	PA3	.778	CO	CO3	.657
PA	PA4	.823	CO	CO4	.836
IP	IP1	.811	IP	IP2	.864
IP	IP3	.741	IP	IP4	.852

Las cargas estandarizadas oscilan entre .583 y .886. La mayoría supera .70. La carga más baja corresponde a CO1, pero sigue siendo relevante y no justifica eliminar el indicador, especialmente porque la escala completa conserva buena confiabilidad.

3.4.2. Confiabilidad y validez convergente

La confiabilidad se evaluó mediante alfa de Cronbach y confiabilidad compuesta (CR, *composite reliability*). La validez convergente se evaluó mediante varianza media extraída (AVE, *average variance extracted*):

$$CR = \frac{(\sum_i \lambda_i)^2}{(\sum_i \lambda_i)^2 + \sum_i \theta_i}, \quad AVE = \frac{\sum_i \lambda_i^2}{\sum_i \lambda_i^2 + \sum_i \theta_i}. \quad (9)$$

Tabla 25: Confiabilidad y validez convergente

Constructo	Alfa	CR	AVE	$\sqrt{AVE}$	Carga mín.	Carga máx.
AC	.891	.894	.679	.824	.815	.837
PA	.847	.858	.602	.776	.692	.823
ST	.811	.812	.519	.720	.697	.737
CO	.823	.834	.564	.751	.583	.886
IP	.886	.890	.670	.818	.741	.864

Todos los valores de alfa y CR son superiores a .70, por lo que existe consistencia interna adecuada. Todas las AVE superan .50, indicando que cada constructo explica más de la mitad de la varianza de sus indicadores.

3.4.3. Validez discriminante

La correlación latente más alta fue $r_{PA,IP} = .562$, inferior a la menor raíz de AVE, correspondiente a ST ($\sqrt{AVE} = .720$). Por tanto, se cumple el criterio de Fornell–Larcker. Además, se calculó la razón heterotrait–monotrait (HTMT), un criterio adicional de validez discriminante. HTMT compara las correlaciones entre constructos distintos con las correlaciones dentro de un mismo constructo; el HTMT máximo fue .569, claramente inferior al umbral conservador de .85.

Tabla 26: Matriz de Fornell–Larcker

	AC	PA	ST	CO	IP
AC	.824	.257	.025	.307	.308
PA	.257	.776	.228	.497	.562
ST	.025	.228	.720	.190	.214
CO	.307	.497	.190	.751	.553
IP	.308	.562	.214	.553	.818

Tabla 27: Razones HTMT entre constructos

	AC	PA	ST	CO	IP
AC	1.000	.260	.044	.275	.310
PA	.260	1.000	.231	.495	.569
ST	.044	.231	1.000	.193	.217
CO	.275	.495	.193	1.000	.501
IP	.310	.569	.217	.501	1.000

En consecuencia, los constructos están relacionados, pero no son empíricamente redundantes. El modelo de medición presenta confiabilidad, validez convergente y validez discriminante adecuadas, por lo que resulta razonable continuar con el análisis estructural.

3.5. b) Selección del modelo estructural superior

La comparación evalúa si los caminos directos $PA \rightarrow IP$ y $AC \rightarrow IP$ pueden fijarse simultáneamente en cero. Las hipótesis son:

$$H_0 : \beta_8 = \beta_9 = 0, \quad H_1 : \text{al menos uno de los dos caminos es distinto de cero.}$$

Tabla 28: Comparación de los modelos estructurales en lavaan

Modelo	χ^2_{rob}	gl	CFI _{rob}	TLI _{rob}	RMSEA _{rob}	SRMR	AIC	BIC
Completamente mediado	260.86	162	.976	.972	.038	.058	24690.37	24961.79
Parcialmente mediado	216.90	160	.987	.985	.028	.033	24647.54	24926.95

Con MLR, la comparación entre modelos anidados debe hacerse mediante una prueba robusta de diferencia, no restando manualmente los chi-cuadrados. La prueba robusta de Satorra-Bentler entregó:

$$\Delta\chi^2_{SB}(2) = 31.12, \quad p < .001.$$

Tabla 29: Prueba robusta de diferencia entre modelos estructurales

Comparación	$\Delta\chi^2_{SB}$	Δgl	p	Decisión
Completo vs. parcialmente mediado	31.12	2	< .001	Favorece modelo parcial

Se rechaza H_0 : imponer simultáneamente que PA y AC no tengan caminos directos hacia IP deteriora significativamente el ajuste. Además, AIC y BIC, obtenidos directamente desde `lavaan`, son menores en el modelo parcialmente mediado. Por tanto, se selecciona el modelo parcialmente mediado como mejor representación de la estructura de covarianzas observada.

El excelente ajuste del modelo parcial debe interpretarse con prudencia. El modelo parcialmente mediado incorpora suficientes caminos para reproducir prácticamente toda la estructura de covarianzas entre las variables latentes; por ello, su ajuste global coincide con el del

CFA. La comparación no demuestra causalidad; solo indica que las restricciones adicionales del modelo completamente mediado no son compatibles con los datos.

3.5.1. Coeficientes estructurales del modelo seleccionado

Tabla 30: Coeficientes del modelo parcialmente mediado

Relación	B	β est.	z	p
$PA \rightarrow ST$	.244	.237	4.177	< .001
$AC \rightarrow ST$	-.036	-.036	-.610	.542
$PA \rightarrow CO$	.507	.427	5.554	< .001
$AC \rightarrow CO$	.231	.195	3.828	< .001
$ST \rightarrow CO$	.101	.087	1.582	.114
$PA \rightarrow IP$	.469	.354	4.360	< .001
$AC \rightarrow IP$	.152	.115	2.333	.020
$ST \rightarrow IP$	.087	.068	1.607	.108
$CO \rightarrow IP$	.367	.329	4.185	< .001

Primera ecuación: satisfacción laboral. PA se asocia positiva y significativamente con ST ($B = .244$, $\beta = .237$, $p < .001$). En cambio, AC no presenta una asociación adicional significativa con ST una vez controlada PA ($p = .542$).

Segunda ecuación: compromiso organizacional. PA se asocia positivamente con CO ($B = .507$, $\beta = .427$, $p < .001$) y AC también se asocia positivamente con CO ($B = .231$, $\beta = .195$, $p < .001$). ST no presenta una asociación adicional significativa con CO dentro de esta ecuación ($p = .114$).

Tercera ecuación: intención de permanecer. PA conserva una asociación directa positiva con IP ($B = .469$, $\beta = .354$, $p < .001$), CO también se asocia positivamente con IP ($B = .367$, $\beta = .329$, $p < .001$), y AC presenta una asociación directa menor pero significativa ($B = .152$, $\beta = .115$, $p = .020$). ST no presenta una asociación adicional significativa con IP ($p = .108$).

3.5.2. Efectos indirectos bootstrap

Los efectos indirectos se estimaron en un modelo separado con ML y bootstrap de 5.000 remuestras, porque lavaan no combina directamente MLR con bootstrap convencional. La interpretación de mediación se basa en si el intervalo de confianza bootstrap incluye o no el cero.

Tabla 31: Efectos indirectos bootstrap hacia intención de permanecer

Efecto indirecto	Estimación	EE boot.	IC 95 % inf.	IC 95 % sup.
$PA \rightarrow ST \rightarrow IP$	.021	.015	-.004	.055
$PA \rightarrow CO \rightarrow IP$	.186	.049	.104	.291
$PA \rightarrow ST \rightarrow CO \rightarrow IP$	.009	.007	-.002	.025
Indirecto total de PA	.216	.053	.127	.329
$AC \rightarrow ST \rightarrow IP$	-.003	.006	-.019	.008
$AC \rightarrow CO \rightarrow IP$	.085	.035	.029	.166
$AC \rightarrow ST \rightarrow CO \rightarrow IP$	-.001	.003	-.008	.004
Indirecto total de AC	.080	.036	.022	.163

Los resultados muestran apoyo para los efectos indirectos que pasan por compromiso organizacional. En particular, $PA \rightarrow CO \rightarrow IP$ y $AC \rightarrow CO \rightarrow IP$ tienen intervalos que no incluyen cero. En cambio, los mecanismos que pasan por satisfacción laboral no reciben apoyo bootstrap. Por tanto, la evidencia de mediación se concentra en el compromiso organizacional, no en satisfacción laboral.

3.6. c) Comparación entre hombres y mujeres

Para evaluar si las relaciones se comportan igual entre hombres y mujeres, se estimó el modelo parcialmente mediado mediante SEM multigrupo. Primero se evaluó la misma estructura general en ambos grupos, luego la igualdad de cargas factoriales, después la igualdad de interceptos y, finalmente, la igualdad de los caminos estructurales.

Tabla 32: Pruebas de invariancia multigrupo por género en lavaan

Modelo	χ^2_{rob}	gl	CFI _{rob}	TLI _{rob}	RMSEA _{rob}	SRMR	$\Delta\chi^2_{SB}$	Δgl	p	ΔCFI
Configural	413.28	320	.980	.976	.033	.047	—	—	—	—
Métrica completa	464.08	335	.969	.964	.040	.060	42.28	15	< .001	-.011
Métrica parcial: carga de CO3 libre	445.41	334	.974	.970	.037	.056	30.97	14	.006	-.006
Escalar: interceptos iguales y carga de CO3 libre	501.40	349	.962	.959	.043	.061	71.27	15	< .001	-.012
Caminos estructurales iguales sobre métrica parcial	475.99	343	.968	.965	.040	.074	25.78	9	.002	-.006

Nota: la métrica completa y la métrica parcial se comparan contra el modelo configural. El modelo escalar y el modelo de caminos estructurales iguales se comparan contra la métrica parcial. En los modelos posteriores se mantiene libre la carga factorial de CO3.

El modelo configural presenta buen ajuste, por lo que la estructura general es plausible en hombres y mujeres. La invariancia métrica completa queda levemente fuera del criterio práctico ($\Delta CFI = -.011$). Se realizó una inspección secuencial de restricciones de cargas

factoriales, liberando una carga a la vez; la mayor mejora correspondió a permitir que la carga factorial de CO3 difiriera entre hombres y mujeres. Con esa liberación se obtiene invariancia métrica parcial ($\Delta CFI = -.006$), suficiente para comparar los caminos estructurales.

El modelo escalar construido sobre la solución métrica parcial no cumple plenamente el criterio adoptado ($\Delta CFI = -.012$). Por tanto, no se realizaron comparaciones de medias latentes entre hombres y mujeres. Esto no invalida la comparación de caminos, porque para comparar relaciones estructurales la condición central es contar con invariancia métrica, completa o parcial.

La igualdad exacta de todos los caminos estructurales es rechazada por la prueba robusta de diferencia de χ^2 ($p = .002$). Sin embargo, el deterioro práctico global es pequeño según CFI ($\Delta CFI = -.006$), por debajo del umbral de .010. Por ello, se concluye invariancia estructural aproximada: globalmente, las relaciones estructurales pueden interpretarse de manera comparable entre hombres y mujeres, aunque conviene revisar contrastes específicos.

Tabla 33: Coeficientes estructurales por género en el modelo multigrupo

Relación	Hombres (B)	Hombres (β)	p_H	Mujeres (B)	Mujeres (β)	p_M
$PA \rightarrow ST$	.237	.221	.005	.249	.238	.002
$AC \rightarrow ST$	.257	.239	.004	-.187	-.179	.051
$PA \rightarrow CO$	.523	.408	< .001	.625	.502	< .001
$AC \rightarrow CO$	.475	.371	< .001	.325	.261	.001
$ST \rightarrow CO$	.052	.044	.512	.075	.063	.443
$PA \rightarrow IP$	.556	.391	< .001	.222	.192	.043
$AC \rightarrow IP$	.004	.003	.969	-.009	-.008	.934
$ST \rightarrow IP$	.024	.018	.756	.141	.128	.072
$CO \rightarrow IP$	.467	.421	.001	.303	.328	.002

La asociación $AC \rightarrow IP$ es positiva y significativa en la muestra completa, pero no aparece significativa cuando el modelo se estima por separado en hombres y mujeres. Esto no proviene de caminos distintos ni de una extracción de otro modelo: el modelo multigrupo usa la misma especificación de nueve caminos y en ambos casos se reportan coeficientes no estandarizados. La discrepancia entre la estimación agrupada y las estimaciones por género requiere cautela, por lo que este camino se interpreta como una asociación débil que no se reproduce claramente dentro de cada grupo.

Tabla 34: Diferencias específicas de caminos estructurales por género

Relación	Hombres (B)	Mujeres (B)	Diferencia de B	z	p
$PA \rightarrow ST$	.237	.249	-.012	-.103	.918
$AC \rightarrow ST$	.257	-.187	.444	3.390	.001
$PA \rightarrow CO$	.523	.625	-.103	-.541	.589
$AC \rightarrow CO$	.475	.325	.150	1.210	.226
$ST \rightarrow CO$	.052	.075	-.023	-.181	.856
$PA \rightarrow IP$	.556	.222	.335	1.762	.078
$AC \rightarrow IP$	.004	-.009	.013	.087	.931
$ST \rightarrow IP$	.024	.141	-.117	-1.056	.291
$CO \rightarrow IP$	.467	.303	.163	.958	.338

La comparación directa de coeficientes muestra una diferencia específica clara en $AC \rightarrow ST$ ($p = .001$): en hombres la asociación es positiva, mientras que en mujeres es negativa y la diferencia entre ambos coeficientes es estadísticamente significativa. La diferencia $PA \rightarrow IP$ es más débil ($p = .078$) y no debe interpretarse como evidencia fuerte de diferencia entre grupos. Por tanto, la conclusión más prudente es que el modelo presenta comparabilidad estructural aproximada, con una posible diferencia localizada en la relación entre actitud hacia compañeros y satisfacción laboral.

3.7. d) Interpretación y conclusión de la pregunta 3

El modelo de medición es sólido: el CFA estimado con `lavaan` presenta muy buen ajuste, todas las escalas poseen confiabilidad adecuada y se cumple la validez convergente y discriminante. Esto permite interpretar las relaciones estructurales con una base de medición razonablemente confiable.

El modelo parcialmente mediado representa mejor los datos que el completamente mediado. La comparación robusta indica que fijar en cero los caminos directos $PA \rightarrow IP$ y $AC \rightarrow IP$ deteriora significativamente el ajuste. Por tanto, las condiciones laborales no se asocian con la intención de permanecer únicamente a través de satisfacción y compromiso, sino también mediante relaciones directas.

En la especificación seleccionada, la percepción del ambiente laboral aparece como el antecedente más consistente: se asocia positivamente con satisfacción laboral, compromiso organizacional e intención de permanecer. La actitud hacia compañeros se asocia principalmente

con compromiso organizacional y, en menor medida, con intención de permanecer. El compromiso organizacional constituye un predictor directo importante de la intención de continuar en la empresa.

Los efectos indirectos bootstrap muestran que los mecanismos de mediación apoyados son los que pasan por compromiso organizacional. En cambio, los mecanismos que pasan por satisfacción laboral no reciben apoyo, porque sus intervalos de confianza incluyen cero. Por ello, no corresponde interpretar el modelo como una cadena simple $ST \rightarrow CO \rightarrow IP$.

El análisis por género muestra invariancia métrica parcial, manteniendo libre la carga de CO3, y no permite comparar medias latentes porque no se alcanzó invariancia escalar. Respecto de los caminos estructurales, existe invariancia estructural aproximada: la igualdad exacta es rechazada por χ^2 , pero el deterioro práctico global es pequeño según ΔCFI . La única diferencia específica claramente detectable aparece en el camino $AC \rightarrow ST$.

En conjunto, la evidencia respalda el modelo parcialmente mediado como la mejor representación de los datos. La permanencia laboral se asocia principalmente con percepción del ambiente, actitud hacia compañeros y compromiso organizacional; además, el compromiso organizacional es el mecanismo indirecto más consistente hacia la intención de permanecer.

4. Pregunta 4: MANOVA factorial

4.1. Justificación conceptual

HBAT evalúa la lealtad mediante tres resultados relacionados: satisfacción, intención de recomendar e intención de recomprar. En lugar de reducir estas respuestas a una sola puntuación, se analizan conjuntamente porque representan dimensiones vinculadas de una misma evaluación del cliente. Aplicar tres ANOVA independientes desde el inicio aumentaría el riesgo de error tipo I e ignoraría la correlación entre las variables. Por ello, MANOVA es el procedimiento adecuado para evaluar si distribución y tamaño se asocian con el perfil conjunto de lealtad.

El diseño es factorial 2×2 porque combina dos factores categóricos: distribución (directa/indirecta) y tamaño (pequeña/grande). Además de los efectos principales, la interacción es central: si resulta significativa, la asociación del canal con la lealtad no es uniforme, sino que cambia según el tamaño del cliente.

4.2. Diseño factorial, estrategia analítica e hipótesis

Para cada resultado, el modelo general es:

$$Y_{ijk} = \mu + \alpha_i + \beta_j + (\alpha\beta)_{ij} + \varepsilon_{ijk},$$

pero en MANOVA la variable dependiente es el vector:

$$\mathbf{Y} = \begin{bmatrix} \text{Satisfacción} \\ \text{Recomendación} \\ \text{Recompra} \end{bmatrix}.$$

Las hipótesis son:

- H_{01} : el tipo de distribución no se asocia conjuntamente con la lealtad.
- H_{02} : el tamaño no se asocia conjuntamente con la lealtad.
- H_{03} : no existe interacción distribución $\times$ tamaño.

La distribución de la muestra por celda se reporta en la Tabla 35.

La estrategia analítica es secuencial: primero se revisan descriptivos y supuestos; luego se

estima el MANOVA factorial para evaluar los efectos conjuntos; después se analizan ANOVA univariados y tamaños de efecto; finalmente se interpretan las medias por celda, la interacción y los efectos simples.

Tabla 35: Distribución de la muestra por tipo de distribución y tamaño

Tamaño	Indirecta	Directa	Total
Pequeña	45	53	98
Grande	63	39	102
Total	108	92	200

Tabla 36: Estadísticos descriptivos generales de lealtad

Variable	<i>N</i>	Media	DE	Mín.	Mediana	Máy.
Satisfacción	200	6.952	1.241	4.700	7.050	9.900
Recomendación	200	6.952	1.083	4.000	7.000	9.900
Recomp. media	200	7.665	0.893	4.300	7.600	9.900

Tabla 37: Medias por tamaño de empresa

Tamaño	Sat. media	Sat. DE	Rec. media	Rec. DE	Recomp. media	Recomp. DE
Pequeña	6.707	1.085	6.626	1.004	7.428	0.823
Grande	7.187	1.338	7.267	1.067	7.893	0.902

Tabla 38: Medias por tipo de distribución

Distribución	Sat. media	Sat. DE	Rec. media	Rec. DE	Recomp. media	Recomp. DE
Indirecta	6.325	1.033	6.488	0.986	7.336	0.880
Directa	7.688	1.049	7.498	0.930	8.051	0.745

4.3. Consistencia y supuestos

Las tres variables de lealtad presentan $\alpha = 0.876$ y correlaciones entre 0.66 y 0.76. Este alfa se reporta solo como descripción de consistencia conjunta; no implica que las tres variables formen una escala unidimensional ni constituye un supuesto del MANOVA. Las variables están suficientemente relacionadas para analizarlas conjuntamente, pero no son redundantes.

Tabla 39: Correlaciones entre variables dependientes

	Satisfacción	Recomendación	Recompra
Satisfacción	1.000	.762	.726
Recomendación	.762	1.000	.661
Recompra	.726	.661	1.000

Box M no fue significativo:

$$\chi^2(18) = 27.55, \quad p = .069,$$

por lo que no existe evidencia suficiente para rechazar la igualdad de matrices de covarianza; esto no prueba igualdad perfecta. Levene fue significativo para satisfacción y compra, pero no para recomendación. Esto exige cautela en los ANOVA univariados, aunque no invalida automáticamente el MANOVA debido al balance razonable de las celdas y al resultado favorable de Box M .

Las pruebas univariadas globales se presentan como diagnóstico descriptivo. El supuesto del modelo se refiere principalmente a la distribución de los residuos o de las observaciones dentro de las celdas, por lo que estos resultados no se interpretan de forma aislada. Como diagnóstico adicional, la normalidad multivariada se evaluó mediante Mardia. La asimetría multivariada no fue significativa ($\chi^2(10) = 10.96$, $p = .360$) y la curtosis tampoco mostró desviación relevante ($z = -0.696$, $p = .486$). El máximo de Mahalanobis fue 17.54, levemente superior al punto de corte $\chi^2_{.999,3} = 16.27$, identificando un caso potencialmente extremo. Dado que se trata de un solo caso y el MANOVA se interpreta principalmente con Pillai, se mantuvo la muestra completa.

Tabla 40: Normalidad univariada y diagnóstico multivariado

Variable / diagnóstico	Asimetría	Curtosis	Estadístico	p
Satisfacción (Shapiro)	.090	-.769	.976	.001
Recomendación (Shapiro)	.070	-.226	.995	.710
Recompra (Shapiro)	-.206	.584	.990	.171
Mardia asimetría multivariada	—	—	10.96	.360
Mardia curtosis multivariada	—	—	-0.696	.486

Tabla 41: Homogeneidad de varianzas y covarianzas

Prueba	Estadístico	gl	p
Box M (aprox. χ^2)	27.55	18	.069
Levene satisfacción	4.933	3,196	.003
Levene recomendación	1.720	3,196	.164
Levene recompra	4.553	3,196	.004

4.4. MANOVA

Dado que dos de las tres variables dependientes presentaron evidencia de heterogeneidad de varianzas, la interpretación principal se basó en la traza de Pillai, considerada uno de los estadísticos multivariados más robustos ante incumplimientos moderados de los supuestos. En este diseño, cada efecto tiene un grado de libertad en el numerador, por lo que Pillai, Wilks, Hotelling y Roy entregan la misma decisión inferencial. Valores mayores de Pillai indican mayor separación multivariada entre grupos.

Tabla 42: Efectos multivariados sobre lealtad

Efecto	Pillai V	F	gl_1	gl_2	p
Distribución	.1474	11.184	3	194	< .001
Tamaño	.0972	6.959	3	194	< .001
Distribución $\times$ Tamaño	.0966	6.917	3	194	< .001

Se rechazan las tres hipótesis nulas. El canal se asocia con el perfil conjunto de lealtad, el tamaño también y, además, existe una interacción significativa. Por tanto, ambos factores presentan un efecto conjunto significativo sobre la lealtad y la asociación del tipo de distribución depende del tamaño de la empresa.

4.5. ANOVA posteriores y tamaños de efecto

Tabla 43: Pruebas univariadas posteriores

Resultado	Efecto	$F(1, 196)$	p	η_p^2
Satisfacción	Distribución	118.934	< .001	.378
	Tamaño	27.977	< .001	.125
	Interacción	17.258	< .001	.081
Recomendación	Distribución	83.116	< .001	.298
	Tamaño	43.401	< .001	.181
	Interacción	1.506	.221	.008
Recompra	Distribución	55.402	< .001	.220
	Tamaño	29.988	< .001	.133
	Interacción	6.793	.010	.033

Los ANOVA posteriores permiten identificar qué resultados contribuyen al efecto conjunto. Dado que se realizan tres pruebas univariadas por familia de efectos, se usa como referencia Bonferroni: $\alpha = 0.05/3 = 0.0167$. Distribución y tamaño se asocian significativamente con las tres variables. La interacción se concentra en satisfacción y recompra; esta última sigue siendo significativa incluso con Bonferroni ($p = .010 < .0167$). Para recomendación, los efectos son esencialmente aditivos.

4.6. Medias e interpretación de la interacción

Tabla 44: Medias de lealtad por distribución y tamaño

Distribución	Tamaño	Satisfacción	Recomendación	Recompra
Indirecta	Pequeña	6.211	6.091	7.142
Indirecta	Grande	6.406	6.771	7.475
Directa	Pequeña	7.128	7.079	7.670
Directa	Grande	8.449	8.067	8.569




Figura 7: Interacción entre tipo de distribución y tamaño de empresa sobre las tres variables de lealtad, generada desde el notebook de la Pregunta 4.

En satisfacción, la diferencia directa–indirecta es 0.917 entre pequeñas y 2.042 entre grandes. En recompra, la diferencia aumenta de 0.528 a 1.095. Estas diferencias en diferencias explican las interacciones significativas. Para recomendación, la ventaja del canal directo es 0.988 entre pequeñas y 1.295 entre grandes, patrón más cercano al paralelismo y coherente con la interacción no significativa.

Debido a la interacción, los efectos principales deben interpretarse condicionados. Decir simplemente que el canal directo es mejor es incompleto: su ventaja es especialmente marcada entre empresas grandes.

Los efectos simples se contrastaron mediante pruebas t de Welch y corrección de Bonferroni por familia ($\alpha = 0.0125$). Las conclusiones se mantuvieron. Las diferencias grande–pequeña bajo distribución indirecta no fueron significativas en satisfacción ni recompra, lo que refuerza que las diferencias por tamaño aparecen principalmente cuando el canal es directo.

4.7. Respuestas según incisos del enunciado

4.7.1. a) ¿Incide el tipo de distribución?

Sí. Se observan diferencias significativas en el perfil de lealtad según el tipo de distribución, y los tres ANOVA muestran medias superiores bajo distribución directa.

4.7.2. b) ¿Existen diferencias según tamaño?

Sí. Se observan diferencias significativas en el perfil de lealtad según el tamaño de la empresa, y las empresas grandes presentan mayores medias de satisfacción, recomendación y recompra.

4.7.3. c) ¿Distribución y tamaño son antecedentes independientes?

No, en el sentido planteado por el modelo factorial. La interacción significativa muestra que la asociación del tipo de distribución con la lealtad depende del tamaño de la empresa. No se está evaluando independencia estadística entre distribución y tamaño como variables de clasificación, sino si el efecto de uno cambia según el nivel del otro. La ventaja del canal directo es especialmente intensa entre empresas grandes, sobre todo en satisfacción y recompra.

Tabla 45: Resumen de hipótesis de la Pregunta 4

Hipótesis nula	Evidencia principal	Decisión
H_{01} : sin efecto conjunto de distribución	Pillai $V = .1474$, $p < .001$	Se rechaza
H_{02} : sin efecto conjunto de tamaño	Pillai $V = .0972$, $p < .001$	Se rechaza
H_{03} : sin interacción distribución $\times$ tamaño	Pillai $V = .0966$, $p < .001$	Se rechaza

4.8. Conclusión de la pregunta 4

El tipo de distribución y el tamaño se asocian con el perfil conjunto de lealtad. Los clientes atendidos directamente presentan mejores resultados y las empresas grandes muestran mayor lealtad promedio. Sin embargo, ambos factores presentan un efecto conjunto significativo: la ventaja observada del canal directo es mayor entre las empresas grandes.

Desde una perspectiva gerencial, los resultados sugieren que HBAT podría priorizar la fuerza de ventas directa para clientes grandes, donde su asociación con satisfacción y recompra es especialmente fuerte, y evaluar estrategias diferenciadas para empresas pequeñas. Los resultados son asociativos y no permiten establecer causalidad. El tipo de distribución podría estar relacionado con otras características no incluidas en el modelo.

5. Conclusión general

Los cuatro análisis responden preguntas distintas. La mediación moderada muestra que la magnitud del efecto indirecto varía según una condición organizacional; el AFE evalúa la estructura latente de un instrumento; el CFA/SEM distingue entre calidad de medición y relaciones estructurales; y el MANOVA evalúa efectos conjuntos e interacción sobre múltiples resultados.

En conjunto, los resultados muestran que las relaciones analizadas no son puramente directas. En la primera pregunta, la evidencia es consistente con una relación indirecta entre presión competitiva y desempeño innovador a través de la conducta innovadora de los empleados.

La intensidad de este mecanismo aumenta cuando la organización presenta una cultura más tolerante frente a los errores derivados de la experimentación.

En la segunda pregunta, los resultados ofrecen apoyo general, aunque no completo, a la estructura de cuatro dimensiones propuesta por la teoría de Blend; algunos ítems requieren revisión y eventual depuración. En la tercera, la intención de permanecer se asocia principalmente con la percepción del ambiente, la actitud hacia los compañeros y el compromiso organizacional. Además, los caminos estructurales pueden interpretarse de manera comparable entre hombres y mujeres bajo invariancia métrica parcial. Finalmente, en la cuarta pregunta, la lealtad se asocia conjuntamente con el tipo de distribución y el tamaño de la empresa, y la ventaja del canal directo es especialmente marcada entre las empresas grandes.

La principal conclusión metodológica de la tarea es que una interpretación adecuada no puede limitarse al reporte de significancia estadística. También debe considerar el mecanismo analizado, la calidad de la medición, las restricciones comparadas y la forma en que los efectos cambian según las condiciones del modelo.

6. Referencias metodológicas

Byrne, B. M., Shavelson, R. J., & Muthén, B. (1989). Testing for the equivalence of factor covariance and mean structures: The issue of partial measurement invariance. *Psychological Bulletin*, 105(3), 456–466.

Chen, F. F. (2007). Sensitivity of goodness of fit indexes to lack of measurement invariance. *Structural Equation Modeling*, 14(3), 464–504.

Cheung, G. W., & Rensvold, R. B. (2002). Evaluating goodness-of-fit indexes for testing measurement invariance. *Structural Equation Modeling*, 9(2), 233–255.

Fornell, C., & Larcker, D. F. (1981). Evaluating structural equation models with unobservable variables and measurement error. *Journal of Marketing Research*, 18(1), 39–50.

Hayes, A. F. (2022). *Introduction to Mediation, Moderation, and Conditional Process Analysis: A Regression-Based Approach* (3rd ed.). Guilford Press.

Henseler, J., Ringle, C. M., & Sarstedt, M. (2015). A new criterion for assessing discriminant validity in variance-based structural equation modeling. *Journal of the Academy of Marketing Science*, 43(1), 115–135.

Meredith, W. (1993). Measurement invariance, factor analysis and factorial invariance. *Psychometrika*, 58(4), 525–543.

Zhao, X., Lynch, J. G., & Chen, Q. (2010). Reconsidering Baron and Kenny: Myths and truths about mediation analysis. *Journal of Consumer Research*, 37(2), 197–206.

Anexo 1: Código y output pregunta 1

Anexo 1: Código y output pregunta 1

Notebook ejecutado de la Pregunta 1

✓ Pregunta 1 — Mediación moderada

Métodos Cuantitativos de la Investigación en Negocios — Tarea 2 (2026)

```
1 # Instalación condicional de dependencias para Google Colab.
2 # En ejecución local no instala nada si los paquetes ya están disponibles.
3 import importlib, subprocess, sys
4
5 def instalar_si_falta(import_name, package_name=None):
6     package_name = package_name or import_name
7     try:
8         importlib.import_module(import_name)
9     except ImportError:
10        print(f'Instalando {package_name}...')
11        subprocess.check_call([sys.executable, '-m', 'pip', 'install', '-q', package_name])
12
13 instalar_si_falta('pyreadstat', 'pyreadstat')
14
15 print('Dependencias verificadas y entorno inicial preparado.')
16
```

Dependencias verificadas y entorno inicial preparado.

✓ Enunciado de la pregunta 1

Para cada una de las preguntas, describa claramente los pasos seguidos y adjunte los resultados de los análisis efectuados durante el proceso.

1. Como parte de una investigación en la que está participando, se le ha solicitado realizar un análisis de un modelo que explica la relación entre la presión competitiva del mercado y el desempeño innovador de la empresa. En este modelo (ver figura 1) se plantea que el efecto de la presión competitiva sobre el desempeño innovador está mediado por la conducta innovadora de los empleados, pero que esta relación depende de la cultura de tolerancia al fracaso de la organización.




Figura 1

Las variables del modelo se explican a continuación:

- **Presión Competitiva del Mercado:** Nivel de rivalidad y cambios tecnológicos en el sector, medida en una escala de 1 a 10, donde un mayor número representa una mayor presión competitiva.
- **Cultura de Tolerancia al Fracaso:** Grado en que la gerencia castiga o premia los errores al experimentar, medida en una escala de 1 a 7, donde un mayor número representa una mayor tolerancia al fracaso por parte de la gerencia.
- **Conducta Innovadora del Empleado:** Generación e implementación de ideas nuevas en el trabajo, medida como el número de ideas propuestas por el empleado en los últimos 5 años.
- **Desempeño Innovador de la Empresa:** Generación exitosa de nuevos productos o servicios para el mercado, medida como el porcentaje de ingresos de la organización proveniente de productos o servicios lanzados los últimos 5 años.

Con los datos de las respuestas 200 empleados de 200 empresas distintas, contenidos en la base `Med_Mod.sav`, usted deberá:

- Plantear el modelo en forma de hipótesis.
- Evaluar cada una de estas hipótesis.
- Interpretar los resultados.

Respuesta

El modelo corresponde a una **mediación moderada de primera etapa**: la presión competitiva del mercado puede influir en el desempeño innovador a través de la conducta innovadora del empleado, y ese primer tramo depende de la cultura de tolerancia al fracaso.

En términos de variables estadísticas:

- **X**: Presión competitiva del mercado.
- **W**: Cultura de tolerancia al fracaso.
- **M**: Conducta innovadora del empleado.
- **Y**: Desempeño innovador de la empresa.

La lógica estadística es equivalente al **modelo 7 de Hayes**. En este notebook no se usa la macro PROCESS directamente; se reproduce esa especificación en Python mediante regresiones OLS y bootstrap para el efecto indirecto condicional.

```
1 from pathlib import Path
2 from urllib.request import urlretrieve, urlopen
3 import ssl
4 import warnings
5 warnings.filterwarnings('ignore')
6
7 import numpy as np
8 import pandas as pd
9 import pyreadstat
10 from scipy import stats
11 import statsmodels.api as sm
12 import statsmodels.formula.api as smf
13
14 pd.set_option('display.max_columns', 100)
15 pd.set_option('display.width', 160)
16
17 # Base requerida para este notebook.
18 # Funciona localmente y también en Google Colab abierto desde GitHub.
19 REQUIRED_DATA_FILE = 'Med_Mod.sav'
20 RAW_DATA_BASE = 'https://raw.githubusercontent.com/sebabcerra/Metodos-Cuantitativos-DEN/main/Tarea2/data'
21
22 def encontrar_o_descargar_base(filename):
23     candidatas = [
24         Path.cwd() / 'data',          # ejecución desde Tarea2
25         Path.cwd().parent / 'data',    # ejecución desde Tarea2/notebooks
26         Path.cwd() / 'Tarea2' / 'data', # ejecución desde raíz del repo o Colab
27         Path.cwd()                    # respaldo: base junto al notebook
28     ]
29     for ruta in candidatas:
30         if (ruta / filename).exists():
31             return ruta
32
33     # Si Colab no tiene la carpeta del repo clonada, se descarga la base desde GitHub.
34     destino_dir = Path.cwd() / 'Tarea2' / 'data'
35     destino_dir.mkdir(parents=True, exist_ok=True)
36     destino = destino_dir / filename
37     url = f'{RAW_DATA_BASE}/{filename}'
38     print(f'Base {filename} no encontrada localmente. Descargando desde GitHub...')
39     try:
40         urlretrieve(url, destino)
41     except Exception as error:
42         # Respaldo útil en algunos entornos locales con problemas de certificados SSL.
43         # En Colab normalmente no se activa, pero evita fallas si Python no encuentra certificados.
44         print('Descarga estándar falló; intentando respaldo SSL...')
45         contexto = ssl._create_unverified_context()
46         with urlopen(url, context=contexto) as respuesta, open(destino, 'wb') as archivo:
47             archivo.write(respuesta.read())
48     return destino_dir
49
50 DATA_DIR = encontrar_o_descargar_base(REQUIRED_DATA_FILE)
51 print('Directorio de datos:', DATA_DIR)
52 print('Base usada:', DATA_DIR / REQUIRED_DATA_FILE)
53
```

Directorio de datos: /content/Tarea2/data
Base usada: /content/Tarea2/data/Med_Mod.sav

✓ 1.a) Planteamiento del modelo en forma de hipótesis

Se analiza una **mediación moderada de primera etapa**:

- X : presión competitiva del mercado.
- M : conducta innovadora del empleado.
- Y : desempeño innovador de la empresa.
- W : cultura de tolerancia al fracaso.

La moderación se ubica en la relación $X \rightarrow M$. Antes de escribir las ecuaciones, se define la notación: X_c representa la presión competitiva centrada en su media, W_c representa la tolerancia al fracaso centrada en su media, M corresponde a la conducta innovadora del empleado y Y al desempeño innovador de la empresa. Los coeficientes a_1 , a_2 , a_3 , b , c' y c representan los efectos estimados en cada camino: a_1 es la asociación entre presión competitiva y conducta innovadora cuando $W_c = 0$, a_2 es la asociación entre tolerancia al

fracaso y conducta innovadora cuando $X_c = 0$, a_3 es la interacción, b es la asociación entre conducta innovadora y desempeño, c' es el efecto directo residual y c es el efecto total.

El análisis se articula en **tres ecuaciones**:

$$\begin{aligned} (1) \text{ Mediador: } M &= i_M + a_1 X_c + a_2 W_c + a_3 (X_c W_c) + e_M \\ (2) \text{ Resultado: } Y &= i_Y + c' X + b M + e_Y \\ (3) \text{ Efecto total: } Y &= i_T + c X + e_T \end{aligned}$$

Las ecuaciones (1) y (2) constituyen el sistema estructural equivalente al modelo 7 de Hayes; la ecuación (3) se reporta para documentar el efecto total, aunque no forma parte de las hipótesis formales. A partir de (1) y (2) se deriva el efecto indirecto condicional $(a_1 + a_3 W)b$, que es una función de los coeficientes y no una regresión adicional.

Las hipótesis, alineadas con las flechas de la figura del enunciado, son:

- **H1:** la presión competitiva se asocia positivamente con la conducta innovadora ($a_1 > 0$).
- **H2:** la conducta innovadora se asocia positivamente con el desempeño innovador ($b > 0$).
- **H3:** existe un efecto directo residual de la presión competitiva sobre el desempeño una vez incorporada la conducta innovadora ($c' \neq 0$).
- **H4:** existe un efecto indirecto significativo de la presión competitiva sobre el desempeño a través de la conducta innovadora ($IE(W_c) \neq 0$).
- **H5:** la tolerancia al fracaso fortalece la relación presión competitiva--conducta innovadora ($a_3 > 0$).

El índice de mediación moderada $a_3 b$ se reporta como evidencia complementaria, porque indica si el mecanismo indirecto cambia de intensidad según W . El efecto total c se estima y reporta porque documenta la asociación global, pero la hipótesis formal sobre el vínculo $X \rightarrow Y$ es H3, correspondiente al camino directo dibujado en la figura.

```
1 # Chequeo inicial de la base.
2 # Se carga la base completa; no se filtran observaciones ni se toma una submuestra.
3 # apply_value_formats=False conserva los valores numéricos originales, necesarios para estimar los modelos.
4 df, meta = pyreadstat.read_sav(DATA_DIR/'Med_Mod.sav', apply_value_formats=False)
5
6 print('Archivo usado:', DATA_DIR/'Med_Mod.sav')
7 print('Número de observaciones:', len(df))
8 print('Número de variables:', df.shape[1])
9 print('Dimensión de la base:', df.shape)
10 print('Datos perdidos totales:', int(df.isna().sum().sum()))
11 print('\nDatos perdidos por variable:')
12 print(df.isna().sum().to_string())
13 print('\nDescriptivos básicos:')
14 print(df.describe().round(3).to_string())
15
16 print('\nEtiquetas de variables:')
17 for c in df.columns:
18     print(c, '->', meta.column_names_to_labels.get(c))
19
```

```
Archivo usado: /content/Tarea2/data/Med_Mod.sav
Número de observaciones: 200
Número de variables: 5
Dimensión de la base: (200, 5)
Datos perdidos totales: 0
```

```
Datos perdidos por variable:
ID          0
Pres_Comp   0
Cult_Tol_Frac 0
Con_Inn_Emple 0
Des_Inn_Empre 0
```

```
Descriptivos básicos:
      ID  Pres_Comp  Cult_Tol_Frac  Con_Inn_Emple  Des_Inn_Empre
count  200.000    200.000    200.000    200.000    200.000
mean   100.500     4.576         2.785         9.595         9.639
std     57.879     1.079         0.758         3.406         2.983
min      1.000     2.129         1.054         3.000         4.113
25%     50.750     3.853         2.200         7.000         7.714
50%    100.500     4.541         2.892         9.000         9.304
75%    150.250     5.328         3.451        12.000        11.445
max    200.000     7.778         4.543        21.000        21.066
```

```
Etiquetas de variables:
ID -> None
Pres_Comp -> Presión Competitiva del Mercado
Cult_Tol_Frac -> Cultura de Tolerancia al Fracaso
Con_Inn_Emple -> Conducta Innovadora del Empleado
Des_Inn_Empre -> Desempeño Innovador de la Empresa
```

✓ 1.b) Evaluación de las hipótesis: preparación de variables

Se centran X y W en sus medias. Esto no cambia el ajuste ni el término de interacción, pero hace que los efectos principales se interpreten cuando la otra variable está en su media y reduce colinealidad no esencial.

```

1 # Definición de variables del modelo.
2 # X: presión competitiva; W: tolerancia al fracaso; M: conducta innovadora; Y: desempeño innovador.
3 X, W, M, Y = 'Pres_Comp', 'Cult_Tol_Frac', 'Con_Inn_Emple', 'Des_Inn_Emple'
4
5 # Se centran X y W para interpretar los efectos principales en el nivel promedio del moderador.
6 # La interacción XW representa el término de moderación del primer tramo X -> M.
7 df['Xc'] = df[X] - df[X].mean()
8 df['Wc'] = df[W] - df[W].mean()
9 df['XW'] = df['Xc'] * df['Wc']
10
11 print(df[[X, W, 'Xc', 'Wc', 'XW']].head().round(3).to_string(index=False))
12

```

Pres_Comp	Cult_Tol_Frac	Xc	Wc	XW
5.745	3.358	1.169	0.573	0.669
4.793	3.561	0.217	0.776	0.168
5.972	4.083	1.396	1.298	1.811
7.285	4.054	2.709	1.269	3.436
4.649	1.622	0.073	-1.163	-0.085

1.b) Evaluación de las hipótesis: estimación de las tres ecuaciones

Se estiman las tres ecuaciones del planteamiento: (1) la del mediador, donde el coeficiente de XW —definido como $X_c W_c$ — evalúa si el efecto de presión competitiva cambia según la tolerancia al fracaso; (2) la del resultado, que incorpora simultáneamente presión competitiva y conducta innovadora; y (3) la del efecto total, reportada como referencia descriptiva de la asociación global. Las dos primeras forman el sistema del modelo 7; la tercera no modifica el modelo, sino que documenta el efecto total antes de descomponerlo en directo e indirecto.

Se utilizan errores estándar robustos HC3. En cada tabla se interpretan el coeficiente, su error estándar, el estadístico de contraste y el p-value.

```

1 # Especificación equivalente al modelo 7 de Hayes, estimada en Python con regresiones OLS.
2 # 1) Modelo del mediador: evalúa X -> M y la interacción XW.
3 # 2) Modelo del resultado: evalúa M -> Y controlando X.
4 # 3) Modelo total: evalúa el efecto total X -> Y antes de introducir el mediador.
5 modelo_M = smf.ols(f'{M} ~ Xc + Wc + XW', df).fit(cov_type='HC3')
6 modelo_Y = smf.ols(f'{Y} ~ Xc + {M}', df).fit(cov_type='HC3')
7 modelo_total = smf.ols(f'{Y} ~ Xc', df).fit(cov_type='HC3')
8
9 print('MODELO DEL MEDIADOR\n', modelo_M.summary().as_text())
10 print('\nMODELO DEL RESULTADO\n', modelo_Y.summary().as_text())
11 print('\nEFECTO TOTAL\n', modelo_total.summary().as_text())
12
13 # Tabla resumida de los coeficientes clave para leer directamente las hipótesis H1 y H5.
14 coeficientes_M = pd.DataFrame({
15     'Coeficiente': modelo_M.params,
16     'Error estándar HC3': modelo_M.bse,
17     'Estadístico z': modelo_M.tvalues,
18     'p-value': modelo_M.pvalues
19 })
20 print('\nCOEFICIENTES CENTRALES DEL MODELO DEL MEDIADOR')
21 print(coeficientes_M.loc[['Xc', 'Wc', 'XW']].round(4).to_string())
22
23 # El 0.5248 sale del coeficiente de XW: es cuánto cambia el efecto de X -> M
24 # cuando la tolerancia al fracaso aumenta una unidad.
25 print('\nEcuación estimada del mediador:')
26 p_ = modelo_M.params
27 print(f'M_hat = {p_["Intercept"]:.4f} + {p_["Xc"]:.4f}·Xc + {p_["Wc"]:.4f}·Wc + {p_["XW"]:.4f}·(Xc×Wc)')
28

```

MODELO DEL MEDIADOR

OLS Regression Results						
Dep. Variable:	Con_Inn_Emple	R-squared:	0.981			
Model:	OLS	Adj. R-squared:	0.980			
Method:	Least Squares	F-statistic:	2625.			
Date:	Thu, 16 Jul 2026	Prob (F-statistic):	6.32e-158			
Time:	18:28:23	Log-Likelihood:	-134.43			
No. Observations:	200	AIC:	276.9			
Df Residuals:	196	BIC:	290.0			
Df Model:	3					
Covariance Type:	HC3					
	coef	std err	z	P> z	[0.025	0.975]
Intercept	9.5207	0.034	277.010	0.000	9.453	9.588
Xc	2.0008	0.039	50.823	0.000	1.924	2.078
Wc	2.8732	0.047	61.140	0.000	2.781	2.965
XW	0.5248	0.039	13.475	0.000	0.449	0.601
Omnibus:	11.982	Durbin-Watson:	1.739			
Prob(Omnibus):	0.003	Jarque-Bera (4):	14.307			
Skew:	0.458	Prob(JB):	0.000782			

Kurtosis: 3.938 Cond. No. 1.53

Notes:
[1] Standard Errors are heteroscedasticity robust (HC3)

MODELO DEL RESULTADO

OLS Regression Results

```
=====
Dep. Variable:          Des_Inn_Empre      R-squared:                0.973
Model:                  OLS                Adj. R-squared:           0.973
Method:                 Least Squares      F-statistic:             2153.
Date:                   Thu, 16 Jul 2026    Prob (F-statistic):      1.38e-134
Time:                   18:28:23           Log-Likelihood:          -140.05
No. Observations:       200               AIC:                    286.1
Df Residuals:           197               BIC:                    296.0
Df Model:                2
Covariance Type:        HC3
=====
               coef      std err          z      P>|z|      [0.025      0.975]
-----
Intercept          1.4086        0.156        9.006      0.000         1.102         1.715
Xc                 0.0265        0.049        0.538      0.590        -0.070         0.123
Con_Inn_Emple      0.8577        0.017       51.267      0.000         0.825         0.891
=====
Omnibus:                 3.405    Durbin-Watson:           1.866
Prob(Omnibus):           0.182    Jarque-Bera (JB):         2.985
Skew:                    0.259    Prob(JB):                 0.225
Kurtosis:                3.301    Cond. No.                 45.5
=====
```

Notes:
[1] Standard Errors are heteroscedasticity robust (HC3)

```
1 # R2 con cuatro decimales, reportados en el documento (Tablas 2 y 3).
2 print(f'R2 modelo del mediador = {modelo_M.rsquared:.4f}')
3 print(f'R2 modelo del resultado = {modelo_Y.rsquared:.4f}')
4 print(f'R2 modelo total          = {modelo_total.rsquared:.4f}')
```

```
R2 modelo del mediador = 0.9805
R2 modelo del resultado = 0.9732
R2 modelo total       = 0.5380
```

▼ Estadístico de comparación y sustitución de los contrastes

Con errores estándar robustos HC3, `statsmodels` reporta estadísticos z asintóticos en los resúmenes utilizados aquí. Por ello, el estadístico de comparación bilateral al 95% de confianza se obtiene desde la distribución normal estándar. La regla de decisión es: se rechaza H_0 si $|z| > z_c$, equivalente a $p < 0.05$.

A modo de ilustración, para la interacción (H5) el estadístico se calcula como el coeficiente dividido por su error estándar robusto:

$$z = \frac{a_3}{EE(a_3)} = \frac{0.5248}{0.0389} = 13.48.$$

Como $13.48 > z_c$ y $p < 0.001$, se rechaza $H_0 : a_3 = 0$: existe moderación. La misma regla aplica a cada coeficiente de las tres ecuaciones. La celda siguiente calcula el valor crítico y los efectos condicionales que luego alimentan los efectos indirectos: cada una se obtiene reemplazando en $a(W) = a_1 + a_3W$ con $DE(W) = 0.7583$.

```
1 # Estadístico de comparación (95%, bilateral) y efectos condicionales de X sobre M.
2 # Statsmodels reporta z en los resúmenes robustos HC3 usados aquí.
3 zc = stats.norm.ppf(.975)
4 z_a3 = modelo_M.params['XW'] / modelo_M.bse['XW']
5 print(f'z crítico bilateral (95%) = ±{zc:.4f}')
6 print(f'z interacción = {modelo_M.params["XW"]:.4f}/{modelo_M.bse["XW"]:.4f} = {z_a3:.4f} -> se rechaza H0: a3=0')
7
8 sdW = df['Wc'].std(ddof=1)
9 print(f'\nDE(W) = {sdW:.4f}')
10 print(f'a(baja) = a1 + a3*(-DE) = {modelo_M.params["Xc"] - modelo_M.params["XW"]*sdW:.4f}')
11 print(f'a(media) = a1              = {modelo_M.params["Xc"]:.4f}')
12 print(f'a(alta) = a1 + a3*(+DE) = {modelo_M.params["Xc"] + modelo_M.params["XW"]*sdW:.4f}')
13
```

```
z crítico bilateral (95%) = ±1.9600
z interacción = 0.5248/0.0389 = 13.4753 -> se rechaza H0: a3=0
```

```
DE(W) = 0.7583
a(baja) = a1 + a3*(-DE) = 1.6029
a(media) = a1           = 2.0008
a(alta) = a1 + a3*(+DE) = 2.3988
```

```
1 # Figura de moderación: efecto condicional de presión competitiva sobre conducta innovadora
2 # para tolerancia baja (-1 DE), media y alta (+1 DE).
3 import matplotlib
4 matplotlib.use('Agg')
5 import matplotlib.pyplot as plt
```

```

6 from pathlib import Path
7 ASSETS_DIR = Path('../assets')
8 ASSETS_DIR.mkdir(parents=True, exist_ok=True)
9
10 x_min = df['Pres_Comp'].min()
11 x_max = df['Pres_Comp'].max()
12 x_grid = np.linspace(x_min, x_max, 100)
13 x_c_grid = x_grid - df['Pres_Comp'].mean()
14
15 w_mean = df['Cult_Tol_Frac'].mean()
16 w_sd = df['Cult_Tol_Frac'].std(ddof=1)
17 niveles = [
18     ('Bajo (-1 DE)', w_mean - w_sd, '#1f77b4'),
19     ('Medio (media)', w_mean, '#ff7f0e'),
20     ('Alto (+1 DE)', w_mean + w_sd, '#2ca02c'),
21 ]
22
23 fig, ax = plt.subplots(figsize=(9, 5.4))
24 for etiqueta, w_val, color in niveles:
25     w_c = w_val - w_mean
26     pred = (modelo_M.params['Intercept'] +
27            modelo_M.params['Xc'] * x_c_grid +
28            modelo_M.params['Wc'] * w_c +
29            modelo_M.params['XW'] * x_c_grid * w_c)
30     ax.plot(x_grid, pred, linewidth=2.5, label=etiqueta, color=color)
31
32 ax.set_title('Moderación de la cultura de tolerancia al fracaso')
33 ax.set_xlabel('Presión competitiva del mercado')
34 ax.set_ylabel('Conducta innovadora predicha')
35 ax.legend(title='Nivel de tolerancia')
36 ax.grid(alpha=.25)
37 fig.tight_layout()
38 fig.savefig(ASSETS_DIR / 'p1_moderacion_tolerancia.png', dpi=200, bbox_inches='tight')
39 plt.close(fig)
40 print(f'Figura guardada: {ASSETS_DIR / 'p1_moderacion_tolerancia.png'}')


```

Figura guardada: ../assets/p1_moderacion_tolerancia.png

```

1 from IPython.display import Image, display
2 display(Image('../assets/p1_moderacion_tolerancia.png'))

```



- ✓ Relación entre las tres ecuaciones: por qué $c \neq c' + a_1 b$ en el modelo 7

En el modelo 4 (mediación simple) se cumple exactamente la descomposición $c = c' + ab$. En el modelo 7 esa identidad **no se cumple con** a_1 , porque a_1 es el efecto de X sobre M condicional a W y a la interacción, mientras que la ecuación del efecto total omite a W . La identidad OLS exacta que sí se cumple es $c = c' + b \tilde{a}_1$, donde $\tilde{a}_1$ proviene de la regresión simple $M \sim X$. La brecha entre $\tilde{a}_1$ y a_1 se

explica por la correlación entre X y W . Además, el efecto total implicado por el sistema es condicional: $c(W) = c' + (a_1 + a_3 W)b$. Por eso la evidencia formal de mediación no descansa en c , sino en los efectos indirectos condicionales y su bootstrap.

```

1 # Verificación numérica de la descomposición del efecto total.
2 modelo_M_simple = smf.ols(f'{M} ~ Xc', df).fit() # M ~ X sin W ni XW
3 a1s = modelo_M_simple.params['Xc']
4 c_ = modelo_total.params['Xc']
5 cp_ = modelo_Y.params['Xc']
6 b_ = modelo_Y.params[M]
7 a1_ = modelo_M.params['Xc']; a3_ = modelo_M.params['XW']
8
9 print(f'c (efecto total) = {c_: .4f}')
10 print(f'c' + a1*b (descomposición modelo 4) = {cp_ + a1_*b_: .4f} -> NO coincide")
11 print(f'a1_simple (M ~ X) = {a1s: .4f}')
12 print(f'c' + b*a1_simple (identidad OLS) = {cp_ + b_*a1s: .4f} -> coincide exactamente")
13 print(f'corr(Xc,Wc) = {df.Xc.corr(df.Wc): .4f} (explica la brecha entre a1 y a1_simple)')
14 print(f"Efecto total condicional c(W) = c' + (a1+a3*W)*b en W medio: {cp_ + a1_*b_: .4f}")

```

```
c (efecto total) = 2.0281
c' + a1*b (descomposición modelo 4) = 1.7427 -> NO coincide
a1_simple (M ~ X) = 2.3336
c' + b*a1_simple (identidad OLS) = 2.0281 -> coincide exactamente
corr(Xc,Wc) = 0.1739 (explica la brecha entre a1 y a1_simple)
Efecto total condicional c(W) = c' + (a1+a3*W)*b en W medio: 1.7427
```

- 1.b) Evaluación de las hipótesis: efectos indirectos condicionales y bootstrap

Con los coeficientes estimados se calcula el efecto indirecto condicional: $(a_1 + a_3 W)b$. Este efecto se evalúa en tres niveles de tolerancia al fracaso: baja ($-1DE$), media y alta ($+1DE$).

El bootstrap de 5.000 remuestras se usa porque el producto de coeficientes no necesariamente sigue una distribución normal; esta cantidad sigue una práctica habitual en aplicaciones tipo PROCESS. La regla de decisión es: si el intervalo de confianza al 95% no contiene cero, el efecto indirecto se interpreta como significativo. El índice de mediación moderada se calcula como a_3b y resume cuánto cambia el efecto indirecto cuando aumenta la tolerancia al fracaso.

```

1 # Coeficientes necesarios para el efecto indirecto conl.
2 # a1: efecto de X sobre M cuando W está en su media.
3 # a3: interacción XW; indica cómo cambia a1 según W.
4 # b: efecto de M sobre Y controlando X.
5 a1 = modelo_M.params['Xc']
6 a3 = modelo_M.params['XW']
7 b = modelo_Y.params[M]
8
9 sw = df['Wc'].std(ddof=1)
10 niveles = {'Baja (-1 DE)': -sw, 'Media': 0, 'Alta (+1 DE)': sw}
11
12 # Bootstrap: se remuestran filas completas para conservar la estructura conjunta de X, W, M e Y.
13 rng = np.random.default_rng(20260706)
14 boot = []
15 for _ in range(5000):
16     d = df.iloc[rng.integers(0, len(df), len(df))]
17     mm = smf.ols(f'{M} ~ Xc + Wc + XW', d).fit()
18     my = smf.ols(f'{Y} ~ Xc + {M}', d).fit()
19     boot.append((mm.params['Xc'], mm.params['XW'], my.params[M]))
20 boot = np.asarray(boot)
21
22 filas = []
23 for nombre, w in niveles.items():
24     vals = (boot[:, 0] + boot[:, 1] * w) * boot[:, 2]
25     filas.append([nombre, a1 + a3 * w, (a1 + a3 * w) * b, *np.quantile(vals, [.025, .975])])
26
27 tabla = pd.DataFrame(filas, columns=['Tolerancia', 'Efecto X-M', 'Indirecto', 'IC95% inferior', 'IC95% superior'])
28 indice = a3 * b
29 ici = np.quantile(boot[:, 1] * boot[:, 2], [.025, .975])
30
31 print(tabla.round(4).to_string(index=False))
32 print(f'\nÍndice de mediación moderada = {indice:.4f}; IC95% bootstrap [{ici[0]:.4f}, {ici[1]:.4f}]')
33

```

Tolerancia	Efecto X-M	Indirecto	IC95% inferior	IC95% superior
Baja (-1 DE)	1.6029	1.3748	1.2880	1.4620
Media	2.0008	1.7162	1.6227	1.8104
Alta (+1 DE)	2.3988	2.0576	1.9319	2.1853

Índice de mediación moderada = 0.4502; IC95% bootstrap [0.3758, 0.5184]

- ✓ 1.b) Evaluación de las hipótesis: diagnósticos del modelo

Se revisa multicolinealidad mediante VIF y heterocedasticidad con Breusch--Pagan. Los VIF permiten verificar que el centrado redujo colinealidad no esencial entre X , W y la interacción. Además, las regresiones principales usan errores estándar robustos HC3, por lo que

las conclusiones son más seguras frente a heterocedasticidad.

```

1 from statsmodels.stats.outliers_influence import variance_inflation_factor
2 from statsmodels.stats.diagnostic import het_breuschpagan
3
4 # VIF bajo indica que la interacción centrada no genera multicolinealidad problemática.
5 vif = pd.DataFrame({
6     'Variable': modelo_M.model.exog_names,
7     'VIF': [variance_inflation_factor(modelo_M.model.exog, i) for i in range(modelo_M.model.exog.shape[1])]
8 })
9
10 # Breusch--Pagan revisa heterocedasticidad; la inferencia principal ya usa HC3.
11 bp = het_breuschpagan(modelo_M.resid, modelo_M.model.exog)
12 print(vif.round(3).to_string(index=False))
13 print(f'\nBreusch-Pagan: LM={bp[0]:.4f}, p={bp[1]:.4g}')
14

```

```

Variable  VIF
Intercept 1.027
Xc 1.036
Wc 1.046
XW 1.016

```

Breusch-Pagan: LM=1.1407, p=0.7673

1.c) Interpretación de los resultados

La respuesta directa es que el modelo propuesto recibe apoyo empírico. La presión competitiva del mercado se relaciona positivamente con el desempeño innovador de la empresa, pero esa relación opera principalmente a través de la conducta innovadora del empleado. Además, la cultura de tolerancia al fracaso fortalece este proceso.

Respuesta directa a las hipótesis

Hipótesis	Relación evaluada	Evidencia principal	Decisión
H1	Presión competitiva → conducta innovadora	$a_1 = 2.0008, p < 0.001$	Apoyada
H2	Conducta innovadora → desempeño innovador	$b = 0.8577, p < 0.001$	Apoyada
H3	Efecto directo presión competitiva → desempeño	$c' = 0.0265, p = 0.590$	No apoyada
H4	Efecto indirecto vía conducta innovadora	IC95% bootstrap sin cero	Apoyada
H5	Moderación de tolerancia al fracaso sobre $X \rightarrow M$	$a_3 = 0.5248, p < 0.001$	Apoyada

En conjunto, los resultados apoyan H1, H2, H4 y H5. El efecto directo planteado en H3 no recibe apoyo empírico, por lo que la evidencia es consistente con una mediación *indirect-only*. El efecto total, reportado como referencia, es positivo y significativo ($c = 2.0281, p < 0.001$). Junto con el efecto directo no significativo y los indirectos significativos en todos los niveles del moderador, el patrón indica que el vínculo entre presión competitiva y desempeño innovador opera a través de la conducta innovadora del empleado.

En términos sustantivos, la presión competitiva no mejora el desempeño innovador simplemente por existir. Su efecto aparece cuando los empleados responden proponiendo e implementando ideas nuevas. Esa respuesta es más fuerte en empresas donde la gerencia tolera el fracaso asociado a experimentar.

Anexo 2: Código y output pregunta 2

Anexo 2: Código y output pregunta 2

Notebook ejecutado de la Pregunta 2

✓ Pregunta 2 — Análisis factorial exploratorio

Métodos Cuantitativos de la Investigación en Negocios — Tarea 2 (2026)

```
1 # Instalación condicional de dependencias para Google Colab.
2 # En ejecución local no instala nada si los paquetes ya están disponibles.
3 import importlib, subprocess, sys
4
5 def instalar_si_falta(import_name, package_name=None):
6     package_name = package_name or import_name
7     try:
8         importlib.import_module(import_name)
9     except ImportError:
10         print(f'Instalando {package_name}...')
11         subprocess.check_call([sys.executable, '-m', 'pip', 'install', '-q', package_name])
12
13 instalar_si_falta('pyreadstat', 'pyreadstat')
14 instalar_si_falta('factor_analyzer', 'factor-analyzer')
15
16 print('Dependencias verificadas y entorno inicial preparado.')
17
```

Dependencias verificadas y entorno inicial preparado.

✓ Enunciado de la pregunta 2

2. La Universidad de Desarrollo está permanentemente tratando de tener los mejores profesores entre sus filas. Como parte de este esfuerzo, la UDD realizó un esfuerzo por analizar el cuestionario basado en la teoría de Blend asociada a los profesores de métodos de investigación. Esta teoría predice que los buenos profesores de métodos cuantitativos poseen cuatro características fundamentales: (1) gran amor por las estadísticas, (2) entusiasmo por el diseño de experimentos, (3) amor por la enseñanza, y (4) una completa ausencia de habilidades interpersonales normales. Estas características pueden estar correlacionadas entre ellas.

El cuestionario “Enseñanza de Experimentos para las Ciencias Sociales” (EECS) ya existe, pero la universidad mejoró este cuestionario y se convirtió en el EECS-R (“Enseñanza de Experimentos para las Ciencias Sociales - Revisado”). Este cuestionario revisado fue enviado y contestado satisfactoriamente por 239 profesores de métodos de investigación alrededor del mundo para evaluar si la teoría de Blend es correcta.

El cuestionario (preguntas, escala y respuestas) se encuentra en el archivo **EECS-R.sav**. Realice un Análisis Factorial Exploratorio y determine si se cumple la teoría de Blend.

Respuesta

La pregunta se resuelve verificando primero si los datos son adecuados para análisis factorial, determinando cuántos factores retener, interpretando las cargas factoriales y evaluando si la estructura empírica coincide con las cuatro dimensiones propuestas por la teoría de Blend.

```
1 from pathlib import Path
2 from urllib.request import urlretrieve, urlopen
3 import ssl
4 import warnings
5 warnings.filterwarnings('ignore')
6
7 import numpy as np
8 import pandas as pd
9 import pyreadstat
10 from scipy import stats
11 import statsmodels.api as sm
12 import statsmodels.formula.api as smf
13
14 pd.set_option('display.max_columns', 100)
15 pd.set_option('display.width', 160)
16
17 # Base requerida para este notebook.
18 # Funciona localmente y también en Google Colab abierto desde GitHub.
19 REQUIRED_DATA_FILE = 'EECS-R.sav'
20 RAW_DATA_BASE = 'https://raw.githubusercontent.com/sebabecerra/Metodos-Cuantitativos-DEN/main/Tarea2/data'
21
22 def encontrar_o_descargar_base(filename):
23     candidatas = [
24         Path.cwd() / 'data', # ejecución desde Tarea2
25         Path.cwd().parent / 'data', # ejecución desde Tarea2/notebooks
26         Path.cwd() / 'Tarea2' / 'data', # ejecución desde raíz del repo o Colab
27         Path.cwd() # respaldo: base junto al notebook
28     ]
29     for ruta in candidatas:
30         if (ruta / filename).exists():
31             return ruta
32
33 # Si Colab no tiene la carpeta del repo clonada, se descarga la base desde GitHub.
```

```

34 destino_dir = Path.cwd() / 'Tarea2' / 'data'
35 destino_dir.mkdir(parents=True, exist_ok=True)
36 destino = destino_dir / filename
37 url = f'{RAW_DATA_BASE}/{filename}'
38 print(f'Base {filename} no encontrada localmente. Descargando desde GitHub...')
39 try:
40     urlretrieve(url, destino)
41 except Exception as error:
42     # Respaldo útil en algunos entornos locales con problemas de certificados SSL.
43     # En Colab normalmente no se activa, pero evita fallas si Python no encuentra certificados.
44     print('Descarga estándar falló; intentando respaldo SSL...')
45     contexto = ssl.create_unverified_context()
46     with urlopen(url, context=contexto) as respuesta, open(destino, 'wb') as archivo:
47         archivo.write(respuesta.read())
48     return destino_dir
49
50 DATA_DIR = encontrar_o_descargar_base(REQUIRED_DATA_FILE)
51 print('Directorio de datos:', DATA_DIR)
52 print('Base usada:', DATA_DIR / REQUIRED_DATA_FILE)
53

```

Directorio de datos: /Users/sbc/projects/Metodos-Cuantitativos-DEN/Tarea2/data
Base usada: /Users/sbc/projects/Metodos-Cuantitativos-DEN/Tarea2/data/EECS-R.sav

1. Objetivo y decisiones analíticas

Se evalúa si los 28 ítems del EECS-R reproducen cuatro dimensiones correlacionadas propuestas por la teoría de Blend: amor por la estadística, entusiasmo por el diseño experimental, amor por la enseñanza y ausencia de habilidades interpersonales.

Se usa **análisis factorial exploratorio de factores comunes**, extracción de máxima verosimilitud y rotación oblicua Oblimin, porque las dimensiones pueden correlacionarse. Los datos perdidos —solo nueve respuestas— se imputan con la mediana del ítem.

```

1 from factor_analyzer import FactorAnalyzer
2 from factor_analyzer.factor_analyzer import calculate_bartlett_sphericity, calculate_kmo
3 import inspect
4 import sklearn.utils.validation as sk_validation
5 import factor_analyzer.factor_analyzer as fa_module
6
7 # Compatibilidad: algunas versiones nuevas de scikit-learn reemplazan
8 # force_all_finite por ensure_all_finite. factor_analyzer todavía usa
9 # force_all_finite en ciertos entornos, por eso se traduce el argumento.
10 _original_check_array = sk_validation.check_array
11 def _check_array_compat(*args, **kwargs):
12     if (
13         'force_all_finite' in kwargs
14         and 'force_all_finite' not in inspect.signature(_original_check_array).parameters
15     ):
16         kwargs['ensure_all_finite'] = kwargs.pop('force_all_finite')
17     return _original_check_array(*args, **kwargs)
18
19 fa_module.check_array = _check_array_compat
20
21 # Chequeo inicial de la base.
22 # Se carga la base completa; no se filtran observaciones ni se toma una submuestra.
23 df, meta = pyreadstat.read_sav(DATA_DIR/'EECS-R.sav', apply_value_formats=False)
24 items = [f'q{i}' for i in range(1, 29)]
25 X = df[items].copy()
26
27 print('Archivo usado:', DATA_DIR/'EECS-R.sav')
28 print('Número de observaciones:', len(df))
29 print('Número de ítems analizados:', len(items))
30 print('Dimensión de la matriz de ítems:', X.shape)
31 faltantes = int(X.isna().sum().sum())
32 print('Datos perdidos totales en los ítems:', faltantes)
33 print(f'Porcentaje de datos perdidos: {100 * faltantes / X.size:.3f}%')
34 print('\nDatos perdidos por ítem:')
35 print(X.isna().sum().to_string())
36 print('\nDescriptivos básicos de los ítems:')
37 print(X.describe().T[['mean', 'std', 'min', 'max']].round(3).to_string())
38 print('\nEtiquetas de ítems:')
39 for c in items:
40     print(f'{c}: {meta.column_names_to_labels[c]}')
41
42 # Imputación por mediana debido a la baja proporción de datos perdidos.
43 X = X.apply(lambda s: s.fillna(s.median()))
44 print('\nDatos perdidos después de imputar por mediana:', int(X.isna().sum().sum()))
45

```

Archivo usado: /Users/sbc/projects/Metodos-Cuantitativos-DEN/Tarea2/data/EECS-R.sav
Número de observaciones: 239
Número de ítems analizados: 28
Dimensión de la matriz de ítems: (239, 28)
Datos perdidos totales en los ítems: 9
Porcentaje de datos perdidos: 0.134%

Datos perdidos por ítem:
q1 0
q2 1

```

q3      1
q4      0
q5      0
q6      0
q7      0
q8      0
q9      0
q10     0
q11     1
q12     2
q13     0
q14     0
q15     1
q16     0
q17     0
q18     1
q19     1
q20     0
q21     1
q22     0
q23     0
q24     0
q25     0
q26     0
q27     0
q28     0

```

Descriptivos básicos de los ítems:

	mean	std	min	max
q1	4.720	1.412	1.0	7.0
q2	4.782	1.391	1.0	7.0
q3	4.929	1.158	1.0	7.0
q4	4.791	1.243	1.0	7.0
q5	3.406	1.315	1.0	7.0
q6	5.276	1.387	1.0	7.0
q7	4.987	1.102	1.0	7.0
q8	5.213	1.277	1.0	7.0
q9	5.314	1.249	1.0	7.0
q10	4.444	1.454	1.0	7.0
q11	4.080	1.545	1.0	7.0
q12	3.865	1.423	1.0	7.0
q13	5.431	1.304	2.0	7.0
q14	4.895	1.575	1.0	7.0
q15	4.639	1.773	1.0	7.0
q16	4.619	1.757	1.0	7.0
q17	5.456	1.256	1.0	7.0
q18	3.958	1.411	1.0	7.0

2. Factorabilidad: Bartlett y KMO

Bartlett contrasta que la matriz de correlaciones sea identidad. Se requiere $p < 0.05$. KMO cuantifica varianza común; valores superiores a 0.80.

La prueba se calcula como $\chi^2 = -\left(n - 1 - \frac{2p+5}{6}\right) \ln |R|$, con $gl = p(p-1)/2$, donde n es el número de casos, p el número de ítems y $|R|$ el determinante de la matriz de correlaciones. La regla de decisión es: se rechaza H_0 (matriz identidad) si el estadístico supera el valor crítico $\chi^2_{0.95, gl}$, equivalente a $p < 0.05$.

```

1 chi,p=calculate_bartlett_sphericity(X); _,kmo=calculate_kmo(X)
2 print(f'Bartlett: chi-cuadrado={chi:.4f}, gl={28*27//2}, ' + ('p<0.001' if p<0.001 else f'p={p:.4g}'))
3 print(f'KMO global={kmo:.4f}')
4
5 # Verificación manual de Bartlett: chi2 = -(n-1-(2p+5)/6)*ln|R|.
6 # Reproducir la fórmula a mano documenta el cálculo y valida la función de la librería.
7 lnR = np.linalg.slogdet(X.corr().to_numpy())[1]
8 chi_manual = -(len(X)-1-(2*28+5)/6)*lnR
9 print(f'\nln|R| = {lnR:.4f}')
10 print(f'chi2 manual = -(239-1-61/6)*({lnR:.4f}) = {chi_manual:.4f} (coincide con la función)')
11 print(f'chi2 crítico (95%, gl=378) = {stats.chi2.ppf(.95,378):.4f} -> como {chi:.2f} > {stats.chi2.ppf(.95,378):.2f}, se

```

```

Bartlett: chi-cuadrado=3045.3894, gl=378, p<0.001
KMO global=0.8952

```

```

ln|R| = -13.3667
chi2 manual = -(239-1-61/6)*(-13.3667) = 3045.3894 (coincide con la función)
chi2 crítico (95%, gl=378) = 424.3342 -> como 3045.39 > 424.33, se rechaza H0

```

3. Número de factores

Para decidir cuántos factores retener se combinan tres criterios:

1. **Autovalores observados:** indican cuánta varianza explica cada dimensión inicial.
2. **Gráfico de sedimentación:** muestra los autovalores ordenados de mayor a menor; se observa el punto donde la curva comienza a aplanarse, porque desde ahí los factores adicionales aportan poca información nueva.
3. **Análisis paralelo:** compara los autovalores observados con los que aparecerían por azar en matrices aleatorias del mismo tamaño.

El análisis paralelo es especialmente importante porque el criterio de autovalor mayor que 1 puede sugerir más factores de los realmente respaldados por los datos. En esta aplicación, el cuarto factor queda muy cerca del percentil 95 aleatorio. El valor 1.501 corresponde al

percentil 95 del cuarto autovalor obtenido en las 1.000 matrices aleatorias generadas para el análisis paralelo. Por eso se revisa también la media de autovalores aleatorios y la coherencia teórica de cuatro dimensiones.


```

1 R=X.corr().to_numpy(); eig=np.linalg.eigvalsh(R)[::-1]
2 rng=np.random.default_rng(12345)
3 rand=[]
4 for _ in range(1000):
5     Rr=np.corrcoef(rng.normal(size=X.shape),rowvar=False)
6     rand.append(np.linalg.eigvalsh(Rr)[::-1])
7 rand=np.array(rand)
8 rand95=np.percentile(rand,95,axis=0)
9 randmean=rand.mean(axis=0)
10 print('Primeros 8 autovalores observados:',np.round(eig[:8],3))
11 print('Percentil 95 aleatorio:',np.round(rand95[:8],3))
12 print('Media aleatoria:',np.round(randmean[:8],3))
13 print('Factores retenidos por percentil 95:',int((eig>rand95).sum()))
14 print('Factores retenidos por media aleatoria:',int((eig>randmean).sum()))
15 print(f'Cuarto autovalor observado = {eig[3]:.3f}; percentil 95 aleatorio = {rand95[3]:.3f}; media aleatoria = {randmean[3]:.3f}')
16
17 import matplotlib.pyplot as plt
18 from pathlib import Path
19 from IPython.display import Image, display
20 ASSETS_DIR = Path('../assets')
21 ASSETS_DIR.mkdir(parents=True, exist_ok=True)
22 fig, ax = plt.subplots(figsize=(8,5))
23 xs=np.arange(1,len(items)+1)
24 ax.plot(xs,eig,marker='o',label='Autovalores observados',linewidth=2)
25 ax.plot(xs,rand95,marker='s',label='Percentil 95 aleatorio',linewidth=1.5)
26 ax.plot(xs,randmean,linestyle='--',label='Media aleatoria',linewidth=1.5)
27 ax.axvline(4,color='gray',linestyle=':',label='4 factores retenidos')
28 ax.set_xlabel('Número de factor')
29 ax.set_ylabel('Autovalor')
30 ax.set_title('Análisis paralelo y gráfico de sedimentación')
31 ax.set_xlim(1,12)
32 ax.grid(alpha=.25)
33 ax.legend()
34 fig.savefig(ASSETS_DIR / 'p2_scee_parallel.png', dpi=200, bbox_inches='tight')
35 plt.close(fig)
36 display(Image(str(ASSETS_DIR / 'p2_scee_parallel.png')))
37 print(f'Figura guardada: {ASSETS_DIR / 'p2_scee_parallel.png'}')

```

Primeros 8 autovalores observados: [9.03 2.725 1.706 1.505 1.157 0.975 0.917 0.831]
 Percentil 95 aleatorio: [1.785 1.656 1.55 1.501 1.437 1.367 1.312 1.268]
 Media aleatoria: [1.687 1.567 1.494 1.445 1.388 1.333 1.285 1.239]
 Factores retenidos por percentil 95: 4
 Factores retenidos por media aleatoria: 4
 Cuarto autovalor observado = 1.505; percentil 95 aleatorio = 1.501; media aleatoria = 1.445
 Figura guardada: ../assets/p2_scee_parallel.png

Análisis paralelo y gráfico de sedimentación



```

1 fa=FactorAnalyzer(n_factors=4,rotation='oblimin',method='ml'); fa.fit(X)
2 L=pd.DataFrame(fa.loadings_,index=items,columns=['F1','F2','F3','F4'])
3 print(L.round(3).to_string())
4 print('\nVarianza por factor:')
5 varianza = pd.DataFrame(np.array(fa.get_factor_variance()).T,columns=['SS cargas','Proporción','Acumulada'],index=['F1',
6 print(varianza.round(4).to_string())
7 print('\nCorrelaciones factoriales:')
8 print(pd.DataFrame(fa.phi_,index=L.columns,columns=L.columns).round(3).to_string())

```

	F1	F2	F3	F4
q1	0.401	-0.140	0.285	0.340
q2	0.097	-0.329	0.357	0.272
q3	0.116	0.293	-0.048	0.508
q4	0.125	0.165	0.137	0.510
q5	0.056	0.055	0.669	-0.131
q6	0.160	-0.347	0.161	0.264
q7	0.139	0.452	-0.049	0.299
q8	0.575	0.222	0.036	0.242
q9	0.437	-0.114	0.258	0.372
q10	0.417	-0.069	0.178	0.044
q11	0.266	0.457	0.200	0.102
q12	-0.011	0.133	0.269	-0.164
q13	0.560	0.082	-0.033	0.209
q14	0.757	0.028	0.179	-0.337
q15	0.361	-0.017	0.137	0.184
q16	0.741	0.215	-0.024	-0.200
q17	0.788	-0.009	-0.034	0.136
q18	0.232	-0.322	0.404	0.142
q19	-0.055	0.568	-0.177	0.078
q20	0.035	0.450	0.052	0.199
q21	0.471	0.165	-0.040	0.270
q22	0.857	-0.074	-0.021	0.113
q23	-0.094	0.042	0.700	0.066
q24	0.097	0.284	0.127	0.481
q25	0.101	0.533	0.131	0.082
q26	0.278	0.593	0.020	-0.072
q27	-0.020	0.612	0.382	0.068
q28	0.012	0.211	0.533	-0.016

Varianza por factor:

	SS cargas	Proporción	Acumulada
F1	4.3219	0.1544	0.1544
F2	2.7152	0.0970	0.2513
F3	2.1239	0.0759	0.3272
F4	1.7733	0.0633	0.3905

Correlaciones factoriales:

	F1	F2	F3	F4
F1	1.000	0.299	0.471	0.370
F2	0.299	1.000	0.130	0.129
F3	0.471	0.130	1.000	0.252
F4	0.370	0.129	0.252	1.000

4. Método de extracción: máxima verosimilitud y contraste con método principal

En el análisis factorial exploratorio existen distintas formas de extraer factores. En este notebook se reportan dos aproximaciones para que la decisión metodológica sea transparente.

Primero, se estima la solución principal mediante **máxima verosimilitud (ML)**. Esta especificación es la utilizada como referencia porque el objetivo de la pregunta es evaluar dimensiones latentes de la teoría de Blend. ML busca modelar la varianza común atribuible a factores latentes y separar esa varianza del error de medición.

Segundo, se estima una solución de sensibilidad mediante el método **principal**. Esta alternativa suele reportar una varianza acumulada más alta porque reproduce una mayor proporción de la varianza observada de los ítems. Por eso es útil como comparación, pero no se adopta como especificación principal: explicar más varianza observada no implica necesariamente representar mejor constructos latentes.

Ambas soluciones se estiman con rotación Oblimin, porque el enunciado indica que las dimensiones pueden estar correlacionadas.

```
1 # Comparación entre extracción por máxima verosimilitud y método principal.
2 # Se usa la misma base imputada y la misma rotación Oblimin para aislar el efecto del método de extracción.
3
4 fa_ml = FactorAnalyzer(n_factors=4, rotation='oblimin', method='ml')
5 fa_ml.fit(X)
6 var_ml = pd.DataFrame(
7     np.array(fa_ml.get_factor_variance()).T,
8     columns=['SS cargas', 'Proporción', 'Acumulada'],
9     index=['F1', 'F2', 'F3', 'F4']
10 )
11
12 fa_principal = FactorAnalyzer(n_factors=4, rotation='oblimin', method='principal')
13 fa_principal.fit(X)
14 var_principal = pd.DataFrame(
15     np.array(fa_principal.get_factor_variance()).T,
16     columns=['SS cargas', 'Proporción', 'Acumulada'],
17     index=['F1', 'F2', 'F3', 'F4']
18 )
19
20 comparacion_metodos = pd.DataFrame({
21     'Método': ['Máxima verosimilitud (ML)', 'Principal'],
22     'Rotación': ['Oblimin', 'Oblimin'],
23     'n': [len(X), len(X)],
24     'Varianza acumulada 4 factores': [var_ml['Acumulada'].iloc[-1], var_principal['Acumulada'].iloc[-1]]
25 })
26
27 print('Comparación de métodos de extracción con la misma muestra imputada:')
28 print(comparacion_metodos.assign(**{'Varianza acumulada 4 factores': comparacion_metodos['Varianza acumulada 4 factores']
29 print('
```

```

30 Varianza por factor - ML:')
31 print(var_ml.round(4).to_string())
32 print('
33 Varianza por factor - Principal:')
34 print(var_principal.round(4).to_string())
35 print('
36 Lectura: Principal explica más varianza observada, pero ML se mantiene como referencia porque modela factores latentes c
37

```

Comparación de métodos de extracción con la misma muestra imputada:

Método	Rotación	n	Varianza acumulada	4 factores
Máxima verosimilitud (ML)	Oblimin	239		39.05%
Principal	Oblimin	239		47.82%

Varianza por factor - ML:

	SS cargas	Proporción	Acumulada
F1	4.3219	0.1544	0.1544
F2	2.7152	0.0970	0.2513
F3	2.1239	0.0759	0.3272
F4	1.7733	0.0633	0.3905

Varianza por factor - Principal:

	SS cargas	Proporción	Acumulada
F1	4.8913	0.1747	0.1747
F2	2.4978	0.0892	0.2639
F3	2.4107	0.0861	0.3500
F4	3.5892	0.1282	0.4782

Lectura: Principal explica más varianza observada, pero ML se mantiene como referencia porque modela factores latentes comunes

5. Interpretación y confiabilidad

La solución se interpreta considerando conjuntamente contenido y cargas:

- F1: entusiasmo por diseño experimental.
- F2: amor por la enseñanza.
- F3: ausencia de habilidades interpersonales.
- F4: amor por la estadística.

Se calcula alfa con conjuntos conceptualmente coherentes. Algunos ítems presentan cargas cruzadas o débiles, por lo que la teoría se evalúa en grado, no solo contando factores.

```

1 def alpha(d):
2     k=d.shape[1]; return k/(k-1)*(1-d.var(ddof=1).sum()/d.sum(axis=1).var(ddof=1))
3 sets={
4     'Diseño experimental':['q8','q13','q14','q16','q17','q22'],
5     'Enseñanza':['q7','q10','q11','q19','q20','q25','q26'],
6     'Habilidades interpersonales deficientes':['q2','q5','q6','q12','q18','q23','q27','q28'],
7     'Estadística':['q1','q3','q4','q9','q15','q21','q24']}
8 for nombre,its in sets.items(): print(f'{nombre}: alpha={alpha(X[its]):.3f} ({len(its)} ítems)')

```

Diseño experimental: alpha=0.880 (6 ítems)
 Enseñanza: alpha=0.747 (7 ítems)
 Habilidades interpersonales deficientes: alpha=0.691 (8 ítems)
 Estadística: alpha=0.830 (7 ítems)

```

1 # Correlaciones ítem-total corregidas por subescala teórica.
2 # Verifica que ningún ítem esté invertido o mal codificado dentro de su subescala:
3 # una correlación ítem-total negativa indicaría necesidad de recodificación antes del alfa.
4 for nombre, its in sets.items():
5     sub = X[its]
6     print(f'\n{nombre}:')
7     for it in its:
8         resto = sub.drop(columns=it).sum(axis=1)
9         r = sub[it].corr(resto)
10        marca = ' <-- NEGATIVA' if r < 0 else ''
11        print(f' {it}: r ítem-total corregida = {r:.3f}{marca}')

```

Diseño experimental:
 q8: r ítem-total corregida = 0.714
 q13: r ítem-total corregida = 0.611
 q14: r ítem-total corregida = 0.634
 q16: r ítem-total corregida = 0.678
 q17: r ítem-total corregida = 0.767
 q22: r ítem-total corregida = 0.783

Enseñanza:
 q7: r ítem-total corregida = 0.476
 q10: r ítem-total corregida = 0.248
 q11: r ítem-total corregida = 0.538
 q19: r ítem-total corregida = 0.360
 q20: r ítem-total corregida = 0.505
 q25: r ítem-total corregida = 0.568
 q26: r ítem-total corregida = 0.583

Habilidades interpersonales deficientes:
 q2: r ítem-total corregida = 0.382
 q5: r ítem-total corregida = 0.486

```

q6: r item-total corregida = 0.261
q12: r item-total corregida = 0.170
q18: r item-total corregida = 0.446
q23: r item-total corregida = 0.566
q27: r item-total corregida = 0.333
q28: r item-total corregida = 0.424

Estadística:
q1: r item-total corregida = 0.636
q3: r item-total corregida = 0.516
q4: r item-total corregida = 0.539
q9: r item-total corregida = 0.626
q15: r item-total corregida = 0.529
q21: r item-total corregida = 0.603
q24: r item-total corregida = 0.647

```

6. Conclusión

Bartlett es significativo ($\chi^2(378) = 3045.39, p < 0.001$) y KMO=0.895, por lo que la matriz es adecuada. El análisis paralelo recomienda **cuatro factores** tanto con el percentil 95 (cuarto autovalor 1.505 contra umbral 1.501, decisión ajustada) como con la media de los autovalores aleatorios (umbral 1.445, decisión holgada), coincidiendo con Blend y con el respaldo de la expectativa teórica a priori. La solución rotada permite reconocer las cuatro áreas teóricas, especialmente diseño experimental y estadística/enseñanza.

Sin embargo, hay cargas cruzadas (por ejemplo q1, q9 y q27) e ítems sin carga factorial relevante o débiles (como q12), y la dimensión de habilidades interpersonales deficientes no queda completamente limpia. **La teoría de Blend recibe apoyo general respecto del número y contenido de factores, pero no apoyo perfecto a nivel de todos los ítems.** Se recomienda revisar o eliminar ítems ambiguos antes de una validación confirmatoria.

▼ Apéndice A. Especificaciones alternativas de sensibilidad

Este apéndice reproduce dos variantes útiles para entender cómo cambian algunos resultados bajo decisiones alternativas. No se usan como especificación principal.

1. **Principal + Oblimin + listwise, sin (ID)**: reproduce la lógica de una especificación con eliminación de casos incompletos. Esta variante alcanza una varianza acumulada de 47.88%, muy cercana a la solución principal con imputación y método principal. La diferencia principal no proviene de los casos faltantes, sino del método de extracción.
2. **Minres + Varimax + listwise, sin (ID)**: permite ver qué ocurre cuando se impone una rotación ortogonal. No se prefiere porque Varimax fuerza factores no correlacionados, mientras que el enunciado permite que las dimensiones estén correlacionadas.

En ambos casos se excluye (ID) porque no es un ítem del EECS-R ni mide un rasgo latente.

```

1 # --- Apéndice A: especificaciones alternativas sin ID ---
2 df_sens, _ = pyreadstat.read_sav(DATA_DIR / REQUIRED_DATA_FILE, apply_value_formats=False)
3 X_listwise = df_sens[items].dropna()
4
5 # A1. Principal + Oblimin + listwise
6 fa_principal_listwise = FactorAnalyzer(n_factors=4, rotation='oblimin', method='principal')
7 fa_principal_listwise.fit(X_listwise)
8 var_principal_listwise = pd.DataFrame(
9     np.array(fa_principal_listwise.get_factor_variance()).T,
10     columns=['SS cargas', 'Proporción', 'Acumulada'],
11     index=['F1', 'F2', 'F3', 'F4'])
12 )
13
14 # A2. Minres + Varimax + listwise
15 fa_varimax = FactorAnalyzer(n_factors=4, rotation='varimax', method='minres')
16 fa_varimax.fit(X_listwise)
17 var_varimax = pd.DataFrame(
18     np.array(fa_varimax.get_factor_variance()).T,
19     columns=['SS cargas', 'Proporción', 'Acumulada'],
20     index=['F1', 'F2', 'F3', 'F4'])
21 )
22 L_varimax = pd.DataFrame(fa_varimax.loadings_, index=items, columns=['F1', 'F2', 'F3', 'F4'])
23
24 print('Apéndice de sensibilidad sin ID')
25 print(f'Observaciones listwise usadas: {len(X_listwise)}')
26 print(f'Observaciones descartadas por listwise: {len(df_sens) - len(X_listwise)}')
27 print('
28 A1. Principal + Oblimin + listwise')
29 print(var_principal_listwise.round(4).to_string())
30 print(f'Varianza acumulada A1: {var_principal_listwise["Acumulada"].iloc[-1]*100:.2f}%')
31 print('
32 A2. Minres + Varimax + listwise')
33 print(var_varimax.round(4).to_string())
34 print(f'Varianza acumulada A2: {var_varimax["Acumulada"].iloc[-1]*100:.2f}%')
35 print('
36 Cargas factoriales Varimax:')
37 print(L_varimax.round(3).to_string())
38 print('
39 Lectura: estas alternativas son útiles para sensibilidad. La especificación principal sigue siendo ML + Oblimin con n=23
40

```

Observaciones descartadas por listwise: 8

A1. Principal + Oblimin + listwise
 SS cargas Proporción Acumulada
 F1 4.8080 0.1717 0.1717
 F2 2.5837 0.0923 0.2640
 F3 2.3110 0.0825 0.3465
 F4 3.7041 0.1323 0.4788
 Varianza acumulada A1: 47.88%

A2. Minres + Varimax + listwise
 SS cargas Proporción Acumulada
 F1 4.1833 0.1494 0.1494
 F2 3.8139 0.1362 0.2856
 F3 3.2596 0.1164 0.4020
 F4 1.6889 0.0603 0.4623
 Varianza acumulada A2: 46.23%

Cargas factoriales Varimax:

	F1	F2	F3	F4
q1	0.242	0.358	0.612	0.108
q2	-0.018	0.092	0.614	0.111
q3	0.638	0.149	0.235	-0.028
q4	0.538	0.098	0.435	0.021
q5	0.034	0.201	0.294	0.542
q6	-0.038	0.098	0.514	0.008
q7	0.602	0.207	0.044	0.027
q8	0.501	0.544	0.310	0.103
q9	0.292	0.385	0.608	0.103
q10	0.106	0.360	0.345	0.129
q11	0.530	0.347	0.106	0.301
q12	0.043	0.035	-0.031	0.320
q13	0.352	0.519	0.276	0.020
q14	0.039	0.701	0.139	0.343
q15	0.223	0.366	0.341	0.082
q16	0.253	0.709	0.020	0.192
q17	0.300	0.671	0.364	0.049
q18	-0.055	0.193	0.551	0.240
q19	0.481	0.024	-0.283	0.032
q20	0.514	0.136	0.009	0.150
q21	0.462	0.451	0.240	-0.004
q22	0.260	0.722	0.419	0.045
q23	0.114	0.027	0.400	0.526
q24	0.595	0.138	0.322	0.045
q25	0.549	0.182	-0.059	0.261
q26	0.528	0.370	-0.204	0.275
q27	0.575	0.155	0.004	0.471
q28	0.215	0.123	0.207	0.496

Lectura: estas alternativas son útiles para sensibilidad. La especificación principal sigue siendo ML + Oblimin con n=239.

Anexo 3: Código y output pregunta 3

Anexo 3: Código y output pregunta 3

Notebook ejecutado de la Pregunta 3

✓ Pregunta 3 — CFA, SEM e invariancia multigrupo con lavaan

Este notebook resuelve la Pregunta 3 usando `lavaan`, manteniendo Python solo como entorno de ejecución. La base se descarga desde el repositorio si no está disponible localmente.

Enunciado textual

Como recién llegado a la consultora, se analiza un proyecto sobre condiciones de trabajo, satisfacción y permanencia de trabajadores del sector telecomunicaciones. Los constructos son actitud hacia compañeros de trabajo, percepción del ambiente de trabajo, satisfacción con el trabajo, compromiso organizacional e intención de permanecer en el trabajo. Cada constructo se mide con cuatro indicadores observados. Se solicita evaluar: (a) la calidad del modelo de medición, incluyendo confiabilidad y validez; (b) cuál modelo estructural representa mejor los datos; (c) si las relaciones son equivalentes entre hombres y mujeres; y (d) interpretar los resultados.

✓ Respuesta

Se estima primero un CFA de cinco factores. Luego se comparan el modelo completamente mediado y el parcialmente mediado. Finalmente se evalúa invariancia multigrupo por género.

✓ Figuras del enunciado


Constructos e ítems considerados en la Pregunta 3

Constructos	Ítems*
Actitud hacia compañeros de trabajo	AC1 - ¿Cuán contento está con el trabajo de sus compañeros?
	AC2 - ¿Cómo se siente en su relación respecto a sus compañeros de trabajo?
	AC3 - ¿Qué tan seguido realiza actividades con sus compañeros de trabajo en días libres?
	AC4 - En general, ¿qué tan parecidos a Ud. son sus compañeros de trabajo?
Compromiso organizacional	CO1 - Mi trabajo en esta empresa me da una sensación de logros.
	CO2 - Estoy dispuesto a poner un gran esfuerzo mas allá de lo que se esperaba normalmente para ayudar a que esta empresa sea exitosa
	CO3 - Tengo un sentido de lealtad con esta empresa.
	CO4 - Estoy orgulloso de contarle a otras personas que trabajo en esta empresa.
Intención de permanecer en el trabajo	IP1 - No estoy buscando activamente otro trabajo.
	IP2 - Rara vez veo las ofertas de trabajo en sitios para esos fines.
	IP3 - No tengo interés en buscar trabajo durante los próximos 12 meses.
	IP4 - ¿Qué tan probable es que usted este trabajando para la misma empresa dentro de los próximos 12 meses?
Percepción del ambiente de trabajo	PA1 - Estoy muy conforme con el ambiente físico de trabajo en esta empresa.
	PA2 - El lugar en que trabajo está diseñado para facilitar mi trabajo.
	PA3 - Hay pocos obstáculos que me hacen ser menos productivo en mi lugar de trabajo.
	PA4 - ¿Qué término describe mejor el ambiente de trabajo en su empresa?
Satisfacción con el trabajo	ST1 - Considerando todas las cosas, me siento muy satisfecho cuando pienso en mi trabajo.
	ST2 - Cuando piensa en su trabajo, ¿qué tan satisfecho se siente?
	ST3 - ¿Que tan satisfecho está con su actual trabajo?
	ST4 - Como empleado, ¿qué tan satisfecho esta con su empleador?
Características personales	D1 - Género
	Edad
	EXP - Experiencia en años

* Las escalas específicas de cada ítem se encuentran detalladas en el archivo de datos **Laboral.sav**


Modelo completamente mediado

Modelo 1 (Completamente Mediado)



Modelo parcialmente mediado

Modelo 1 (Parcialmente Mediado)



```
1 # Instalación condicional para Google Colab.
2 # En local no hace nada si R y los paquetes ya existen.
3 import shutil, subprocess, textwrap, os, sys
4 if shutil.which('Rscript') is None:
5     subprocess.check_call(['apt-get', 'update', '-qq'])
6     subprocess.check_call(['apt-get', 'install', '-y', 'r-base'])
7 subprocess.check_call(['Rscript', '-e', "pkgs <- c('lavaan','haven'
8 print('R/lavaan listo')
9
```

R/lavaan listo

```
1 from pathlib import Path
2 r_code = r'''
3 # Workaround for macOS/R setups where parallel::detectCores() re
4 ns <- asNamespace('parallel')
5 unlockBinding('detectCores', ns)
6 assign('detectCores', function(all.tests=FALSE, logical=TRUE) 8L
7 lockBinding('detectCores', ns)
8
9 pkgs <- c('lavaan','haven','psych')
10 missing <- pkgs[!sapply(pkgs, requireNamespace, quietly=TRUE)]
11 if (length(missing) > 0) install.packages(missing, repos='https:
12
13 library(lavaan)
14 library(haven)
15 library(psych)
16
17 find_data <- function() {
18     candidates <- c(
19         '../data/Laboral.sav'62
```

```

20   '../..data/Laboral.sav',
21   'Tarea2/data/Laboral.sav',
22   'data/Laboral.sav',
23   'Laboral.sav'
24 )
25 for (f in candidates) if (file.exists(f)) return(f)
26 url <- 'https://raw.githubusercontent.com/sebabecerra/Metodos-
27 download.file(url, 'Laboral.sav', mode='wb', quiet=TRUE)
28 return('Laboral.sav')
29 }
30
31 base <- find_data()
32 d <- as.data.frame(read_sav(base))
33 vars <- c(paste0('AC',1:4), paste0('PA',1:4), paste0('ST',1:4),
34 d <- d[, vars]
35 d$GENERO <- as.integer(d$GENERO)
36
37 cat('CHEQUEO INICIAL DE LA BASE\n')
38 cat('Archivo usado:', base, '\n')
39 cat('Número de observaciones:', nrow(d), '\n')
40 cat('Número de variables analizadas:', ncol(d), '\n')
41 cat('Frecuencia GENERO: 0=Masculino, 1=Femenino\n')
42 print(table(d$GENERO, useNA='ifany'))
43 cat('Datos perdidos totales:', sum(is.na(d)), '\n')
44 cat('Datos perdidos por variable:\n')
45 print(colSums(is.na(d)))
46 cat('Descriptivos básicos de los indicadores y género:\n')
47 print(round(psych::describe(d)[, c('n','mean','sd','min','max')])
48 cat('\n')
49
50 measurement <- '
51 AC =~ AC1 + AC2 + AC3 + AC4
52 PA =~ PA1 + PA2 + PA3 + PA4
53 ST =~ ST1 + ST2 + ST3 + ST4
54 CO =~ CO1 + CO2 + CO3 + CO4
55 IP =~ IP1 + IP2 + IP3 + IP4
56 '
57 complete_model <- paste0(measurement, '
58 ST ~ PA + AC
59 CO ~ PA + AC + ST
60 IP ~ ST + CO
61 ')
62 partial_model <- paste0(measurement, '
63 ST ~ PA + AC
64 CO ~ PA + AC + ST
65 IP ~ PA + AC + ST + CO
66 ')
67
68 fit_cfa <- cfa(measurement, data=d, estimator='MLR', missing='fi
69 fit_complete <- sem(complete_model, data=d, estimator='MLR', mis
70 fit_partial <- sem(partial_model, data=d, estimator='MLR', missi
71
72 fm <- c('chisq.scaled','df.scaled','pvalue.scaled','cfi.robust',
73 cat('1) CFA robusto\n')
74 print(round(fitMeasures(fit_cfa, fm), 4))

```

```

75
76 pe_cfa <- parameterEstimates(fit_cfa, standardized=TRUE, ci=TRUE)
77 loadings <- pe_cfa[pe_cfa$op=='~', c('lhs','rhs','est','se','z')]
78 cat('\n2) Cargas factoriales CFA\n')
79 print(loadings)
80
81 cat('\n3) Confiabilidad y AVE\n')
82 quality <- data.frame()
83 for (fac in c('AC','PA','ST','CO','IP')) {
84   items <- pe_cfa[pe_cfa$op=='~' & pe_cfa$lhs==fac,]
85   lambda <- items$std.all
86   cr <- sum(lambda)^2 / (sum(lambda)^2 + sum(1-lambda^2))
87   ave <- mean(lambda^2)
88   alpha <- psych::alpha(d[, items$rhs], warnings=FALSE)$total$ra
89   quality <- rbind(quality, data.frame(Constructo=fac, Alfa=alpha, CR=cr))
90 }
91 print(round_df <- within(quality, {Alfa=round(Alfa,4); CR=round(CR,4)}))
92
93 cat('\n4) Correlaciones latentes CFA y Fornell-Larcker\n')
94 std <- standardizedSolution(fit_cfa)
95 latcorr <- std[std$op=='~~' & std$lhs %in% c('AC','PA','ST','CO','IP'),]
96 print(latcorr)
97 cat('Correlación latente máxima absoluta:', max(abs(latcorr$est)))
98
99 hmt <- function(data, a, b) {
100   ra <- cor(data[,a], use='pairwise.complete.obs')
101   rb <- cor(data[,b], use='pairwise.complete.obs')
102   rab <- cor(data[,a], data[,b], use='pairwise.complete.obs')
103   mean(abs(as.vector(rab))) / sqrt(mean(abs(ra[upper.tri(ra)])))
104 }
105 constructos <- list(AC=paste0('AC',1:4), PA=paste0('PA',1:4), ST=paste0('ST',1:4), CO=paste0('CO',1:4), IP=paste0('IP',1:4))
106 hmt_vals <- c()
107 for (i in seq_along(constructos)) for (j in seq_along(constructos)) if (i < j) {
108   cat('HTMT máximo:', max(hmt_vals), '\n')
109   hmt_vals <- c(hmt_vals, hmt(data[,constructos[i]], constructos[j]))
110 }
111 cat('\n5) Comparación SEM completo vs parcial\n')
112 fits_table <- rbind(Completo=fitMeasures(fit_complete, fm), Parcial=fitMeasures(fit_partial, fm))
113 print(round(fits_table, 4))
114 cat('\nPrueba robusta de diferencia Satorra-Bentler\n')
115 print(lavTestLRT(fit_complete, fit_partial, method='satorra.bentler'))
116 cat('\n6) Coeficientes estructurales modelo parcial\n')
117 pe_partial <- parameterEstimates(fit_partial, standardized=TRUE, ci=TRUE)
118 print(pe_partial[pe_partial$op=='~', c('lhs','rhs','est','se','z')])
119
120 cat('\n7) Efectos indirectos bootstrap (ML, 5000 remuestras)\n')
121 model_boot <- '
122 AC =~ AC1 + AC2 + AC3 + AC4
123 PA =~ PA1 + PA2 + PA3 + PA4
124 ST =~ ST1 + ST2 + ST3 + ST4
125 CO =~ CO1 + CO2 + CO3 + CO4
126 IP =~ IP1 + IP2 + IP3 + IP4
127 ST ~ a1*PA + a2*AC
128 CO ~ d1*PA + d2*AC + a3*ST
129 IP ~ c1*PA + c2*AC + b1*ST + b2*CO

```

```

130 pa_st_ip := a1*b1
131 pa_co_ip := d1*b2
132 pa_st_co_ip := a1*a3*b2
133 pa_ind_total := pa_st_ip + pa_co_ip + pa_st_co_ip
134 ac_st_ip := a2*b1
135 ac_co_ip := d2*b2
136 ac_st_co_ip := a2*a3*b2
137 ac_ind_total := ac_st_ip + ac_co_ip + ac_st_co_ip
138 '
139 set.seed(12345)
140 fit_boot <- sem(model_boot, data=d, estimator='ML', missing='fim
141 pe_boot <- parameterEstimates(fit_boot, standardized=TRUE, ci=TR
142 print(pe_boot[pe_boot$op==':=', c('lhs','est','se','z','pvalue',
143
144 cat('\n8) Invariancia multigrupo\n')
145 fit_config <- sem(partial_model, data=d, group='GENERO', estimat
146 fit_metric <- sem(partial_model, data=d, group='GENERO', group.e
147 fit_metric_partial <- sem(partial_model, data=d, group='GENERO',
148 fit_scalar <- sem(partial_model, data=d, group='GENERO', group.e
149 fit_struct <- sem(partial_model, data=d, group='GENERO', group.e
150 fits <- list(Configural=fit_config, Metrica=fit_metric, Metrica_
151 for (nm in names(fits)) {
152   cat('\n', nm, '\n')
153   print(round(fitMeasures(fits[[nm]]), c('chisq.scaled','df.scaled
154 }
155 cat('\nDiferencias robustas\n')
156 print(lavTestLRT(fit_config, fit_metric, method='satorra.bentler
157 print(lavTestLRT(fit_config, fit_metric_partial, method='satorra
158 print(lavTestLRT(fit_metric_partial, fit_scalar, method='satorra
159 print(lavTestLRT(fit_metric_partial, fit_struct, method='satorra
160
161 cat('\n9) Diferencias específicas por género\n')
162 pec <- parameterEstimates(fit_config, standardized=TRUE, ci=TRUE
163 reg <- pec[pec$op=='~',]
164 for (path in unique(paste(reg$lhs, reg$rhs, sep='~'))) {
165   lhs <- sub('~.*','',path); rhs <- sub('.*~','',path)
166   r1 <- reg[reg$lhs==lhs & reg$rhs==rhs & reg$group==1,]
167   r2 <- reg[reg$lhs==lhs & reg$rhs==rhs & reg$group==2,]
168   diff <- r1$est-r2$est; se <- sqrt(r1$se^2 + r2$se^2); z <- dif
169   cat(path, 'hombres=',round(r1$est,4),'mujeres=',round(r2$est,4
170 }
171 '''
172 Path('pregunta3_lavaan.R').write_text(r_code)
173 print('Script R creado: pregunta3_lavaan.R')
174

```

Script R creado: pregunta3_lavaan.R

```

1 import subprocess, sys
2 resultado = subprocess.run(['Rscript', 'pregunta3_lavaan.R'], tex
3 print(resultado.stdout)
4 if resultado.returncode != 0:
5     print(resultado.stderr)

```

```
6 raise SystemExit(resultado.returncode)
7
```

```
Base usada: ../data/Laboral.sav
N total: 400
Frecuencia GENERO: 0=Masculino, 1=Femenino
```

```
0 1
200 200
Valores perdidos totales: 0
```

1) CFA robusto

chisq.scaled	df.scaled	pvalue.scaled	cfi.robust	tli.robust
216.902	160.000	0.002	0.987	0.985
rmsea.robust	srmr	aic	bic	
0.028	0.033	24647.543	24926.945	

2) Cargas factoriales CFA

	lhs	rhs	est	se	z	pvalue	ci.lower	ci.upper	std.all
1	AC	AC1	1.144	0.045	25.321	0	1.056	1.233	0.822
2	AC	AC2	1.414	0.053	26.878	0	1.311	1.517	0.820
3	AC	AC3	1.187	0.043	27.559	0	1.102	1.271	0.837
4	AC	AC4	1.312	0.053	24.744	0	1.208	1.416	0.815
5	PA	PA1	1.265	0.116	10.869	0	1.037	1.493	0.692
6	PA	PA2	1.307	0.101	12.947	0	1.109	1.505	0.804
7	PA	PA3	1.038	0.078	13.367	0	0.886	1.190	0.778
8	PA	PA4	1.156	0.084	13.814	0	0.992	1.320	0.823
9	ST	ST1	0.986	0.063	15.613	0	0.862	1.109	0.737
10	ST	ST2	1.008	0.066	15.284	0	0.879	1.137	0.737
11	ST	ST3	0.916	0.060	15.321	0	0.799	1.033	0.697
12	ST	ST4	0.907	0.056	16.133	0	0.797	1.017	0.709
13	CO	CO1	1.471	0.107	13.777	0	1.262	1.681	0.583
14	CO	CO2	1.934	0.161	12.027	0	1.618	2.249	0.886
15	CO	CO3	1.151	0.148	7.770	0	0.861	1.442	0.657
16	CO	CO4	1.714	0.155	11.077	0	1.411	2.018	0.836
17	IP	IP1	0.706	0.051	13.961	0	0.607	0.805	0.811
18	IP	IP2	0.757	0.049	15.520	0	0.662	0.853	0.864
19	IP	IP3	0.752	0.045	16.807	0	0.664	0.839	0.741
20	IP	IP4	0.823	0.041	19.893	0	0.742	0.905	0.852

3) Confiabilidad y AVE

	Constructo	Alfa	CR	AVE	sqrtAVE	CargaMin	CargaMax
1	AC	0.8908	0.8941	0.6786	0.8238	0.8154	0.8372
2	PA	0.8474	0.8576	0.6019	0.7758	0.6917	0.8229
3	ST	0.8112	0.8115	0.5185	0.7201	0.6968	0.7371
4	CO	0.8227	0.8341	0.5637	0.7508	0.5834	0.8855
5	IP	0.8863	0.8900	0.6699	0.8185	0.7410	0.8641

4) Correlaciones latentes CFA y Fornell-Larcker

	lhs	rhs	est.std
46	AC	PA	0.257
47	AC	ST	0.025
48	AC	CO	0.307
49	AC	IP	0.308
50	PA	ST	0.228
51	PA	CO	0.497
52	PA	IP	0.562
53	ST	CO	0.190
54	ST	IP	0.214
55	CO	IP	0.553

Inspección secuencial de cargas para la invariancia métrica parcial

El documento reporta que la invariancia métrica completa queda levemente fuera del criterio práctico y que se identificó la carga de (C03) mediante inspección secuencial. Esta celda documenta ese procedimiento: se libera **una carga a la vez** sobre el modelo métrico y se compara cada solución contra el configural. La carga cuya liberación produce la mayor recuperación de ajuste (menor $\Delta\chi^2$ escalado y ΔCFI dentro del criterio) es la candidata a invariancia parcial.

```
1 from pathlib import Path
2 r_seq = r""""
3 ns <- asNamespace('parallel'); unlockBinding('detectCores', ns)
4 assign('detectCores', function(all.tests=FALSE, logical=TRUE) 8L,
5 library(lavaan); library(haven)
6
7 find_data <- function() {
8   candidates <- c('../data/Laboral.sav', '../..data/Laboral.sav',
9   for (f in candidates) if (file.exists(f)) return(f)
10  download.file('https://raw.githubusercontent.com/sebabecerra/Me
11  'Laboral.sav'
12 }
13 d <- as.data.frame(read_sav(find_data()))
14 vars <- c(paste0('AC',1:4),paste0('PA',1:4),paste0('ST',1:4),paste
15 d <- d[, vars]; d$GENERO <- as.integer(d$GENERO)
16
17 measurement <- '
18 AC =~ AC1 + AC2 + AC3 + AC4
19 PA =~ PA1 + PA2 + PA3 + PA4
20 ST =~ ST1 + ST2 + ST3 + ST4
21 CO =~ CO1 + CO2 + CO3 + CO4
22 IP =~ IP1 + IP2 + IP3 + IP4
23 '
24 partial_model <- paste0(measurement, '
25 ST ~ PA + AC
26 CO ~ PA + AC + ST
27 IP ~ PA + AC + ST + CO
28 ')
29
30 fit_config <- sem(partial_model, data=d, group='GENERO', estimato
31 cfi_config <- fitMeasures(fit_config, 'cfi.robust')
32
33 items <- c(paste0('AC',1:4),paste0('PA',1:4),paste0('ST',1:4),pas
34 factores <- rep(c('AC','PA','ST','CO','IP'), each=4)
35
36 cat('Liberacion de una carga a la vez sobre el modelo metrico (coi
37 cat(sprintf('%-10s %12s %10s %10s\n','Carga libre','Dchi2_SB(14)'
38 resultados <- data.frame())
```

```

39 for (i in seq_along(items)) {
40   etiqueta <- paste0(factoros[i], '~', items[i])
41   fit_i <- try(sem(partial_model, data=d, group='GENERO', group.e
42                 group.partial=etiqueta, estimator='MLR', missi
43   if (inherits(fit_i, 'try-error')) next
44   lrt <- lavTestLRT(fit_config, fit_i, method='satorra.bentler.20
45   dcfi <- fitMeasures(fit_i, 'cfi.robust') - cfi_config
46   cat(sprintf('%-10s %12.3f %10.4g %10.4f\n', etiqueta, lrt$`Chis
47   resultados <- rbind(resultados, data.frame(carga=etiqueta, dchi
48 }
49 mejor <- resultados[which.max(resultados$dcfi),]
50 cat('\nMayor recuperacion de ajuste al liberar:', mejor$carga, '\n
51 """"
52 Path('pregunta3_invarianza_secuencial.R').write_text(r_seq)
53 import subprocess
54 res = subprocess.run(['Rscript', 'pregunta3_invarianza_secuencial.l
55 print(res.stdout)
56 if res.returncode != 0:
57     print(res.stderr); raise SystemExit(res.returncode)

```

Liberacion de una carga a la vez sobre el modelo metrico (comparado con el modelo libre)

Carga libre	Dchi2_SB(14)	p	DCFI
AC=~AC1	33.607	0.002353	-0.0081
AC=~AC2	30.059	0.00749	-0.0070
AC=~AC3	41.003	0.0001777	-0.0109
AC=~AC4	41.111	0.0001709	-0.0111
PA=~PA1	41.226	0.0001639	-0.0110
PA=~PA2	40.339	0.0002258	-0.0103
PA=~PA3	41.481	0.0001494	-0.0109
PA=~PA4	41.550	0.0001456	-0.0112
ST=~ST1	40.708	0.0001977	-0.0106
ST=~ST2	41.630	0.0001415	-0.0112
ST=~ST3	37.695	0.0005785	-0.0101
ST=~ST4	41.517	0.0001474	-0.0112
C0=~C01	39.249	0.0003338	-0.0103
C0=~C02	38.065	0.0005079	-0.0094
C0=~C03	30.968	0.005601	-0.0058
C0=~C04	46.043	2.759e-05	-0.0116
IP=~IP1	39.932	0.0002614	-0.0106
IP=~IP2	41.869	0.0001297	-0.0111
IP=~IP3	40.981	0.0001791	-0.0111
IP=~IP4	41.704	0.0001378	-0.0108

Mayor recuperacion de ajuste al liberar: C0=~C03

Conclusión operativa

El modelo de medición presenta buen ajuste, confiabilidad y validez. El modelo parcialmente mediado representa mejor los datos que el completamente mediado. Los efectos indirectos apoyados son los que pasan por compromiso organizacional. En el análisis multigrupo se obtiene invarianza métrica parcial, no se comparan

medias latentes por falta de invariancia escalar, y los caminos estructurales muestran comparabilidad aproximada con una posible diferencia localizada en (AC $\rightarrow$ ST).

Anexo 4: Código y output pregunta 4

Anexo 4: Código y output pregunta 4

Notebook ejecutado de la Pregunta 4

✓ Pregunta 4 — MANOVA factorial de lealtad

Métodos Cuantitativos de la Investigación en Negocios — Tarea 2 (2026)

```
1 # Instalación condicional de dependencias para Google Colab.
2 # En ejecución local no instala nada si los paquetes ya están disponibles.
3 import importlib, subprocess, sys
4
5 def instalar_si_falta(import_name, package_name=None):
6     package_name = package_name or import_name
7     try:
8         importlib.import_module(import_name)
9     except ImportError:
10         print(f'Instalando {package_name}...')
11         subprocess.check_call([sys.executable, '-m', 'pip', 'install', '-q', package_name])
12
13 instalar_si_falta('pyreadstat', 'pyreadstat')
14 instalar_si_falta('pingouin', 'pingouin')
15
16 print('Dependencias verificadas y entorno inicial preparado.')
17
```

Dependencias verificadas y entorno inicial preparado.

✓ Enunciado de la pregunta 4

4. La empresa HBAT produce y vende productos de papel a dos industrias: Impresores de revistas e impresores de diarios. Los productos llegan a estos clientes a través de dos canales: Directo (Fuerza de Ventas) e Indirecto (Agentes). HBAT realizó una investigación de mercados en las que recolectó información en un sinnúmero de variables, métricas y no métricas, disponibles en el archivo **HBAT200.sav**, en una muestra de 200 clientes.

Entre las variables consideradas se encuentran algunas asociadas al resultado de compras y relación (5 variables), y variables descriptivas de las empresas de las cuales se recolectó información. Las variables se describen a continuación:

Datos de Clasificación de las empresas encuestadas

- X1 - Tipo de Cliente.
- X2 - Tipo de Industria.
- X3 - Tamaño de la Empresa.
- X4 - Región.
- X5 - Sistema de Distribución.

Resultado de Compras y Relación con HBAT

- X19 - Satisfacción.
- X20 - Intención de Recomendar a HBAT.
- X21 - Intención de Recomprar a HBAT.
- X22 - Nivel de Compras de HBAT.
- X23 - Considera Alianza Estratégica con HBAT.

Los ejecutivos de HBAT tienen diversas preguntas respecto a su desempeño y el nivel de satisfacción de sus clientes. En particular, están interesados en conocer el efecto de “Tamaño de la Empresa” y el “Tipo de Distribución” en la lealtad de los clientes, la cual consideran un constructo compuesto por tres variables: X19, Satisfacción; X20, Intención de Recomendar; X21, Intención de Recomprar.

En particular, desean determinar si:

- a) ¿Incide el tipo de distribución en la lealtad de los clientes?
- b) ¿Se comportan los clientes de forma distinta en términos de su lealtad dependiendo de su tamaño?
- c) ¿Son las variables tipo de distribución y tamaño antecedentes independientes de la lealtad?

Respuesta

Como la lealtad se mide mediante tres variables relacionadas, la pregunta se resuelve mediante un MANOVA factorial 2x2. Este enfoque permite evaluar simultáneamente el efecto del tipo de distribución, el tamaño de la empresa y su interacción sobre satisfacción, recomendación y recompra.

```
1 from pathlib import Path
2 from urllib.request import urlretrieve, urlopen
3 import ssl
4 import warnings
5 warnings.filterwarnings('ignore')
6
```

```

7 import numpy as np
8 import pandas as pd
9 import pyreadstat
10 from scipy import stats
11 import statsmodels.api as sm
12 import statsmodels.formula.api as smf
13
14 pd.set_option('display.max_columns', 100)
15 pd.set_option('display.width', 160)
16
17 # Base requerida para este notebook.
18 # Funciona localmente y también en Google Colab abierto desde GitHub.
19 REQUIRED_DATA_FILE = 'HBAT_200.sav'
20 RAW_DATA_BASE = 'https://raw.githubusercontent.com/sebabecerra/Metodos-Cuantitativos-DEN/main/Tarea2/data'
21
22 def encontrar_o_descargar_base(filename):
23     candidatas = [
24         Path.cwd() / 'data',                # ejecución desde Tarea2
25         Path.cwd().parent / 'data',         # ejecución desde Tarea2/notebooks
26         Path.cwd() / 'Tarea2' / 'data',     # ejecución desde raíz del repo o Colab
27         Path.cwd()                          # respaldo: base junto al notebook
28     ]
29     for ruta in candidatas:
30         if (ruta / filename).exists():
31             return ruta
32
33     # Si Colab no tiene la carpeta del repo clonada, se descarga la base desde GitHub.
34     destino_dir = Path.cwd() / 'Tarea2' / 'data'
35     destino_dir.mkdir(parents=True, exist_ok=True)
36     destino = destino_dir / filename
37     url = f'{RAW_DATA_BASE}/{filename}'
38     print(f'Base {filename} no encontrada localmente. Descargando desde GitHub...')
39     try:
40         urlretrieve(url, destino)
41     except Exception as error:
42         # Respaldo útil en algunos entornos locales con problemas de certificados SSL.
43         # En Colab normalmente no se activa, pero evita fallas si Python no encuentra certificados.
44         print('Descarga estándar falló; intentando respaldo SSL...')
45         contexto = ssl.create_unverified_context()
46         with urlopen(url, context=contexto) as respuesta, open(destino, 'wb') as archivo:
47             archivo.write(respuesta.read())
48     return destino_dir
49
50 DATA_DIR = encontrar_o_descargar_base(REQUIRED_DATA_FILE)
51 print('Directorio de datos:', DATA_DIR)
52 print('Base usada:', DATA_DIR / REQUIRED_DATA_FILE)
53

```

Directorio de datos: /Users/sbc/projects/Metodos-Cuantitativos-DEN/Tarea2/data
Base usada: /Users/sbc/projects/Metodos-Cuantitativos-DEN/Tarea2/data/HBAT_200.sav

✓ 1. Diseño, procedimiento e hipótesis

La lealtad se representa mediante satisfacción, recomendación y compra. Se aplica MANOVA factorial 2×2 con tipo de distribución y tamaño. Se prueban:

- H01: la distribución no se asocia conjuntamente con la lealtad.
- H02: el tamaño no se asocia conjuntamente con la lealtad.
- H03: distribución y tamaño actúan independientemente (sin interacción).

Tras MANOVA se analizan ANOVA univariados y medias de celdas.

```

1 from statsmodels.multivariate.manova import MANOVA
2 from statsmodels.stats.anova import anova_lm
3 import pingouin as pg
4
5 # Chequeo inicial de la base.
6 # Se carga la base completa; no se filtran observaciones ni se toma una submuestra.
7 df, meta = pyreadstat.read_sav(DATA_DIR/'HBAT_200.sav', apply_value_formats=False)
8 dvs = ['Satisfaccion', 'Recomendacion', 'Compra']
9 factores = ['Tipo_Dist', 'Tamaño_Empresa']
10
11 print('Archivo usado:', DATA_DIR/'HBAT_200.sav')
12 print('Número de observaciones:', len(df))
13 print('Número de variables:', df.shape[1])
14 print('Dimensión de la base:', df.shape)
15 print('Datos perdidos totales:', int(df[dvs + factores].isna().sum().sum()))
16 print('\nDatos perdidos por variable usada:')
17 print(df[dvs + factores].isna().sum().to_string())
18 print('\nCodificación observada de factores:')
19 for v in factores:

```

```

20 print(f'\n{v}:')
21 print(df[v].value_counts(dropna=False).sort_index().to_string())
22 print('\nTamaños de celda:')
23 print(df.groupby(['Tipo_Dist', 'Tamaño_Empresa']).size().rename('n').to_string())
24 print('\nDescriptivos de variables dependientes:')
25 print(df[dvs].describe().round(3).to_string())
26 print('\nMedias por celda:')
27 print(df.groupby(['Tipo_Dist', 'Tamaño_Empresa'])[dvs].mean().round(3).to_string())
28 print(f'\nF crítico univariado (95%; 1,196) = {stats.f.ppf(.95,1,196):.4f}')
29

```

Archivo usado: /Users/sbc/projects/Metodos-Cuantitativos-DEN/Tarea2/data/HBAT_200.sav

Número de observaciones: 200

Número de variables: 11

Dimensión de la base: (200, 11)

Datos perdidos totales: 0

Datos perdidos por variable usada:

Satisfaccion 0

Recomendacion 0

Recompra 0

Tipo_Dist 0

Tamaño_Empresa 0

Codificación observada de factores:

Tipo_Dist:

Tipo_Dist

0.0 108

1.0 92

Tamaño_Empresa:

Tamaño_Empresa

0.0 98

1.0 102

Tamaños de celda:

Tipo_Dist Tamaño_Empresa

0.0 0.0 45

1.0 1.0 63

0.0 0.0 53

1.0 1.0 39

Descriptivos de variables dependientes:

	Satisfaccion	Recomendacion	Recompra
count	200.000	200.000	200.000
mean	6.952	6.952	7.665
std	1.241	1.083	0.893
min	4.700	4.000	4.300
25%	6.000	6.100	7.100
50%	7.050	7.000	7.600
75%	7.900	7.650	8.200
max	9.900	9.900	9.900

Medias por celda:

Tipo_Dist	Tamaño_Empresa	Satisfaccion	Recomendacion	Recompra
0.0	0.0	6.211	6.091	7.142
1.0	1.0	6.406	6.771	7.475
0.0	0.0	7.128	7.079	7.670
1.0	1.0	8.449	8.067	8.569

F crítico univariado (95%; 1,196) = 3.8893

2. Consistencia de la medida de lealtad y supuestos

Se reportan alfa, correlaciones, Box M para igualdad de matrices de covarianza y Levene por variable. MANOVA es razonablemente robusto con tamaños similares; ante violaciones se privilegia Pillai, aunque también se presenta Wilks.

La consistencia se calcula con $\alpha = \frac{k}{k-1} \left(1 - \frac{\sum_i s_i^2}{s_T^2} \right)$. Reemplazando ($k = 3$, $\sum s_i^2 = 3.5109$, $s_T^2 = 8.4457$):

$\alpha = \frac{3}{2} \left(1 - \frac{3.5109}{8.4457} \right) = 0.876$. Los estadísticos de comparación al 95% son $\chi_{0.95,18}^2 = 28.87$ para Box M y $F_{0.95,3,196} = 2.6507$ para Levene: Box M (27.55) no supera su crítico, por lo que no se rechaza la igualdad de matrices de covarianza; Levene lo supera en satisfacción (4.93) y recompra (4.55), pero no en recomendación (1.72).

```

1 def alpha(d):
2     k=d.shape[1]; return k/(k-1)*(1-d.var(ddof=1).sum()/d.sum(axis=1).var(ddof=1))
3     print('Alfa lealtad=',round(alpha(df[dvs]),4)); print('\nCorrelaciones:\n',df[dvs].corr().round(3).to_string())
4     df['grupo']=df.Tipo_Dist.astype(str)+'_'+df.Tamaño_Empresa.astype(str)
5     print('\nBox M:\n',pg.box_m(df,dvs=dvs,group='grupo').round(4).to_string())
6     for v in dvs:
7         grupos=[g[v] for _,g in df.groupby('grupo')]; st,p=stats.levene(*grupos); print(f'Levene {v}: F={st:.4f}, p={p:.4f}')
8     print(f'\nchi2 crítico Box M (95%, gl=18) = {stats.chi2.ppf(.95,18):.4f}')
9     print(f'F crítico Levene (95%; 3,196) = {stats.f.ppf(.95,3,196):.4f}')

```

Alfa lealtad= 0.8764

Correlaciones:

	Satisfaccion	Recomendacion	Recompra
Satisfaccion	1.000	0.762	0.726
Recomendacion	0.762	1.000	0.661
Recompra	0.726	0.661	1.000

Box M:

```
Chi2    df    pval  equal_cov
box 27.551 18.0 0.0692      True
Levene Satisfaccion: F=4.9332, p=0.00252
Levene Recomendacion: F=1.7195, p=0.1643
Levene Recompra: F=4.5532, p=0.004149
```

chi2 crítico Box M (95%, gl=18) = 28.8693
F crítico Levene (95%; 3,196) = 2.6507

3. MANOVA factorial

La interacción prueba directamente si distribución y tamaño son antecedentes independientes. Si es significativa, la asociación de una variable varía según el nivel de la otra.

Con efectos de un grado de libertad (diseño 2×2), las cuatro pruebas multivariadas (Pillai, Wilks, Hotelling y Roy) producen exactamente el mismo F , y este se obtiene directamente de Λ mediante

$$F = \frac{1 - \Lambda}{\Lambda} \cdot \frac{gl_2}{gl_1}.$$

Por ejemplo, para distribución: $F = \frac{1-0.8526}{0.8526} \cdot \frac{194}{3} = 11.18$. El estadístico de comparación al 95% es $F_{0.95;3,194} = 2.6512$: se rechaza cada H_0 cuyo F observado lo supere.

```
1 ma=MANOVA.from_formula('Satisfaccion + Recomendacion + Recompra ~ C(Tipo_Dist) * C(Tamaño_Empresa)',df)
2 print(ma.mv_test())
3 print(f'F crítico multivariado (95%; 3,194) = {stats.f.ppf(.95,3,194):.4f}')
```

Multivariate linear model					
Intercept	Value	Num DF	Den DF	F Value	Pr > F
Wilks' lambda	0.0436	3.0000	194.0000	1419.8017	0.0000
Pillai's trace	0.9564	3.0000	194.0000	1419.8017	0.0000
Hotelling-Lawley trace	21.9557	3.0000	194.0000	1419.8017	0.0000
Roy's greatest root	21.9557	3.0000	194.0000	1419.8017	0.0000
C(Tipo_Dist)	Value	Num DF	Den DF	F Value	Pr > F
Wilks' lambda	0.8526	3.0000	194.0000	11.1840	0.0000
Pillai's trace	0.1474	3.0000	194.0000	11.1840	0.0000
Hotelling-Lawley trace	0.1729	3.0000	194.0000	11.1840	0.0000
Roy's greatest root	0.1729	3.0000	194.0000	11.1840	0.0000
C(Tamaño_Empresa)	Value	Num DF	Den DF	F Value	Pr > F
Wilks' lambda	0.9028	3.0000	194.0000	6.9588	0.0002
Pillai's trace	0.0972	3.0000	194.0000	6.9588	0.0002
Hotelling-Lawley trace	0.1076	3.0000	194.0000	6.9588	0.0002
Roy's greatest root	0.1076	3.0000	194.0000	6.9588	0.0002
C(Tipo_Dist):C(Tamaño_Empresa)	Value	Num DF	Den DF	F Value	Pr > F
Wilks' lambda	0.9034	3.0000	194.0000	6.9167	0.0002
Pillai's trace	0.0966	3.0000	194.0000	6.9167	0.0002
Hotelling-Lawley trace	0.1070	3.0000	194.0000	6.9167	0.0002
Roy's greatest root	0.1070	3.0000	194.0000	6.9167	0.0002

F crítico multivariado (95%; 3,194) = 2.6512

4. ANOVA univariados y tamaño de efecto

Se calcula eta cuadrado parcial $\eta_p^2 = SC_{efecto} / (SC_{efecto} + SC_{error})$.

El estadístico de comparación de los ANOVA univariados al 95% es $F_{0.95;1,196} = 3.8893$; se rechaza H_0 cuando el F observado lo supera. A modo de ilustración del tamaño de efecto, para la interacción en satisfacción: $\eta_p^2 = \frac{15.3264}{15.3264+174.0669} = 0.081$.

Dado que se realizan tres pruebas univariadas por familia de efectos, se usa como referencia adicional la corrección de Bonferroni: $\alpha = 0.05/3 = 0.0167$. Con este criterio, la interacción sigue siendo significativa en satisfacción ($p < 0.001$) y en recompra ($p = 0.0099 < 0.0167$), y no significativa en recomendación ($p = 0.221$).

```
1 for v in dvs:
2     fit=smf.ols(f'{v} ~ C(Tipo_Dist) * C(Tamaño_Empresa)',df).fit(); tab=anova_lm(fit,typ=2); err=tab.loc['Residual']
3     print('\n',v); print(tab.round(4).to_string())
4     print(f'\nF crítico univariado (95%; 1,196) = {stats.f.ppf(.95,1,196):.4f}')
5     print(f'F crítico univariado con Bonferroni (alfa=0.05/3; 1,196) = {stats.f.ppf(1-0.05/3,1,196):.4f}')
```

Satisfaccion	sum_sq	df	F	PR(>F)	eta2_parcial
C(Tipo_Dist)	105.6251	1.0	118.9343	0.0	0.3776
C(Tamaño_Empresa)	24.8461	1.0	27.9768	0.0	0.1249
C(Tipo_Dist):C(Tamaño_Empresa)	15.3264	1.0	17.2576	0.0	0.0809
Residual	174.0669	196.0	NaN	NaN	0.5000

Recomendacion	sum_sq	df	F	PR(>F)	eta2_parcial
C(Tipo_Dist)	63.0323	1.0	83.1164	0.0000	0.2978
C(Tamaño_Empresa)	32.9133	1.0	43.4006	0.0000	0.1813
C(Tipo_Dist):C(Tamaño_Empresa)	1.1417	1.0	1.5055	0.2213	0.0076
Residual	148.6389	196.0	NaN	NaN	0.5000

Recompra	sum_sq	df	F	PR(>F)	eta2_parcial
C(Tipo_Dist)	31.7444	1.0	55.4024	0.0000	0.2204
C(Tamaño_Empresa)	17.1827	1.0	29.9883	0.0000	0.1327
C(Tipo_Dist):C(Tamaño_Empresa)	3.8924	1.0	6.7934	0.0099	0.0335
Residual	112.3039	196.0	NaN	NaN	0.5000

F crítico univariado (95%; 1,196) = 3.8893
F crítico univariado con Bonferroni (alfa=0.05/3; 1,196) = 5.8308

```
1
2 # Diagnósticos multivariados adicionales: Mardia y Mahalanobis.
3 # Estos diagnósticos complementan Box M, Levene y la elección de Pillai.
4 X = df[dvs].to_numpy(float)
5 media = X.mean(axis=0)
6 S = np.cov(X, rowvar=False)
7 Sinv = np.linalg.inv(S)
8 D = (X - media) @ Sinv @ (X - media).T
9 b1p = np.mean(D**3)
10 md2 = np.diag(D)
11 b2p = np.mean(md2**2)
12 n, p_dim = X.shape
13 skew_stat = n * b1p / 6
14 skew_df = p_dim * (p_dim + 1) * (p_dim + 2) // 6
15 skew_p = 1 - stats.chi2.cdf(skew_stat, skew_df)
16 z_kurt = (b2p - p_dim * (p_dim + 2)) / np.sqrt(8 * p_dim * (p_dim + 2) / n)
17 kurt_p = 2 * (1 - stats.norm.cdf(abs(z_kurt)))
18 mah_cut = stats.chi2.ppf(.999, p_dim)
19 print(f'Mardia asimetría: b1p={b1p:.4f}, chi2={skew_stat:.4f}, gl={skew_df}, p={skew_p:.4f}')
20 print(f'Mardia kurtosis: b2p={b2p:.4f}, z={z_kurt:.4f}, p={kurt_p:.4f}')
21 print(f'Mahalanobis máximo={md2.max():.4f}; corte chi2(.999,3)={mah_cut:.4f}; casos sobre corte={(md2 > mah_cut).sum()}')
22
23 # Efectos simples con pruebas t de Welch y corrección Bonferroni por variable dependiente.
24 filas = []
25 for dv in dvs:
26     for size_val, size_lab in [(0, 'Pequeña'), (1, 'Grande')]:
27         directa = df[(df.Tipo_Dist == 1) & (df.Tamaño_Empresa == size_val)][dv]
28         indirecta = df[(df.Tipo_Dist == 0) & (df.Tamaño_Empresa == size_val)][dv]
29         t_stat, p_val = stats.ttest_ind(directa, indirecta, equal_var=False)
30         va, vb = directa.var(ddof=1), indirecta.var(ddof=1)
31         na, nb_ = len(directa), len(indirecta)
32         gl = (va/na + vb/nb_)*2 / ((va/na)*2/(na-1) + (vb/nb_)*2/(nb_-1))
33         filas.append([dv, f'Directa - indirecta | {size_lab}', directa.mean() - indirecta.mean(), t_stat, gl, p_val])
34     for dist_val, dist_lab in [(0, 'Indirecta'), (1, 'Directa')]:
35         grande = df[(df.Tipo_Dist == dist_val) & (df.Tamaño_Empresa == 1)][dv]
36         pequena = df[(df.Tipo_Dist == dist_val) & (df.Tamaño_Empresa == 0)][dv]
37         t_stat, p_val = stats.ttest_ind(grande, pequena, equal_var=False)
38         va, vb = grande.var(ddof=1), pequena.var(ddof=1)
39         na, nb_ = len(grande), len(pequena)
40         gl = (va/na + vb/nb_)*2 / ((va/na)*2/(na-1) + (vb/nb_)*2/(nb_-1))
41         filas.append([dv, f'Grande - pequeña | {dist_lab}', grande.mean() - pequena.mean(), t_stat, gl, p_val])
42
43 efectos_simples = pd.DataFrame(filas, columns=['Variable', 'Comparación', 'Diferencia', 't_Welch', 'gl', 'p'])
44 efectos_simples['p_Bonf'] = np.minimum(efectos_simples['p'] * 4, 1)
45 print('\nEfectos simples Welch con Bonferroni por variable dependiente:')
46 print(efectos_simples.round({'Diferencia': 3, 't_Welch': 3, 'gl': 2, 'p': 4, 'p_Bonf': 4}).to_string(index=False))
47
```

Mardia asimetría: b1p=0.3289, chi2=10.9630, gl=10, p=0.3604
Mardia curtosis: b2p=14.4609, z=-0.6960, p=0.4864
Mahalanobis máximo=17.5371; corte chi2(.999,3)=16.2662; casos sobre corte=1

Efectos simples Welch con Bonferroni por variable dependiente:

Variable	Comparación	Diferencia	t_Welch	gl	p	p_Bonf
Satisfaccion	Directa - indirecta Pequeña	0.917	4.487	82.48	0.0000	0.0001
Satisfaccion	Directa - indirecta Grande	2.042	11.855	94.68	0.0000	0.0000
Satisfaccion	Grande - pequeña Indirecta	0.195	0.946	86.65	0.3466	1.0000
Satisfaccion	Grande - pequeña Directa	1.320	7.767	87.34	0.0000	0.0000
Recomendacion	Directa - indirecta Pequeña	0.988	5.451	83.89	0.0000	0.0000
Recomendacion	Directa - indirecta Grande	1.295	7.539	86.85	0.0000	0.0000
Recomendacion	Grande - pequeña Indirecta	0.680	3.689	89.62	0.0004	0.0015
Recomendacion	Grande - pequeña Directa	0.987	5.862	80.50	0.0000	0.0000
Recompra	Directa - indirecta Pequeña	0.528	3.176	65.69	0.0023	0.0091
Recompra	Directa - indirecta Grande	1.095	7.606	89.15	0.0000	0.0000
Recompra	Grande - pequeña Indirecta	0.332	1.878	79.17	0.0640	0.2562
Recompra	Grande - pequeña Directa	0.899	6.901	71.91	0.0000	0.0000

✓ Gráfico de interacción

Se grafica la media de satisfacción por celda. Las rectas no paralelas ilustran la interacción: la ventaja de la distribución directa es mayor entre las empresas grandes. Este gráfico respalda la Figura 6 del documento.

```
1 # Figura integrada de interacción para las tres variables dependientes.
2 # Cada panel muestra las medias por tamaño de empresa y tipo de distribución.
3 import matplotlib
4 matplotlib.use('Agg')
5 import matplotlib.pyplot as plt
6 from pathlib import Path
7 from IPython.display import Image, display
8 ASSETS_DIR = Path('../assets')
9 ASSETS_DIR.mkdir(parents=True, exist_ok=True)
10
11 labels_tam = {0.0: 'Pequeña', 1.0: 'Grande'}
12 labels_dist = {0.0: 'Distribución indirecta', 1.0: 'Distribución directa'}
13 colors = {0.0: '#1f77b4', 1.0: '#ff7f0e'}
14 markers = {0.0: 'o', 1.0: 's'}
15
16 y_lims = {
17     'Satisfaccion': (6.0, 8.7),
18     'Recomendacion': (5.9, 8.3),
19     'Recompra': (7.0, 8.8),
20 }
21
22 titles = {
23     'Satisfaccion': 'Satisfacción',
24     'Recomendacion': 'Recomendación',
25     'Recompra': 'Recompra',
26 }
27
28 fig, axes = plt.subplots(1, 3, figsize=(13, 4), sharex=True)
29 for ax, dv in zip(axes, dvs):
30     for dist_val in [0.0, 1.0]:
31         medias = []
32         for tam_val in [0.0, 1.0]:
33             media = df[(df['Tipo_Dist'] == dist_val) & (df['Tamaño_Empresa'] == tam_val)][dv].mean()
34             medias.append(media)
35             ax.plot([0, 1], medias, marker=markers[dist_val], color=colors[dist_val], linewidth=2, label=labels_dist[dist_val])
36         ax.set_title(titles[dv])
37         ax.set_xticks([0, 1], ['Pequeña', 'Grande'])
38         ax.set_xlabel('Tamaño de la empresa')
39         ax.set_ylim(*y_lims[dv])
40         ax.grid(alpha=.25)
41 axes[0].set_ylabel('Media')
42 axes[0].legend(loc='upper left', fontsize=8)
43 fig.suptitle('Interacción distribución x tamaño sobre las variables de lealtad', y=1.04)
44 fig.tight_layout()
45 fig.savefig(ASSETS_DIR / 'p4_interaccion_lealtad.png', dpi=200, bbox_inches='tight')
46 plt.close(fig)
47 display(Image(str(ASSETS_DIR / 'p4_interaccion_lealtad.png')))
48 print(f'Figura guardada: {ASSETS_DIR / 'p4_interaccion_lealtad.png'})
```

5. Efectos simples

Dado que existe interacción multivariada, las medias permiten interpretar donde cambia el efecto. Se comparan distribución directa versus indirecta dentro de cada tamaño y tamaño grande versus pequeño dentro de cada distribución.

Figura guardada: ../assets/p4_interaccion_lealtad.png

Se reportan 12 contrastes t de Welch. Con corrección de Bonferroni por familia ($\alpha = 0.05/4 = 0.0125$ por variable dependiente) todas las conclusiones se mantienen: los contrastes significativos conservan $p < 0.0125$ y los no significativos, como grande-pequeña bajo distribución indirecta en satisfacción ($p = 0.347$) y recompra ($p = 0.064$), siguen siéndolo.

```
1 for v in dvs:
2     print('\n',v)
3     for tam in [0,1]:
4         a=df[(df.Tamaño_Empresa==tam)&(df.Tipo_Dist==0)][v]; b=df[(df.Tamaño_Empresa==tam)&(df.Tipo_Dist==1)][v]
5         t,p=stats.ttest_ind(b,a,equal_var=False); print(f'Directa-Indirecta, tamaño {tam}: diferencia={b.mean()-a.me
6     for dist in [0,1]:
7         a=df[(df.Tipo_Dist==dist)&(df.Tamaño_Empresa==0)][v]; b=df[(df.Tipo_Dist==dist)&(df.Tamaño_Empresa==1)][v]
8         t,p=stats.ttest_ind(b,a,equal_var=False); print(f'Grande-Pequeña, distribución {dist}: diferencia={b.mean()-a.me
```

```
Satisfaccion
Directa-Indirecta, tamaño 0: diferencia=0.917, t=4.487, p=2.318e-05
Directa-Indirecta, tamaño 1: diferencia=2.042, t=11.855, p=2.054e-20
Grande-Pequeña, distribución 0: diferencia=0.195, t=0.946, p=0.3466
Grande-Pequeña, distribución 1: diferencia=1.320, t=7.767, p=1.437e-11

Recomendacion
Directa-Indirecta, tamaño 0: diferencia=0.988, t=5.451, p=4.932e-07
Directa-Indirecta, tamaño 1: diferencia=1.295, t=7.539, p=4.279e-11
Grande-Pequeña, distribución 0: diferencia=0.680, t=3.689, p=0.0003856
Grande-Pequeña, distribución 1: diferencia=0.987, t=5.862, p=9.628e-08

Recompra
Directa-Indirecta, tamaño 0: diferencia=0.528, t=3.176, p=0.002273
Directa-Indirecta, tamaño 1: diferencia=1.095, t=7.606, p=2.753e-11
Grande-Pequeña, distribución 0: diferencia=0.332, t=1.878, p=0.06404
Grande-Pequeña, distribución 1: diferencia=0.899, t=6.901, p=1.689e-09
```

6. Conclusión

La medida de lealtad es confiable ($\alpha = 0.876$). La distribución incide en la combinación de resultados, Pillai $V = 0.147$, $F(3, 194) = 11.184$, $p < 0.001$; el tamaño también, $V = 0.097$, $F(3, 194) = 6.959$, $p < 0.001$. Se rechazan H_{01} y H_{02} . (Con efectos de un grado de libertad, Wilks entrega el mismo F .)

La interacción distribución×tamaño también es significativa, Pillai $V = 0.097$, $F(3, 194) = 6.917$, $p < 0.001$: **no son antecedentes independientes**. En los ANOVA, la interacción aparece en satisfacción ($p < 0.001$) y recompra ($p = 0.0099$), pero no en recomendación ($p = 0.221$). Las empresas grandes con distribución directa presentan las mayores medias: satisfacción 8.449, recomendación 8.067 y recompra 8.569. El beneficio de distribución directa es especialmente fuerte en empresas grandes.